Due用于深度强化学习的 ling 网络架构

Ziyu Wang ZIYU@GOOGLE.COM
Tom Schaul SCHAUL@GOOGLE.COM
Matteo Hessel MTTHSS@GOOGLE.COM
哈多·范哈塞尔特 HADO@GOOGLE.COM
马克·兰克托 LANCTOT@GOOGLE.COM
南多·德弗雷塔斯 NANDODEFREITAS@GOOGLE.COM
Google DeepMind，英国伦敦

摘要

近年来，在强化学习中使用深度表示已取得诸多成功。然而，其中许多应用仍采用传统架构，例如卷积网络、LSTMs 或自编码器。本文提出了一种用于无模型强化学习的新型神经网络架构。我们的对偶网络包含两个独立的估计器：一个用于状态价值函数，另一个用于依赖于状态的动作优势函数。这种分解的主要优势在于，无需对底层强化学习算法作任何改动，即可使学习在不同动作之间泛化。我们的结果表明，在存在许多价值相近的动作时，该架构能够实现更好的策略评估。此外，对偶架构使我们的强化学习智能体在 Atari 2600 领域超越了当前最先进的方法。

1. 引言

过去几年，深度学习推动了机器学习在可扩展性和性能方面的显著进步 (LeCun et al., 2015)。一项令人振奋的应用是强化学习 (RL) 和控制中的序贯决策场景。典型示例包括深度 Q 学习 (Mnih et al., 2015)、深度视觉运动策略 (Levine et al., 2015)、结合循环网络的注意力机制 (Ba et al., 2015)，以及结合嵌入表示的模型预测控制 (Watter et al., 2015)。近期的其他成功案例包括大规模并行框架 (Nair et al., 2015) 和围棋中的专家落子预测 (Maddison et al., 2015)，后者生成的策略可与蒙特卡洛树搜索程序的策略相媲美，并在与搜索相结合时，以明显优势击败了一名职业棋手 (Silveret al.,2016)。

尽管如此，大多数 RL 方法仍使用标准神经网络，例如卷积网络、MLPs、LSTMs 和自编码器。这些近期进展的重点在于设计改进的控制与 RL 算法，或仅仅将现有神经网络架构融入 RL 方法。在此，我们采用一种不同但互补的方法，主要致力于创新一种更适合无模型 RL 的神经网络架构。这种方法的优势在于，新网络可以轻松地与现有及未来的 RL 算法结合。也就是说，本文提出了一种新网络（图 1），但使用的是已发表的算法。

所提出的网络架构被我们命名为对偶架构，它显式地分离了以下两者的表示：

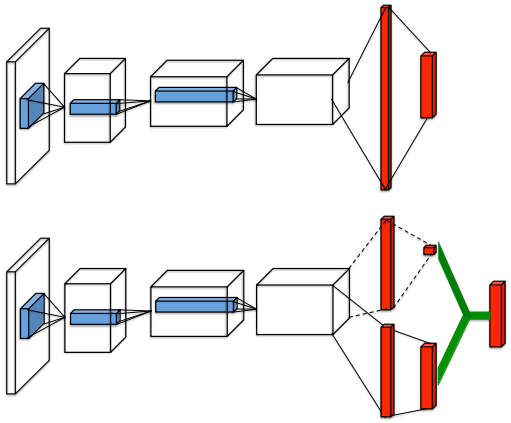


图 *1.*一种常用的单流 Q 网络（上）和对偶 Q 网络（下）。对偶网络具有两个流，分别估计（标量）状态价值和每个动作的优势；绿色输出模块实现公式 (9)，将二者结合。两个网络均针对每个动作 output Q-values。

会议论文集： 33rd 国际机器学习会议，美国纽约州纽约市，2016。JMLR: W&CP 第 48 卷。版权归作者所有，2016。

状态价值和（依赖于状态的）动作优势。对偶架构由两个分别表示价值函数和优势函数的分支组成，同时共享一个卷积特征学习模块。这两个分支通过一个特殊的聚合层进行组合，以生成状态-动作价值函数 Q 的估计，如图 1 所示。应将这一对偶网络理解为一个具有两个分支的单一 Q 网络，它替代了现有算法（例如深度 Q 网络（DQN；Mnih et al., 2015））中广泛使用的单分支 Q 网络。对偶网络无需任何额外监督，即可自动生成状态价值函数和优势函数的独立估计。

直观而言，对偶架构能够学习哪些状态有价值（或没有价值），而无需学习每个状态下每个动作的影响。这在动作不会对环境产生任何相关影响的状态下尤为有用。为说明这一点，请看图 2[1] 中的显著性图。这些图遵循 Simonyan 等人（2013）提出的方法，通过计算训练后的价值流和优势流相对于输入视频的雅可比矩阵生成。（实验部分更详细地介绍了这一方法。）该图展示了两个不同时刻的价值显著性图和优势显著性图。在其中一个时刻（最左侧的一对图像），我们可以看到，价值网络流关注道路，尤其是新车辆出现的地平线。它还关注得分。另一方面，优势流对视觉输入并不太关注，因为当前方没有车辆时，其动作选择实际上无关紧要。然而，在第二个时刻（最右侧的一对图像），由于正前方有一辆车，动作选择变得非常重要，因此优势流会对此予以关注。

在实验中，我们证明，随着学习问题中加入冗余或相似的动作，竞争架构能够在策略评估过程中更快地识别正确的动作。

我们还在具有挑战性的 Atari 2600 测试平台上评估了对偶架构带来的收益。在这里，具有相同结构和超参数的强化学习智能体必须仅通过观察图像像素和游戏得分，就能玩 57 种不同的游戏。结果表明，与 Mnih et al. (2015) 和 van Hasselt et al. (2015) 的单流基线相比，该架构取得了大幅改进。将优先经验回放（Schaul et al., 2016）与所提出的对偶网络相结合，在这一热门领域取得了新的最先进性能。

[1]https://www.youtube.com/playlist?list=PLVFXyCSfS2Pau0gBh0mwTxDmutywWyFBP

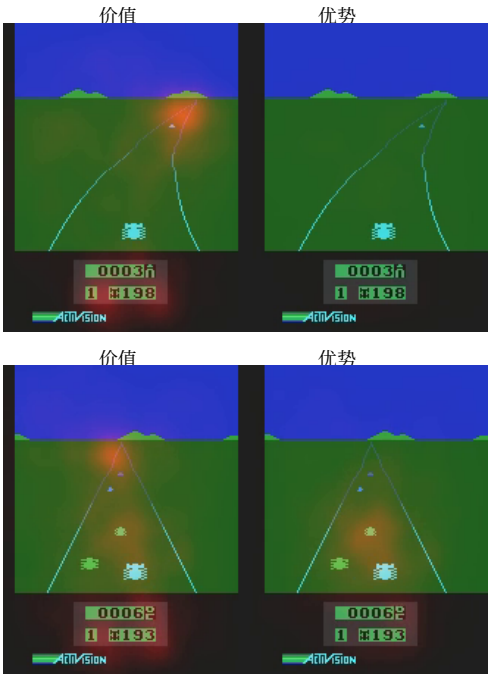


图 2.观察、关注并驾驶：训练后的对偶架构在 Atari 游戏 Enduro 中的价值和优势显著性图（红色叠加层）。价值流学会关注道路。优势流学会仅在正前方有车辆时予以关注，以避免碰撞。

1.1. 相关工作

分别维护价值函数和优势函数的概念可以追溯到 Baird (1993)。在 Baird 最初的优势更新算法中，共享的贝尔曼残差更新方程被分解为两个更新：一个用于状态价值函数，另一个用于与之关联的优势函数。Harmon et al. (1995) 表明，在简单的连续时间领域中，优势更新比 Q-learning 收敛得更快。其后继算法，即优势学习算法，仅表示一个优势函数（Harmon & Baird, 1996）。

对偶架构使用单个深度模型同时表示价值函数 $V(s)$ 和优势函数 $A(s,a)$，其输出将二者结合，生成状态-动作价值 $Q(s,a)$。与优势更新不同，该架构在设计上将表示与算法解耦。因此，对偶架构可以与多种无模型强化学习算法结合使用。

优势函数在策略梯度中的应用历史悠久，始于 (Sutton et al., 2000)。作为这一研究方向的近期示例，Schulman et al. (2015) 在线估计优势值，以降低策略梯度算法的方差。

已有若干尝试使用深度

强化学习玩 Atari 游戏，包括 Mnih 等人 (2015)；Guo 等人 (2014)；Stadie 等人 (2015)；Nair 等人 (2015)；van Hasselt 等人 (2015)；Bellemare 等人 (2016) 和 Schaul 等人 (2016)。Schaul 等人 (2016) 的结果是目前已发表研究中的最先进水平。

2. 背景

我们考虑一种序贯决策设定，其中智能体在离散时间步上与环境 $\mathcal{E}$ 交互，相关介绍参见 Sutton & Barto (1998)。例如，在 Atari 领域中，智能体在时间步 t感知由 M个图像帧组成的视频 s_t： $s_t = (x_{t-M+1}, \dots, x_t) \in \mathcal{S}$。随后，智能体从离散集合 $a_t \in \mathcal{A} = \{1, \dots, |\mathcal{A}|\}$ 中选择一个动作，并观测游戏模拟器给出的奖励 signal r_t produced。

智能体力求最大化期望折扣回报，其中我们将折扣回报定义为 $R_t = \sum_{\tau=t}^{\infty} \gamma^{\tau-t} r_\tau$。在这一表述中，$\gamma \in [0, 1]$ 是一个折扣因子，用于权衡即时奖励与未来奖励的重要性。

对于按照随机策略 policy π行动的智能体，状态-动作对 (s, a) 的价值和状态 s 的价值定义如下

$$\begin{aligned} Q^\pi(s, a) &= \mathbb{E}\left[R_t \middle| s_t = s, a_t = a, \pi\right], \text{ and} \\ V^\pi(s) &= \mathbb{E}_{a\sim\pi(s)}\left[Q^\pi(s, a)\right]. \end{aligned} \tag{1}$$

上述状态-动作价值函数（简称Q 函数）可通过动态规划递归计算：

$$Q^\pi(s, a) = \mathbb{E}_{s'}\left[r + \gamma \mathbb{E}_{a'\sim\pi(s')}\left[Q^\pi(s', a')\right] \mid s, a, \pi\right].$$

我们定义最优的 $Q^*(s, a) = \max_\pi Q^\pi(s, a)$。在确定性策略 $a = \arg\max_{a'\in\mathcal{A}} Q^*(s, a')$下，可得 $V^*(s) = \max_a Q^*(s, a)$。由此还可得，最优 Q 函数满足贝尔曼方程：

$$Q^*(s, a) = \mathbb{E}_{s'}\left[r + \gamma \max_{a'} Q^*(s', a') \mid s, a\right]. \tag{2}$$

我们定义另一个重要的量，即优势函数，它关联价值 and Q functions:

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s). \tag{3}$$

注意， $\mathbb{E}_{a\sim\pi(s)}\left[A^\pi(s, a)\right] = 0$。直观地说，价值函数 V 衡量处于特定状态 s 的好坏程度。然而， Q 函数衡量在该状态下选择某个特定动作的价值。优势函数减去状态价值 from Q to，得到衡量各个动作重要性的相对指标。

2.1. 深度Q网络

上一节所述的价值函数是高维对象。为了近似这些函数，我们可以使用一个深度 Q 网络： $Q(s, a; \theta)$，其参数为 θ。为了估计该网络，我们在 iteration i 处优化以下损失函数序列：

$$L_i(\theta_i) = \mathbb{E}_{s,a,r,s'}\left[\left(y_i^{DQN} - Q(s, a; \theta_i)\right)^2\right], \tag{4}$$

其中

$$y_i^{DQN} = r + \gamma \max_{a'} Q(s', a'; \theta^-), \tag{5}$$

其中， θ^- 表示一个固定且独立的目标网络的参数。我们可以尝试使用标准的 Q-学习来在线学习网络 $Q(s, a; \theta)$的参数。然而，这种估计器在实践中表现不佳。(Mnih et al., 2015)中的一项关键创新是，在固定次数的迭代中冻结目标网络 $Q(s', a'; \theta^-)$的参数，同时通过梯度下降更新在线网络 $Q(s, a; \theta_i)$。（这极大地提高了算法的稳定性。）具体的梯度更新为

$$\nabla_{\theta_i} L_i(\theta_i) = \mathbb{E}_{s,a,r,s'}\left[\left(y_i^{DQN} - Q(s, a; \theta_i)\right)\nabla_{\theta_i} Q(s, a; \theta_i)\right]$$

这种方法是无模型的，因为状态和奖励由环境产生。它也是离策略的，因为这些状态和奖励是通过一种行为策略（在 DQN 中为 epsilon 贪心策略）获得的，该行为策略不同于正在学习的在线策略。

DQN 成功的另一个关键要素是经验回放（Lin, 1993; Mnih et al., 2015 ）。在学习过程中，智能体从多个回合中积累由经验 $e_t = (s_t, a_t, r_t, s_{t+1})$ 构成的数据集 $\mathcal{D}_t = \{e_1, e_2, \dots, e_t\}$。训练 Q-网络时，并非仅使用标准时序差分学习所规定的当前经验，而是从 $\mathcal{D}$ 中均匀随机采样经验的小批量来训练网络。因此，损失序列具有如下形式

$$L_i(\theta_i) = \mathbb{E}_{(s,a,r,s')\sim\mathcal{U}(\mathcal{D})}\left[\left(y_i^{DQN} - Q(s, a; \theta_i)\right)^2\right].$$

经验回放通过在多次更新中重复使用经验样本来提高数据效率，而且更为重要的是，它还降低了方差，因为从回放缓冲区中均匀采样降低了用于更新的样本之间的相关性。

2.2. 双重深度 Q 网络

上一节介绍了 (Mnih et al., 2015) 中提出的 DQN 的主要组成部分。在本文中，

我们采用 van Hasselt et al. (2015) 提出的改进型 Double DQN (DDQN) 学习算法。在 Q-learning 和 DQN 中，max 算子使用相同的值来选择和评估动作。因此，这可能导致过于乐观的价值估计 (van Hasselt,2010)。为缓解这一问题，DDQN 使用以下目标：

$$y_i^{DDQN} = r + \gamma Q(s', \arg\max_{a'} Q(s', a'; \theta_i); \theta^-). \quad (6)$$

DDQN 与 DQN 相同（参见 Mnih 等人 (2015)），但将目标 y_i^{DQN} 替换为 y_i^{DDQN}。DDQN 的伪代码见附录 A。

2.3. 优先经验回放

近期，优先经验回放方面的一项创新（Schaul 等人，2016）建立在 DDQN 的基础上，进一步提升了当前最佳性能。其核心思想是提高预期学习进展较大的经验元组的回放概率（以 TD 误差的绝对值作为代理指标来衡量）。与均匀经验回放相比，这使得在 Atari 基准测试集的大多数游戏中，学习速度更快，最终策略质量也更高。

为进一步支持我们的对偶架构与算法创新具有互补性这一论断，我们展示了该架构能够提升均匀回放和优先回放两种基线的性能（对于优先回放，我们选择了更易实现的基于排序的变体），由此得到的优先回放对偶变体取得了新的最佳性能。

3. 对偶网络架构

如图 2 所示，我们的新架构背后的关键洞见是：对于许多状态，无需估计每个可选动作的价值。例如，在 Enduro 游戏场景中，只有当碰撞即将发生时，判断应该向左还是向右移动才有意义。在某些状态下，知道应采取哪个动作至关重要，但在许多其他状态下，动作的选择并不会影响后续发生的情况。然而，对于基于自举的算法，每个状态的状态价值估计都非常重要。

为实现这一思路，我们设计了一个单一的 Q- 网络架构，如图 1 所示，我们将其称为对偶网络。对偶网络的底层与原始 DQN（Mnih et al., 2015）一样，采用卷积层。然而，我们并未在卷积层之后接入单一的全连接层序列，而是使用两个全连接层序列（或流）。这两个流的构造使其能够分别估计价值函数和优势函数。最后，将这两个流组合起来，生成单一的输出 Q 函数。与（Mnih et al., 2015）中一样，网络的输出是一个集合 of Q values，其中每个动作对应一个元素。由于对偶网络的输出是一个 Q 函数，因此可以使用许多现有算法进行训练，例如 DDQN 和 SARSA。此外，它还可以受益于这些算法的任何改进，包括更好的经验回放存储、更好的探索策略、内在动机等。

将两路全连接层合并以输出 a Q estimate 的模块需要经过十分周密的设计。

由优势函数 $Q^\pi(s,a) = V^\pi(s) + A^\pi(s,a)$ 和状态价值函数 $V^\pi(s) = \mathbb{E}_{a\sim\pi(s)}[Q^\pi(s,a)]$, 的表达式可得 $\mathbb{E}_{a\sim\pi(s)}[A^\pi(s,a)] = 0$。此外，对于确定性策略， $a^* = \arg\max_{a'\in\mathcal{A}} Q(s,a')$, 可得 $Q(s,a^*) = V(s)$，因此 $A(s,a^*) = 0$。

考虑图 1 所示的对偶网络，其中我们使一个全连接层分支输出标量 $V(s;\theta,\beta)$，另一个分支输出 $|\mathcal{A}|$ 维向量 $A(s,a;\theta,\alpha)$。这里， θ 表示卷积层的参数，while α and β 是两个全连接层分支的参数。

根据优势的定义，我们可能会倾向于按如下方式构建聚合模块：

$$Q(s,a;\theta,\alpha,\beta) = V(s;\theta,\beta) + A(s,a;\theta,\alpha), \quad (7)$$

注意，此表达式适用于所有 (s,a) 实例；也就是说，要以矩阵形式表示方程 (7)，我们需要将标量 $V(s;\theta,\beta)$ 复制 $|\mathcal{A}|$ 次。

然而，我们需要牢记， $Q(s,a;\theta,\alpha,\beta)$ 只是真实 Q 函数的参数化估计。此外，若据此断定 $V(s;\theta,\beta)$ 是状态价值函数的良好估计器，或同样断定 $A(s,a;\theta,\alpha)$ 能够提供对优势函数的合理估计，都是错误的。

方程 (7) 是不可辨识的，即给定 Q，我们无法唯一地 recover V and A 。为说明这一点，可给 $V(s;\theta,\beta)$ 加上一个常数，并从 from$A(s,a;\theta,\alpha)$ 中减去同一个常数。该常数相互抵消，从而得到相同的 Q 值。直接使用此方程时，实际性能较差，这也反映了这种不可辨识性。

为解决这一可辨识性问题，我们可以强制优势函数估计器在所选动作处的优势为零。也就是说，我们让网络的最后一个模块实现如下前向映射

$$Q(s,a;\theta,\alpha,\beta) = V(s;\theta,\beta) + \left(A(s,a;\theta,\alpha) - \max_{a'\in|\mathcal{A}|} A(s,a';\theta,\alpha)\right). \quad (8)$$

现在，对于 $a^* = \arg\max_{a' \in \mathcal{A}} Q(s, a'; \theta, \alpha, \beta) = \arg\max_{a' \in \mathcal{A}} A(s, a'; \theta, \alpha)$，我们得到 $Q(s, a^*; \theta, \alpha, \beta) = V(s; \theta, \beta)$。因此，分支 $V(s; \theta, \beta)$ 提供价值函数的估计，而另一分支则产生优势函数的估计。

另一种模块用平均值替代最大值算子：

$$Q(s, a; \theta, \alpha, \beta) = V(s; \theta, \beta) + \left(A(s, a; \theta, \alpha) - \frac{1}{|\mathcal{A}|} \sum_{a'} A(s, a'; \theta, \alpha) \right). \quad (9)$$

一方面，这会使 V and A because 失去原有的语义，因为它们现在与目标值相差一个常数；但另一方面，这提高了优化的稳定性：在式 (9) 中，优势只需以与均值相同的速度变化，而不必补偿式 (8) 中最优动作优势的任何变化。我们还尝试了式 (8) 的 softmax 版本，但发现其结果与式 (9) 中更简单的模块相近。因此，本文报告的所有实验均采用式 (9) 中的模块。

请注意，虽然在式 (9) 中减去均值有助于保证可辨识性，但这不会改变 A （因而也不会改变 Q）值的相对排序，从而保留了基于式 (7) 中 Q 值的任何贪婪策略或 ϵ-贪婪策略。在执行动作时，只需计算优势分支即可作出决策。

需要注意的是，方程 (9) 被视为网络的一部分并作为网络的一部分实现，而非单独的算法步骤。与标准 Q 网络（例如 Mnih et al. (2015) 的深度 Q网络）一样，决斗架构的训练仅需反向传播。估计值 $V(s; \theta, \beta)$ 和 $A(s, a; \theta, \alpha)$ 自动计算，无需任何额外监督或算法修改。

由于决斗架构与标准 Q 网络具有相同的输入输出接口，我们可以复用所有用于 Q 网络的学习算法（例如，DDQN 和 SARSA）来训练决斗架构。

4. 实验

现在我们展示决斗网络的实际性能。我们从一个简单的策略评估任务开始，然后展示在更大规模上学习通用 Atari 游戏策略的结果。

4.1. 策略评估

我们首先衡量决斗架构在策略评估任务上的性能。我们选择这一特定的任务，是因为它非常适合用于评估网络架构，因为其中不存在探索策略的选择以及策略改进与策略评估之间的交互等混杂因素。

在本实验中，我们采用时序差分学习（不使用资格迹，即，$\lambda = 0$）来 learn Q values. 更具体地说，给定行为策略 π，我们通过优化方程 (4) 中的代价序列来估计状态-动作价值 $Q^\pi(\cdot, \cdot)$，其目标为

$$y_i = r + \gamma \mathbb{E}_{a' \sim \pi(s')} \left[Q(s', a'; \theta_i) \right].$$

上述更新规则与 Expected SARSA（van Seijen et al., 2009）的更新规则相同。然而，我们并不像 Expected SARSA 那样修改行为策略。

为了评估学习到的 Q 值，我们选择了一个简单的环境，在该环境中，可以针对所有 $(s, a) \in \mathcal{S} \times \mathcal{A}$ 分别计算精确的 $Q^\pi(s, a)$ 值。我们将这个环境称为走廊，它由三条相互连接的走廊组成。走廊环境的示意图如图 3 所示。智能体从环境的左下角出发，必须移动到右上角才能获得最大奖励。共有 5 种可用动作：向上、向下、向左、向右以及空操作。我们还可以自由添加任意数量的空操作动作。在我们的设置中，两个竖直部分各有 10 个状态，而水平部分有 50 个状态。

我们使用 ϵ-贪心策略作为行为策略 π，该策略以 probability ϵ or 选择随机动作，以概率 $1 - \epsilon$ 根据最优 Q 函数 $\arg\max_{a \in \mathcal{A}} Q^*(s, a)$ 选择动作。在我们的实验中，ϵ 取值为 0.001。

我们在走廊环境的三种变体上比较单流 Q 架构与对偶架构，这三种变体分别有 5、10 和 20 个动作。具有 10 和 20 个动作的变体通过向原始环境添加空操作构建而成。我们通过相对于真实状态值的平方误差 (SE) 衡量性能：$\sum_{s \in \mathcal{S}, a \in \mathcal{A}} (Q(s, a; \theta) - Q^\pi(s, a))^2$。单流架构是一个三层 MLP，每个隐藏层有 50 个单元。对偶架构也由三层组成。不过，在具有 50 个单元的第一个隐藏层之后，网络分为两个流，每个流都是一个具有 25 个隐藏单元的两层 MLP。结果汇总于图 3。

结果表明，当有 5 个动作时，两种架构的收敛速度大致相同。然而，当我们增加动作数量时，决斗架构的表现优于传统的 Q-网络。在决斗网络中，分支 $V(s; \theta, \beta)$ 学习一个在 s 处由许多相似动作共享的通用价值，从而加快收敛。这一结果非常有前景，因为许多具有大动作空间的控制任务都具有这一特-

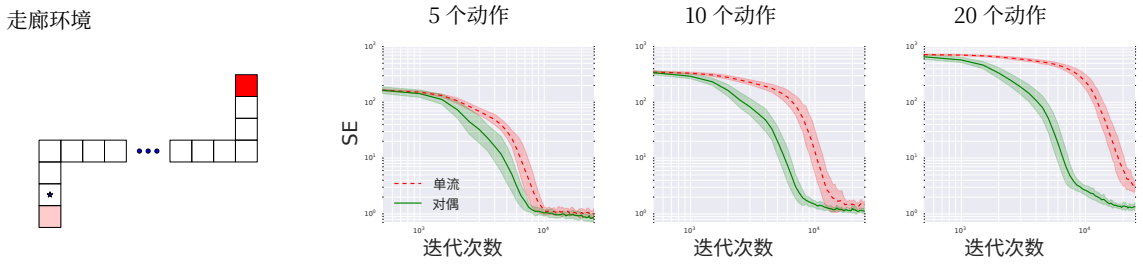


图 *3.***(a)** 走廊环境。星号标记起始状态。状态的红色深浅表示智能体到达该状态时获得的奖励。到达任一奖励状态时，游戏结束。智能体的动作包括向上、向下、向左、向右和不采取动作。图 **(b), (c)** 和 **(d)** 以双对数坐标展示了在 5、10 和 20 个动作下进行策略评估的平方误差。对偶网络（Duel）的性能始终优于传统的单流网络（Single），且性能差距随动作数量的增加而扩大。

性，因此我们应当预期，决斗网络的收敛速度会远快于传统的单分支网络。在下一节中，我们确实将看到，决斗网络在多种 Atari 游戏中带来了显著的性能提升。

4.2. 通用 Atari 游戏玩法

我们在由 57 款 Atari 游戏组成的街机学习环境（Arcade Learning Environment，Bellemare et al., 2013）中，对所提出的方法进行了全面评估。其挑战在于，采用单一算法和架构以及一组固定的超参数，仅凭原始像素观测和游戏奖励来学习玩所有游戏。这一环境极具挑战性，因为它既包含大量差异显著的游戏，又具有高维观测。

我们严格遵循 van Hasselt et al. (2015) 的实验设置，并与其使用单流 Q 网络所得的结果进行比较。我们使用 DDQN 算法训练对偶网络（见附录 A）。在本节末尾，我们引入优先经验回放（Schaul et al., 2016）。

我们的网络架构具有与 DQN（Mnih et al., 2015; van Hasselt et al., 2015）相同的底层卷积结构。共有 3 个卷积层，后接 2 个全连接层。第一个卷积层 has 32 8×8 filters，步幅为 4；第二个卷积层有 64 4×4 个滤波器，步幅为 2；第三个也是最后一个卷积层 layer64 3×3 filters，步幅为 1。如图 1 所示，决斗网络分为两个由全连接层构成的分支。价值分支和优势分支各有一个包含 512 个单元的全连接层。价值分支和优势分支的最后一个隐藏层均为全连接层，其中价值分支有一个输出，优势分支的输出数量与有效的 actions[2]. 的数量相同。我们使用以下公式所描述的模块来组合价值分支和优势分支：

[2]在 ALE 环境中，动作数量范围为 3-18。

公式 (9)。所有相邻层之间均插入了整流非线性函数（Fukushima, 1980）。

我们采用 van Hasselt et al. (2015) 的优化器和超参数，但将学习率设得略低一些（对于双重 DQN，我们不作此调整，因为这可能降低其性能）。由于优势流和价值流在反向传播过程中都会将梯度传递到最后一个卷积层，我们将传入最后一个卷积层的合并梯度乘以 $1/\sqrt{2}$ 进行缩放。这一简单的启发式方法略微提高了稳定性。此外，我们对梯度进行裁剪，使其范数小于或等于 10。这种裁剪并非深度强化学习中的标准做法，但在循环网络训练中很常见（Bengio et al., 2013）。

为了单独考察对偶架构的贡献，我们采用与上述完全相同的流程，使用单流网络重新训练 DDQN。具体而言，我们应用梯度裁剪，并在网络的第一个全连接层中使用 1024 个隐藏单元，使两种架构（对偶架构和单流架构）的参数数量大致相同。我们将这个重新训练的模型称为 单流裁剪，而将 van Hasselt 等人（2015）原先训练的模型称为单流。

与（van Hasselt 等人，2015）中的做法一样，我们在游戏开始时执行最多 *30* 个无操作 动作，为智能体提供随机的起始位置。为了评估我们的方法，我们以人类得分和基准智能体得分中较高者为基准，衡量得分提升的百分比（正值或负值）：

$$\frac{\text{Score}_{\text{Agent}} - \text{Score}_{\text{Baseline}}}{\max\{\text{Score}_{\text{Human}}, \text{Score}_{\text{Baseline}}\} - \text{Score}_{\text{Random}}}. \tag{10}$$

我们取人类得分与基线智能体得分中的最大值，因为当所考察的智能体和基线智能体表现都不佳时，这样可以避免将微小的变化呈现为大幅提升。例如，当基线智能体达到人类表现的 1% 时，不应将达到人类表现的 2% 的智能体解读为表现好了一倍。我们还选择不衡量

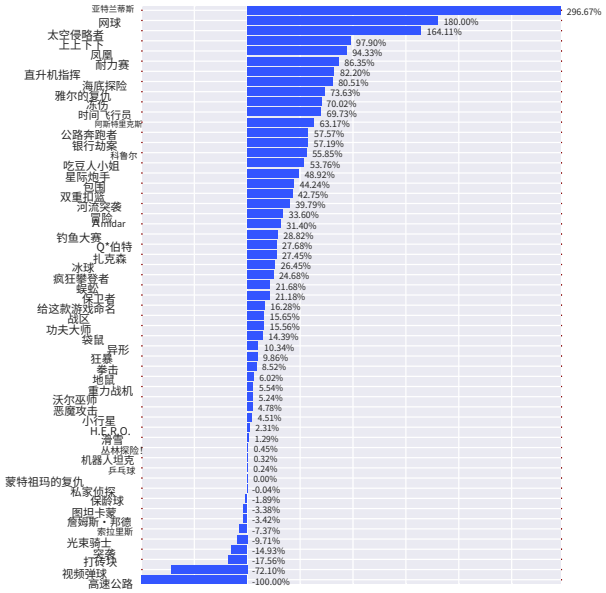


图 *4.* 对偶架构相对于 van Hasselt et al. (2015) 的基线 Single 网络的改进，采用公式 (10) 中描述的指标。向右延伸的条形表示对偶网络优于单流网络的幅度。

仅以人类表现的百分比表示的性能，因为在某些游戏中，相对于基线的微小差异可能转化为以人类表现百分比衡量的数百个百分点的差异。

57 款游戏的广泛测试结果汇总于表1。详细结果见附录。

采用这一 30 次空操作性能度量，对偶网络 (Duel Clip) 的表现显著优于容量相近的 Single Clip 网络。它的表现也明显优于 van Hasselt et al. (2015) 的基线 (Single)。作为参考，我们还展示了 Mnih et al. (2015) 的深度 Q-网络的结果，该网络称为 Nature DQN。

图 4 展示了对偶网络相对于 van Hasselt et al. (2015) 的基线 Single 网络的改进。我们再次看到，这些改进往往非常显著。

如表 1 所示，Single Clip 的表现优于 Single。我们验证了这一提升主要来自梯度裁剪。因此，我们在所有新方法中都采用梯度裁剪。

Duel Clip 在 75.4% 的游戏（57 款中的 43 款）中表现优于 Single Clip。与 Single 基线相比，它还在 80.7% 的游戏（57 款中的 46 款）中取得了更高的分数。在所有具有 18 个动作的游戏中，Duel Clip 在 86.6% 的游戏（30 款中的 26 款）中表现更好。这与上一节的发现一致。总体而言，我们的智能体（Duel Clip）在 57 款游戏中的 42 款中达到了人类水平的表现

表 *1.* 全部 57 款 Atari 游戏的平均得分和中位数得分，以人类表现的百分比衡量。

	30 次空操作		人类起始状态	
	平均值	**中位数**	**均值**	**中位数**
优先化 双流 裁剪	**591.9%**	**172.1%**	**567.0%**	**115.3%**
优先单网络	434.6%	123.7%	386.7%	112.9%
对决 裁剪	**373.1%**	**151.5%**	**343.8%**	**117.1%**
单流 裁剪	341.2%	132.6%	302.8%	114.1%
单一	307.3%	117.8%	332.9%	110.9%
《自然》DQN	227.9%	79.1%	219.6%	68.5%

。所有游戏的原始分数以及以人类表现百分比衡量的结果均列于附录中。

对人类起始状态的鲁棒性。30 次无操作指标的一个不足是，智能体未必需要具备良好的泛化能力就能玩 Atari 游戏。由于 Atari 环境具有确定性，从一个固定的起点出发，智能体只需记住动作序列，就可能学会取得良好的表现。

为获得更稳健的衡量指标，我们采用 Nair et al. (2015) 的方法。具体而言，对于每款游戏，我们从人类专家的轨迹中采样 100 个起点。从每个起点启动一个评估回合，最多运行 108,000 帧。评估智能体时，仅计入起点之后累积的奖励。我们将这一指标称为人类起始状态。

如表 1 所示，在人类起始状态指标下，Duel Clip 再次优于单流变体。具体而言，我们的智能体在 70.2% 的游戏（57 款中的 40 款）上优于 Single 基线；在具有 18 个动作的游戏中，Duel Clip 在 83.3% 的游戏（30 款中的 25 款）上表现更好。

与优先经验回放相结合。决斗架构可以很容易地与其他算法改进相结合。特别是，已有研究表明，对经验回放进行优先级排序可显著提升 Atari 游戏的性能 (Schaul et al., 2016)。此外，由于优先级排序与决斗架构针对学习过程中截然不同的方面，二者的结合很有前景。因此，在最后一项实验中，我们研究了决斗架构与优先经验回放的整合。我们使用 DDQN 的优先级变体 (Prior. Single) 作为新的基线算法，用基于排名的优先采样替代经验元组的均匀采样。我们保留 (Schaul et al., 2016) 中所述的优先回放的所有参数，即优先级指数为 0.7，重要性采样指数按退火计划从 0.5 增至 1。我们将此基线与我们的决斗架构相结合（如上所述），并再次使用梯度裁剪 (Prior. Duel Clip)。

请注意，尽管这些扩展在目标上相互独立，但它们

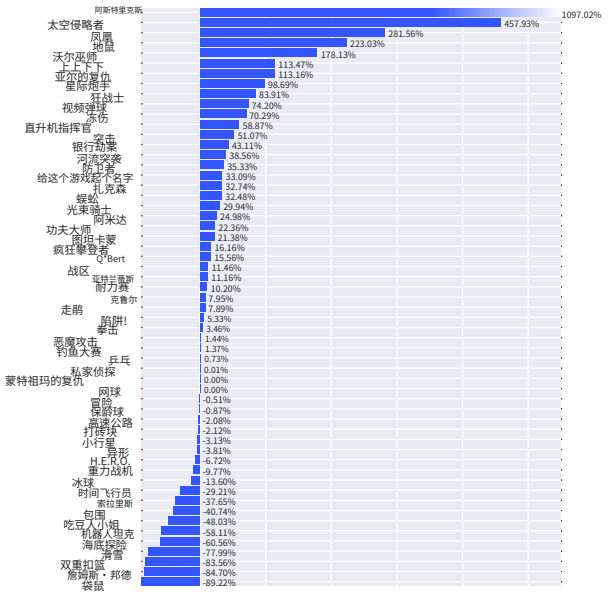


图 *5.* 对偶架构相较于优先级 DDQN 基线的性能提升，采用与图 4 相同的度量指标。同样，对偶架构在大多数游戏中相较于单流基线取得了显著提升。

（优先级采样、对偶架构和梯度裁剪）之间存在微妙的相互作用。例如，优先级采样会与梯度裁剪相互作用，因为更频繁地采样绝对 TD 误差较大的转移会导致梯度范数增大。为避免不利的相互作用，我们在由 9 个游戏组成的子集上对学习率和梯度裁剪范数进行了粗略的重新调优。经过粗略调优，我们最终将学习率设为 6.25×10^{-5}，将梯度裁剪范数设为 10（与上一节相同）。

在全部 57 款 Atari 游戏上进行评估时，我们的优先级对偶智能体的表现显著优于优先级基线智能体和单独使用的对偶智能体。表 1 展示了以人类表现百分比衡量的完整平均性能和中位数性能。在使用最多 30 次无操作动作初始化游戏时，我们观察到平均得分和中位数得分分别为 591% 和 172%。图 5 使用公式 10 中描述的度量指标，展示了优先级基线版本与优先级对偶版本的直接比较。

优先级经验回放与对偶网络的结合，在广泛使用的 ALE 基准上相较于此前的最先进方法取得了大幅提升。

显著性图。为了更好地理解价值流和优势流的作用，我们计算显著性图（Simonyan et al., 2013）。更具体地说，为了可视化价值流所看到的图像显著部分，we$\widehat{\ }$compute V 相对于$\widehat{\ }$输入帧的雅可比矩阵的绝对值：$|\nabla_s V(s;\theta)|$. 类似地，为了可视化优势$\widehat{\ }$$\widehat{\ }$流所看到的图像显著部分，我们计算 $|\nabla_s A(s,\arg\max_{a'} A(s,a');\theta)|$。这两个量的维度均与输入帧相同，因此可以方便地并排可视化。

这里，我们将灰度输入帧放入绿色和蓝色通道，将显著性图放入红色通道。三个通道共同构成一幅 RGB 图像。图 2 展示了 Enduro 游戏中两个不同时刻的价值显著性图和优势显著性图。如引言中所述，价值分支关注地平线，因为那里出现的汽车可能影响未来的表现。价值分支也关注得分。另一方面，优势分支更关注即将发生碰撞的汽车。

5. 讨论

对偶架构的优势部分在于它能够高效地学习状态价值函数。对偶架构中的 Q 值每次更新时，价值分支 V 都会更新——这与单分支架构中的更新不同，后者仅更新一个动作的价值，而所有其他动作的价值均保持不变。我们的方法更频繁地更新价值分支，为 V分配了更多资源，从而能够更好地逼近状态价值；对于 Q-learning 等基于时序差分的方法，准确的状态价值是其有效运行的必要条件（Sutton & Barto, 1998）。这一现象在实验中得到了体现：当动作数量较大时，对偶架构相对于单分支 Q网络的优势随之增大。

此外，对于给定状态，Q值之间的差异相对于 Q的量级通常很小。例如，在 Seaquest 游戏上使用 DDQN 训练后，在访问过的状态中，平均动作间隙（给定状态下最优动作与次优动作的 Q值之差）约为 0.04，而这些状态的平均状态价值约为 15。这种尺度差异意味着，更新中的少量噪声就可能改变动作的排序，从而使近似贪心策略发生突变。决斗架构具有独立的优势分支，对此类影响具有鲁棒性。

6. 结论

我们提出了一种新的神经网络架构，在共享同一个特征学习模块的同时，将深度 Q-网络中的价值与优势解耦。这种新的对偶架构结合若干算法改进，在具有挑战性的 Atari 领域中，相较于现有深度强化学习方法实现了显著的性能提升。本文所呈现的结果在这一热门领域达到了新的最先进水平。

参考文献

Ba, J., Mnih, V., 和 Kavukcuoglu, K. 基于视觉注意力的多目标识别。载于*ICLR*，2015。Baird, L.C. 优势更新。技术报告 WL- TR-93-1146，赖特-帕特森空军基地，1993。Bellemare, M. G., Naddaf, Y., Veness, J., 和 Bowling, M. 街机学习环境：通用智能体的评估平台。人工智能研究期刊，47:253–279, 2013。

Bellemare, M. G., Ostrovski, G., Guez, A., Thomas, P. S., 和 Munos, R. 增大动作差距：强化学习的新算子。载于*AAAI*，2016。待发表。

Bengio, Y., Boulanger-Lewandowski, N., 和 Pascanu, R. 循环网络优化的进展。载于 *ICASSP*，第 8624–8628 页，2013。Fukushima, K. Neocognitron：一种用于不受位置偏移影响的模式识别机制的自组织神经网络模型。生物控制论，36: 193–202，1980。

Guo, X., Singh, S., Lee, H., Lewis, R. L., 和 Wang, X. 使用离线蒙特卡洛树搜索规划进行实时 Atari 游戏的深度学习。载于 *NIPS*，第 3338– 3346 页。2014。

Harmon, M.E. 和 Baird, L.C. 使用通用函数逼近的多玩家残差优势学习。技术报告 WL-TR-1065，赖特-帕特森空军基地，1996。Harmon, M.E., Baird, L.C., 和 Klopf, A.H. 应用于微分博弈的优势更新。载于 G. Tesauro, D.S. Touretzky 和 Leen, T.K.（编），*NIPS*，1995。

LeCun, Y., Bengio, Y., 和 Hinton, G. 深度学习。自然, 521(7553):436–444，2015。

Levine, S., Finn, C., Darrell, T., 和 Abbeel, P. 深度视觉运动策略的端到端训练。*arXiv* 预印本 *arXiv:1504.00702*, 2015. Lin, L.J. 使用神经网络的机器人强化学习。博士学位论文，卡内基梅隆大学计算机科学学院，1993. Maddison, C. J., Huang, A., Sutskever, I., 和 Silver, D. 使用深度卷积神经网络进行围棋落子评估。载于*ICLR*, 2015. Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Ve- ness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wier- stra, D., Legg, S., 和 Hassabis, D. 通过深度强化学习实现人类水平的控制。自然, 518 (7540):529–533, 2015.

Nair, A., Srinivasan, P., Blackwell, S., Alcicek, C., Fearon, R., Maria, A. De, Panneershelvam, V., Suley- man, M., Beattie, C., Petersen, S., Legg, S., Mnih, V., Kavukcuoglu, K., 和 Silver, D. 深度强化学习的大规模并行方法。载于深度学习研讨会，*ICML*, 2015. Schaul, T., Quan, J., Antonoglou, I., 和 Silver, D. 优先经验回放。载于 *ICLR*, 2016. Schulman, J., Moritz, P., Levine, S., Jordan, M. I., 和 Abbeel, P. 使用广义优势估计的高维连续控制。arXiv 预印本 arXiv:1506.02438, 2015. Silver, D., Huang, A., Maddison, C.J., Guez, A., Sifre, L., van den Driessche, G., Schrittwieser, J., Antonoglou, I., Panneershelvam, V., Lanctot, M., Dieleman, S., Grewe, D., Nham, J., Kalchbrenner, N., Sutskever, I., Lillicrap, T., Leach, M., Kavukcuoglu, K., Graepel, T., 和 Has- sabis, D. 利用深度神经网络和树搜索精通围棋。自然, 529(7587):484–489, 01 2016. Simonyan, K., Vedaldi, A., 和 Zisserman, A. 深入卷积网络内部：图像分类模型与显著性图的可视化。*arXiv* 预印本 *arXiv:1312.6034*, 2013. Stadie, B. C., Levine, S., 和 Abbeel, P. 利用深度预测模型激励强化学习中的探索。*arXiv* 预印本 *arXiv:1507.00814*, 2015. Sutton, R. S. 和 Barto, A. G. 强化学习导论。麻省理工学院出版社，1998. Sutton, R. S., Mcallester, D., Singh, S., 和 Mansour, Y. 使用函数逼近的强化学习策略梯度方法。载于*NIPS*，第 1057–1063 页，2000. van Hasselt, H. 双重 Q 学习。*NIPS*, 23:2613–2621, 2010. van Hasselt, H., Guez, A., 和 Silver, D. 使用双重 Q 学习的深度强化学习。*arXiv* 预印本 *arXiv:1509.06461*, 2015. van Seijen, H., van Hasselt, H., Whiteson, S., 和 Wier- ing, M. Expected Sarsa 的理论与实证分析。载于 *IEEE* 自适应动态规划与强化学习研讨会，第 177–184 页。2009. Watter, M., Springenberg, J. T., Boedecker, J., 和 Ried- miller, M. A. 嵌入以实现控制：用于从原始图像进行控制的局部线性潜在动力学模型。载于 *NIPS*, 2015.