文章

DeepSeek-R1通过强化学习激励大语言模型的推理能力

https://doi.org/10.1038/s41586-025-09422-z

收稿日期：2025年2月14日

接收日期：2025年7月17日

在线发布：2025年9月17日

开放获取

查看更新

通用推理是人工智能（AI）领域一个长期存在且极为艰巨的挑战。近期的突破，以大语言模型（LLMs）[1,2]和思维链（CoT）提示[3]为代表，在基础推理任务上取得了相当大的成功。然而，这一成功在很大程度上依赖于大量人工标注的演示，且模型的能力对于更复杂的问题仍然不足。在此我们表明，大语言模型的推理能力可以通过纯强化学习（RL）来激励，从而无需人工标注的推理轨迹。所提出的强化学习框架促进了高级推理模式的涌现式发展，例如自我反思、验证和动态策略适应。因此，训练后的模型在数学、编程竞赛和STEM领域等可验证任务上取得了优于通过传统监督学习在人工演示上训练的同类模型的性能。此外，这些大规模模型所展现的涌现推理模式可以被系统地用于指导和增强较小模型的推理能力。

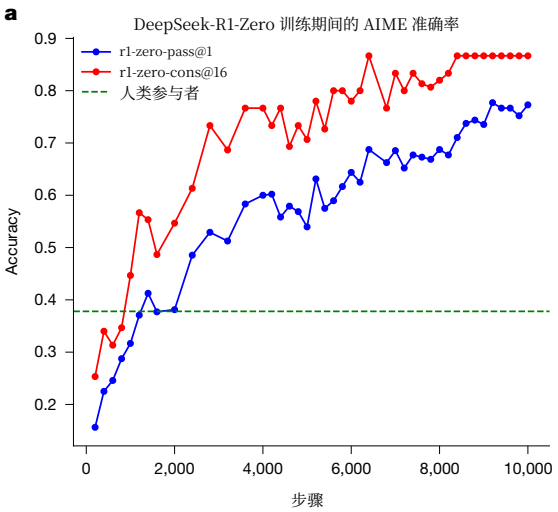
推理能力作为人类智能的基石，使人能够完成从数学问题求解到逻辑推演与编程等复杂的认知任务。近期人工智能的进展表明，当LLMs扩展到足够规模时，可以展现出涌现行为，包括推理能力[4,5]。然而，在预训练阶段获得此类能力通常需要大量计算资源。与此同时，另一条互补的研究路线表明，LLMs可以通过CoT提示得到有效增强。该技术既可以提供精心设计的少样本示例，也可以使用诸如“让我们一步一步思考”这类极简提示[3,6]，使模型生成中间推理步骤，从而显著提升其在复杂任务上的表现。类似地，当模型在后训练阶段学习高质量的多步推理轨迹时，也观察到了进一步的性能提升[2,7]。尽管这些方法有效，但它们存在明显的局限。它们依赖人工标注的推理轨迹，这拖慢了可扩展性并引入认知偏差。此外，通过约束模型去复现人类思维过程，其性能本质上受限于人类提供的示例，从而阻碍了对更优、非人类式推理路径的探索。

为解决这些问题，我们旨在探索LLMs通过在RL框架中自我进化来发展推理能力的潜力，且尽可能减少对人类标注工作的依赖。具体而言，我们基于DeepSeek-V3 Base[8]并使用组相对策略优化（GRPO）[9]作为我们的RL框架。奖励信号仅基于最终预测与真实答案的正确性，而不对推理过程本身施加约束。值得注意的是，我们在RL训练之前绕过了传统的监督微调（SFT）阶段。这一设计选择源于我们的假设：人类定义的推理模式可能会限制模型探索，而无限制的RL训练则能更好地激励LLMs中新推理能力的涌现。通过这一过程（详见下一节），我们的模型（称为DeepSeek-R1-Zero）自然地发展出了多样且复杂的推理行为。为解决推理问题，模型表现出生成更长回答的倾向，在每次回答中纳入验证、反思以及对替代方法的探索。尽管我们没有明确教模型如何推理，它通过RL成功学会了改进的推理策略。

尽管 DeepSeek-R1-Zero 展现出卓越的推理能力，但它面临可读性差和语言混杂等挑战，偶尔在单个 CoT 回复中混合使用英文和中文。此外，DeepSeek-R1-Zero 基于规则的 RL 训练阶段仅狭窄地聚焦于推理任务，导致在写作和开放域问答等更广泛领域的性能有限。为应对这些挑战，我们提出了 DeepSeek-R1，一个通过多阶段学习框架训练的模型，该框架集成了拒绝采样、RL 和监督微调，详见“DeepSeek-R1”章节。这一训练流程使 DeepSeek-R1 能够继承其前身 DeepSeek-R1-Zero 的推理能力，同时通过进一步的非推理数据使模型行为与人类偏好对齐。

为了让更多人能以更低的能耗获得强大的AI，我们蒸馏了多个更小的模型并已将其公开。这些蒸馏模型展现出强大的推理能力，超越了其原始指令微调对应模型的性能。我们相信，这些指令微调版本也将为研究界做出重大贡献，为理解长CoT推理模型的底层机制提供宝贵资源，并推动更强大推理模型的发展。我们按照“代码可用性”部分所述，向公众发布了DeepSeek-R1-Zero、DeepSeek-R1、数据样本和蒸馏模型。

作者列表及其单位信息见文末



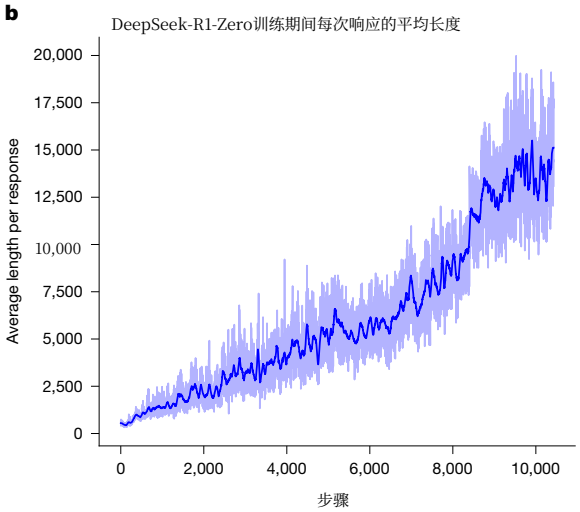


图1 | DeepSeek-R1-Zero在训练过程中的准确率和输出长度。 **a**, DeepSeek-R1-Zero在训练期间的AIME准确率。AIME以数学问题为输入，以数字为输出，如扩展数据表1所示。pass@1和cons@16在补充信息第4.1节中描述。基线是人类在AIME竞赛中取得的平均分数。**b**, DeepSeek-R1-Zero在RL过程中在训练集上的平均响应长度。DeepSeek-R1-Zero自然地学会用更多的思考时间来解决推理任务。注意，一个训练步骤指的是单次策略更新操作。

DeepSeek-R1-Zero

为了实现DeepSeek-R1-Zero的大规模强化学习，我们使用了高效的强化学习流水线。具体而言，我们使用GRPO[9]作为我们的强化学习算法，详见方法部分“GRPO”。此外，我们使用基于规则的奖励系统来计算准确性和格式奖励，详细方法见方法部分“奖励设计”。此外，我们的高性能强化学习基础设施见补充信息第2.1节，确保可扩展且高效的训练。

具体而言，我们在DeepSeek-V3 Base上应用强化学习技术来训练DeepSeek-R1-Zero。在训练过程中，我们设计了一个简单的模板，要求DeepSeek-R1-Zero首先生成推理过程，然后给出最终答案。提示模板如下所示。

“用户与助手之间的对话。用户提出一个问题，助手解决它。助手首先在脑海中思考推理过程，然后向用户提供答案。推理过程和答案分别被包含在<think>...</think>and <answer>...</answer> tags中，即<think> reasoning在此处放置过程</think><answer> answer在此处放置</answer>.用户：提示。助手：”，在训练中将提示替换为具体的推理问题。我们有意将约束限制在这种结构格式上，避免任何内容特定的偏差，以确保我们能够准确观察模型在强化学习过程中的自然进展。

图**1a**展示了DeepSeek-R1-Zero在美国数学邀请赛（AIME）2024基准测试中，在整个强化学习训练过程中的性能轨迹。其中，AIME 2024上的平均pass@1得分显著提升，从初始的15.6%跃升至77.9%。此外，通过使用自一致性解码[10]，模型的性能可进一步提升，达到86.7%的准确率。这一表现远超AIME所有人类参赛者的平均成绩。除数学竞赛外，如补充图8所示，DeepSeek-R1-Zero在编程竞赛以及研究生级别的生物、物理和化学问题上也表现出色。这些结果凸显了强化学习在提升大语言模型推理能力方面的有效性。

除了训练过程中推理能力的逐步增强外，DeepSeek-R1-Zero在强化学习训练中还展现出自我进化行为。如图**1b**所示，DeepSeek-R1-Zero在整个训练过程中思考时间稳步增加，这仅由内在适应驱动，而非外部修改。利用长思维链，模型逐步完善其推理过程，生成数百至数千个token以探索和改进其问题解决策略。

思考时间的增加有助于自主发展复杂行为。具体而言，DeepSeek-R1-Zero 日益展现出如反思性推理和对备选解决方案的系统性探索等高级推理策略（见扩展数据图 1a），显著提升了其在数学和编码等可验证任务上的表现。值得注意的是，在训练过程中，DeepSeek-R1-Zero 表现出一个‘顿悟时刻’，见表 **1**，其特征是在反思过程中‘wait’一词的使用突然增加（见扩展数据图 1b）。这一时刻标志着推理模式的明显变化，并清晰展示了 DeepSeek-R1-Zero 的自我演化过程。

DeepSeek-R1-Zero 的自我演化凸显了强化学习的力量与美妙之处：我们并非明确教给模型如何解决问题，而只是为其提供正确的激励，它便自主发展出高级的问题解决策略。这提醒我们，强化学习有潜力释放大语言模型更高层次的能力，为未来更自主、更具适应性的模型铺平道路。

DeepSeek-R1

尽管DeepSeek-R1-Zero展现出强大的推理能力，但它面临若干问题。DeepSeek-R1-Zero在可读性差和语言混杂等方面存在困难，因为DeepSeek-V3 Base是在多种语言上训练的，尤其是英语和中文。为了解决这些问题，我们开发了DeepSeek-R1，其流程如图**2**所示。在初始阶段，我们收集了数千条冷启动数据，这些数据展现出对话式、符合人类对齐的思维过程，详见补充信息第2.3.2节。随后应用RL训练，超参数见方法部分“第一RL阶段的训练细节”，数据细节见补充信息第2.3.1节，以提升模型在

表 1 | 一个有趣的“顿悟时刻”，来自中间版本的 DeepSeek-R1-Zero

问题：如果 *a*>1，那么 *a* 的实数解之和为 $\sqrt{a-\sqrt{a+x}}=x$ 等于
响应：<think> 为了求解方程 $\sqrt{a-\sqrt{a+x}}=x$，让我们先对两边进行平方…… $\sqrt{a-\sqrt{a+x}}^2=x^2 \Rightarrow a-\sqrt{a+x}=x^2$. 重新排列以分离内层平方根项： $a-x^2=\sqrt{a+x} \Rightarrow (a-x^2)^2=a+x \Rightarrow a^2-2ax^2+x^4=a+x \Rightarrow x^4-2ax^2-x+(a^2-a)=0$ ( ) ( ) ... **等等，等等。等等。这是一个我可以在这里标记的顿悟时刻。** 让我们逐步重新评估这一步，以确定正确的和是否可能为…… 我们从以下方程开始： $\sqrt{a-\sqrt{a+x}}=x$ 首先，让我们对两边进行平方： $a-\sqrt{a+x}=x^2 \Rightarrow \sqrt{a+x}=a-x^2$ 接下来，我可以再次对两边进行平方，处理该方程：…… ...
该模型学会了用拟人化的语气重新思考。这也是一个顿悟时刻，对于我们，让我们得以见证强化学习的力量与美妙。

对话式思维过程和语言一致性方面的性能。随后，我们再次应用拒绝采样和SFT。此阶段将推理和非推理数据集都纳入SFT过程，详见补充信息第2.3.3节，使模型不仅在推理任务上表现出色，还能展现高级写作能力。为了进一步使模型与人类偏好对齐，我们实施了第二RL阶段，旨在增强模型的有用性和无害性，同时改进其推理能力。奖励模型见方法部分“奖励设计”，RL超参数见方法部分“第二RL阶段的训练细节”。总训练成本列于补充信息第2.4.4节。

我们在 MMLU[11], MMLU-Redux[12], MMLU-Pro[13], DROP[14], C-Eval[15], IFEval[16], FRAMES[17], GPQA Diamond[18], SimpleQA[19], C-SimpleQA[20], CLUEWSC[21], AlpacaEval 2.0（参考文献 **22**）、Arena-Hard[23], SWE-bench Verified[24], Aider-Polyglot[25], LiveCodeBench[26]（2024-08– 2025-01）、Codeforces[27], 中国全国高中数学奥林匹克竞赛（CNMO 2024）[28] 和 AIME 2024（参考文献 **29**）。这些基准测试的详细信息见补充表 15–29。

表 **2** 总结了 DeepSeek-R1 在多个开发阶段的性能，如图 **2** 所示。DeepSeek-R1-Zero 与 DeepSeek-R1 Dev1 的对比显示，指令遵循能力有显著提升，这体现在 IF-Eval 和 Arena-Hard 基准测试得分更高上。然而，由于冷启动数据集规模有限，与 DeepSeek-R1-Zero 相比，Dev1 在推理性能上出现了部分退化，在 AIME 基准测试上尤为明显。相比之下，DeepSeek-R1 Dev2 在需要高级推理技能的基准测试上表现出显著性能提升，包括代码生成、数学问题求解和 STEM 相关任务。面向通用任务的基准测试，如 Alpac-aEval 2.0，仅显示出 marginal improvement。这些结果表明，面向推理的强化学习大幅增强了推理能力，而对面向用户偏好的基准测试影响有限。

DeepSeek-R1 Dev3 将推理数据集和非推理数据集整合到 SFT 流程中，从而增强了模型在推理和通用语言生成任务上的能力。与 Dev2 相比，DeepSeek-R1 Dev3 在 AlpacaEval 2.0 和 Aider-Polyglot 上取得了显著的性能提升，这归因于引入了大规模非推理语料库和代码工程数据集。最后，使用混合的推理导向和通用数据对 DeepSeek-R1 Dev3 进行全面的 RL 训练，产生了最终的 DeepSeek-R1。在代码和数学基准测试中出现了边际改进，因为在之前的阶段已经进行了大量针对推理的 RL。最终 DeepSeek-R1 的主要进步在于通用指令遵循和用户偏好基准测试，其中 AlpacaEval 2.0 提升了 25%，Arena-Hard 提升了 17%。

我们还在补充信息第4.2节中将DeepSeek-R1与其他模型进行了比较。模型安全性评估见补充信息第4.3节。评估的全面分析见补充信息第5节，包括与DeepSeek-V3的比较、在两个全新测试集上的性能评估、按类别划分的数学能力分析以及测试时扩展行为的研究。补充信息第6节表明，强大的推理能力可以迁移到更小的模型上。

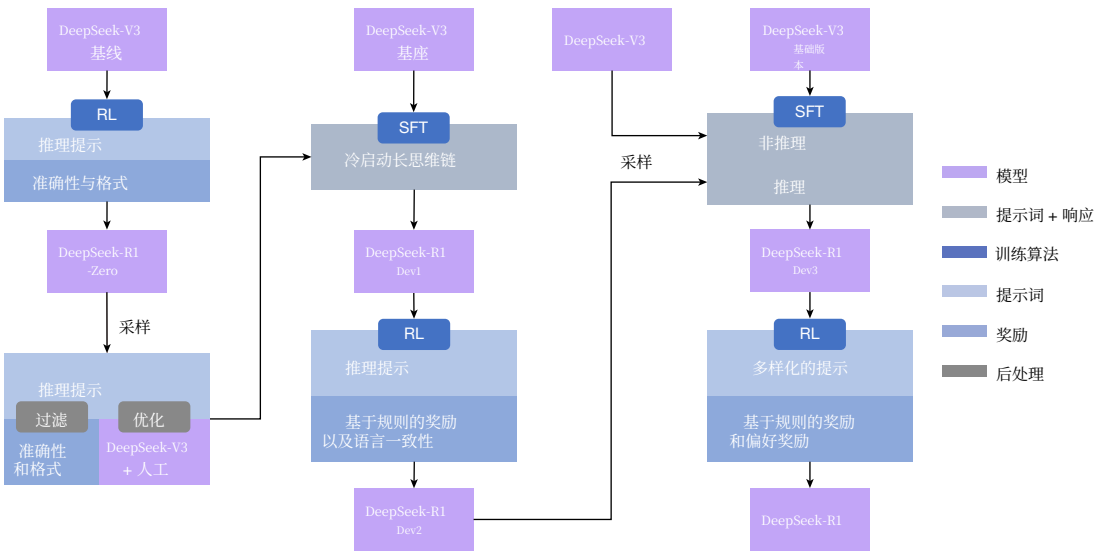


图 2 | DeepSeek-R1 的多阶段流程。有关 DeepSeek-V3 Base 和 DeepSeek-V3 的详细背景见补充信息第 1.1 节。模型 DeepSeek-R1 Dev1、Dev2 和 Dev3 表示该流程中的中间检查点。

表 2 | DeepSeek-R1 各阶段的实验结果

	基准测试（指标）	R1-Zero	R1 Dev1	R1 Dev2	R1 Dev3	R1
英语	MMLU (EM)	88.8	89.1	**91.2**	91.0	90.8
	MMLU-Redux (EM)	85.6	90.0	93.0	93.1	92.9
	MMLU-Pro (EM)	68.9	74.1	83.8	83.1	**84.0**
	DROP (3-shot F1)	89.1	89.8	91.1	88.7	**92.2**
	IF-Eval（提示严格）	46.6	71.7	72.0	78.1	**83.3**
	GPQA Diamond（Pass@1）	**75.8**	66.1	70.7	71.2	71.5
	SimpleQA（正确）	30.3	17.8	28.2	24.9	30.1
	FRAMES（准确率）	82.3	78.5	81.8	81.9	**82.5**
	AlpacaEval 2.0（LC胜率）	24.7	50.1	55.8	62.1	**87.6**
	Arena-Hard（GPT-4-1106）	53.6	77.0	73.2	75.6	**92.3**
代码	LiveCodeBench（Pass@1-COT）	50.0	57.5	63.5	64.6	**65.9**
	Codeforces（百分位）	80.4	84.5	90.5	92.1	**96.3**
	Codeforces（评分）	1,444	1,534	1,687	1,746	**2,029**
	SWE-bench Verified（已解决）	43.2	39.6	44.6	45.6	**49.2**
	Aider-Polyglot（准确率）	12.2	6.7	25.6	44.8	**53.3**
数学	AIME 2024（Pass@1）	77.9	59.0	74.0	78.1	**79.8**
	MATH-500（Pass@1）	95.9	94.2	95.9	95.4	**97.3**
	CNMO 2024（Pass@1）	**88.1**	58.0	73.9	77.3	78.8
中文	CLUEWSC（EM）	93.1	92.8	92.6	91.6	92.8
	C-Eval（EM）	**92.8**	85.7	91.9	86.4	91.8
	C-SimpleQA（正确）	66.4	58.8	64.2	66.9	63.7

粗体数字表示性能具有统计显著性（*t*检验，$P < 0.01$）。

伦理与安全声明

随着DeepSeek-R1推理能力的进步，我们深刻认识到潜在的伦理风险。例如，R1可能遭受越狱攻击，导致生成危险内容，如爆炸物制造方案，而增强的推理能力使模型能够提供具有更好操作可行性和可执行性的方案。此外，公开模型也容易受到进一步微调的影响，这可能破坏固有的安全保护。

在补充信息第4.3节中，我们从多个角度呈现了一份全面的安全报告，包括在开源及内部安全评估基准上的表现，以及跨多种语言和抵御越狱攻击的安全水平。这些全面的安全分析得出结论：与其他最先进模型相比，DeepSeek-R1模型的固有安全水平总体处于中等水平（与GPT-4o (2024-05-13)相当）[30]。此外，当与风险控制系统结合时，该模型的安全水平提升至更优标准。

结论、局限性与未来工作

我们提出了DeepSeek-R1-Zero和DeepSeek-R1，它们依靠大规模强化学习来激励模型的推理行为。我们的结果表明，预训练检查点本身在复杂推理任务上具有巨大潜力。我们相信，释放这一潜力的关键不在于大规模人工标注，而在于提供困难的推理问题、一个可靠的验证器以及足够的强化学习计算资源。诸如自我验证和反思等复杂的推理行为，似乎在强化学习过程中自然涌现。

即使 DeepSeek-R1 在推理基准测试中取得了前沿结果，它仍然面临若干能力限制，概述如下。

结构化输出与工具使用

目前，与现有模型相比，DeepSeek-R1 的结构化输出能力仍不够理想。此外，DeepSeek-R1 无法利用搜索引擎、计算器等工具来提升输出性能。然而，由于构建用于结构化输出和工具使用的 RL 环境并不困难，我们相信该问题将在下一个版本中得到解决。

令牌效率

与传统的测试时计算扩展方法（如多数投票或蒙特卡洛树搜索（MCTS））不同，DeepSeek-R1 在推理过程中根据当前问题的复杂度动态分配计算资源。具体而言，它使用较少的令牌来解决简单任务，但为复杂任务生成更多令牌。尽管如此，在令牌效率方面仍有进一步优化的空间，因为在回答较简单问题时，仍可观察到过度推理的实例——表现为过度思考。

语言混合

DeepSeek-R1 目前针对中文和英文进行了优化，这可能导致在处理其他语言的查询时出现语言混合问题。例如，即使查询使用的是英语或中文之外的语言，DeepSeek-R1 也可能使用英语进行推理和回复。我们计划在未来的更新中解决这一限制。该限制可能与基础检查点 DeepSeek-V3 Base 有关，它主要使用中文和英文，因此能够在这两种语言的推理中取得更好的结果。

提示工程

在评估DeepSeek-R1时，我们观察到它对提示敏感。少样本提示会持续降低其性能。因此，我们建议用户直接描述问题并以零样本设置指定输出格式，以获得最佳结果。

软件工程任务

由于评估时间较长，这影响了强化学习过程的效率，大规模强化学习尚未在软件工程任务中广泛应用。因此，DeepSeek-R1在软件工程基准上未表现出相较于DeepSeek-V3的巨大改进。未来版本将通过实施软件工程数据上的拒绝采样或在强化学习过程中引入异步评估来提高效率。

除了特定的能力局限外，纯强化学习方法本身也存在固有挑战：

奖励黑客

纯强化学习的成功依赖于可靠的奖励信号。在本研究中，我们通过推理领域的基于规则的奖励模型来确保奖励的可靠性。然而，对于某些任务（如写作），构建如此可靠的奖励模型十分困难。如果奖励信号由模型而非预定义规则给出，那么随着训练的推进，它更容易被利用，这意味着策略模型可能找到捷径来攻击奖励模型。因此，对于无法通过可靠奖励模型有效评估的复杂任务，扩展纯强化学习方法仍是一个未解决的挑战。

在本工作中，对于无法获得可靠信号的任务，DeepSeek-R1使用人工标注来创建监督数据，并且仅进行数百步的强化学习。我们希望未来能够获得一个稳健的奖励模型来解决此类问题。

随着DeepSeek-R1等纯强化学习方法的出现，未来在解决任何能够被验证器有效评估的任务方面蕴含着巨大潜力，无论这些任务对人类而言多么复杂。配备此类先进强化学习技术的机器有望在这些领域超越人类能力，这得益于其通过试错迭代优化性能的能力。然而，对于本质上难以构建可靠奖励模型的任务，挑战依然存在。在这种情况下，缺乏稳健的反馈机制可能会减缓进展，这表明未来的研究应聚焦于开发创新方法，为这些复杂且较难验证的问题定义并改进奖励结构。

此外，在推理过程中利用工具具有显著的前景。无论是使用编译器或搜索引擎等工具来检索或计算必要信息，还是使用生物或化学试剂等外部工具在现实世界中验证最终结果，这种工具增强推理的整合都能极大提升机器驱动解决方案的范围和准确性。

在线内容

任何方法、附加参考文献、Nature Portfolio报告摘要、源数据、扩展数据、补充信息、致谢、同行评审信息；作者贡献和利益冲突详情；以及数据和代码可用性声明均可在以下网址获取：https://doi.org/10.1038/s41586-025-09422-z。

1. Brown, T. B. 等。语言模型是少样本学习器。载于《神经信息处理系统进展》第*33*卷（编：Larochelle, H. 等）（ACM，2020年）。2. OpenAI 等。GPT-4 技术报告。预印本见 https://doi.org/10.48550/arXiv.2303.08774（2024年）。3. Wei, J. 等。思维链提示引发生成大规模语言模型中的推理。载于《神经信息处理系统进展》第*35*卷（编：Koyejo, S. 等）24824–24837（ACM，2022年）。4. Wei, J. 等。大规模语言模型的涌现能力。载于《机器学习研究汇刊》（编：Kamath, G. 等）（2022年）。5. Kaplan, J. 等。神经语言模型的缩放定律。预印本见https://doi.org/10.48550/arXiv.2001.08361（2020年）。6. Kojima, T., Gu, S. S., Reid, M., Matsuo, Y. & Iwasawa, Y. 大规模语言模型是零样本推理器。载于《神经信息处理系统进展》第*35*卷（编：Oh, A. H. 等）22199–22213（ACM，2022年）。
7. Chung, H. W. 等。缩放指令微调语言模型。J. Mach. Learn. Res. 25, 1–53（2024年）。8. DeepSeek-AI 等。DeepSeek-V3 技术报告。预印本见 https://doi.org/10.48550/arXiv.2412.19437（2025年）。9. Shao, Z. 等。DeepSeekMath：推动开源语言模型数学推理的极限。预印本见 https://doi.org/10.48550/arXiv.2402.03300（2024年）。10. Wang, X. 等。自洽性提升语言模型中的思维链推理。载于第11届国际学习表征会议（ICLR，2023年）。11. Hendrycks, D. 等。测量大规模多任务语言理解。载于第9届国际学习表征会议（ICLR，2021年）。12. Gema, A. P. 等。我们对MMLU的研究完成了吗？载于2025年美洲国家计算语言学协会分会会议论文集：人类语言技术（编：Chiruzzo, L. 等）第1卷（长论文），5069–5096（ACL，2025年）。13. Wang, Y. 等。MMLU-Pro：一个更稳健且更具挑战性的多任务语言理解基准。载于《神经信息处理系统进展》第37卷（编：Globersons, A. 等）95266–95290（ACM，2024年）。14. Dua, D. 等。DROP：需要对段落进行离散推理的阅读理解基准。载于2019年北美计算语言学协会分会会议论文集：人类语言技术第1卷（长论文和短论文）（编：Burstein, J. 等）2368–2378（ACL，2019年）。15. Huang, Y. 等。C-EVAL：基础模型的多层次多学科中文评估套件。载于《神经信息处理系统进展》第36卷（编：Oh, A. 等）62991–63010（ACM，2023年）。16. Zhou, J. 等。大规模语言模型的指令遵循评估。预印本见 https://doi.org/10.48550/arXiv.2311.07911（2023年）。17. Krishna, S. 等。事实、获取与推理：检索增强生成的统一评估。载于2025年美洲国家计算语言学协会分会会议论文集：人类语言技术第1卷（长论文）4745–4759（ACL，2025年）。18. Rein, D. 等。GPQA：一个研究生水平的谷歌防作弊问答基准。预印本见 https://doi.org/10.48550/arXiv.2311.12022（2023年）。19. OpenAI。介绍SimpleQA；https://openai.com/index/introducing-simpleqa/（2024年）。20. He, Y. 等。Chinese SimpleQA：大规模语言模型的中文事实性评估。载于第63届计算语言学协会年会论文集第1卷（长论文），19182–19208（ACL，2025年）。21. Xu, L. 等。CLUE：一个中文语言理解评估基准。载于第28届国际计算语言学会议论文集（编：Scott, D. 等）4762–4772（国际计算语言学委员会，2020年）。22. Dubois, Y., Galambosi, B., Liang, P. & Hashimoto, T. B. 长度控制的AlpacaEval：一种消除自动评估器偏差的简单方法。预印本见 https://doi.org/10.48550/arXiv.2404.04475（2025年）。23. Li, T. 等。从众包数据到高质量基准：Arena-Hard和BenchBuilder流水线。预印本见 https://doi.org/10.48550/arXiv.2406.11939（2024年）。24. OpenAI。介绍SWE-bench验证版；https://openai.com/index/introducing-swe-bench-verified/（2024年）。25. Aider。Aider大语言模型排行榜；https://aider.chat/docs/leaderboards/（2024年）。26. Jain, N. 等。LiveCodeBench：面向代码的大语言模型全面无污染评估。载于第13届国际学习表征会议（ICLR，2024年）。27. Mirzayanov, M. Codeforces；https://codeforces.com/（2025年）。28. 中国数学会（CMS）。中国全国高中数学奥林匹克竞赛；https://www.cms.org.cn/Home/comp/comp/cid/12.html（2024年）。29. 美国数学协会。美国数学邀请赛；https://maa.org/maa-invitational-competitions（2024年）。30. OpenAI。你好GPT-4o；https://openai.com/index/hello-gpt-4o/（2024年）。

出版商说明 Springer Nature对已发表地图中的管辖权主张和机构隶属关系保持中立。

开放获取 本文根据Creative Commons Attribution 4.0 International License许可协议授权，允许以任何媒介或格式使用、共享、改编、分发和复制，只要您给予原作者和来源适当的署名，提供Creative Commons许可协议的链接，并说明是否进行了修改。本文中的图片或其他第三方材料均包含在本文的Creative Commons许可协议中，除非在材料的署名行中另有说明。如果材料未包含在本文的Creative Commons许可协议中，且您的预期使用不被法定法规允许或超出许可使用范围，您需要直接从版权持有人处获得许可。要查看此许可协议的副本，请访问http://creativecommons.org/licenses/by/4.0/。

© 作者 2025

Daya Guo[1], Dejian Yang[1], Haowei Zhang[1], Junxiao Song[1], Peiyi Wang[1], Qihao Zhu[1], Runxin Xu[1], Ruoyu Zhang[1], Shirong Ma[1], Xiao Bi[1], Xiaokang Zhang[1], Xingkai Yu[1], Yu Wu[1], Z. F. Wu[1],Zhibin Gou[1], Zhihong Shao[1], Zhuoshu Li[1], Ziyi Gao[1], Aixin Liu[1], Bing Xue[1], Bingxuan Wang[1],Bochao Wu[1], Bei Feng[1], Chengda Lu[1], Chenggang Zhao[1], Chengqi Deng[1], Chong Ruan[1],Damai Dai[1], Deli Chen[1], Dongjie Ji[1], Erhang Li[1], Fangyun Lin[1], Fucong Dai[1], Fuli Luo[1,2],Guangbo Hao[1], Guanting Chen[1], Guowei Li[1], H. Zhang[1], Hanwei Xu[1], Honghui Ding[1],Huazuo Gao[1], Hui Qu[1], Hui Li[1], Jianzhong Guo[1], Jiashi Li[1], Jingchang Chen[1], Jingyang Yuan[1],Jinhao Tu[1,3], Junjie Qiu[1], Junlong Li[1], J. L. Cai[1], Jiaqi Ni[1], Jian Liang[1], Jin Chen[1], Kai Dong[1],Kai Hu[1,4], Kaichao You[1], Kaige Gao[1], Kang Guan[1], Kexin Huang[1,5], Kuai Yu[1], Lean Wang[1],Lecong Zhang[1], Liang Zhao[1], Litong Wang[1], Liyue Zhang[1], Lei Xu[1], Leyi Xia[1],Mingchuan Zhang[1], Minghua Zhang[1], Minghui Tang[1], Mingxu Zhou[1], Meng Li[1],Miaojun Wang[1], Mingming Li[1], Ning Tian[1], Panpan Huang[1], Peng Zhang[1], Qiancheng Wang[1],Qinyu Chen[1], Qiushi Du[1], Ruiqi Ge[1], Ruisong Zhang[1], Ruizhe Pan[1], Runji Wang[1], R. J. Chen[1],

R. L. Jin[1], Ruyi Chen[1], Shanghao Lu[1], Shangyan Zhou[1], Shanhuang Chen[1], Shengfeng Ye[1], Shiyu Wang[1], Shuiping Yu[1], Shunfeng Zhou[1], Shuting Pan[1], S. S. Li[1], Shuang Zhou[1],Shaoqing Wu[1], Tao Yun[1], Tian Pei[1], Tianyu Sun[1], T. Wang[1], Wangding Zeng[1], Wen Liu[1], Wenfeng Liang[1]✉, Wenjun Gao[1], Wenqin Yu[1,5], Wentao Zhang[1], W. L. Xiao[1], Wei An[1],Xiaodong Liu[1], Xiaohan Wang[1], Xiaokang Chen[1], Xiaotao Nie[1], Xin Cheng[1], Xin Liu[1], Xin Xie[1],Xingchao Liu[1], Xinyu Yang[1], Xinyuan Li[1,5], Xuecheng Su[1], Xuheng Lin[1], X. Q. Li[1], Xiangyue Jin[1],Xiaojin Shen[1], Xiaosha Chen[1], Xiaowen Sun[1], Xiaoxiang Wang[1], Xinnan Song[1], Xinyi Zhou[1],Xianzu Wang[1], Xinxia Shan[1], Y. K. Li[1], Y. Q. Wang[1], Y. X. Wei[1], Yang Zhang[1], Yanhong Xu[1],Yao Li[1], Yao Zhao[1], Yaofeng Sun[1], Yaohui Wang[1], Yi Yu[1], Yichao Zhang[1], Yifan Shi[1],Yiliang Xiong[1], Ying He[1], Yishi Piao[1], Yisong Wang[1], Yixuan Tan[1], Yiyang Ma[1], Yiyuan Liu[1],Yongqiang Guo[1], Yuan Ou[1], Yuduan Wang[1], Yue Gong[1,5], Yuheng Zou[1], Yujia He[1,5],Yunfan Xiong[1], Yuxiang Luo[1], Yuxiang You[1], Yuxuan Liu[1], Yuyang Zhou[1], Y. X. Zhu[1], Yanping Huang[1], Yaohui Li[1], Yi Zheng[1], Yuchen Zhu[1], Yunxian Ma[1], Ying Tang[1], Yukun Zha[1], Yuting Yan[1], Z. Z. Ren[1], Zehui Ren[1], Zhangli Sha[1], Zhe Fu[1], Zhean Xu[1], Zhenda Xie[1],Zhengyan Zhang[1], Zhewen Hao[1], Zhicheng Ma[1], Zhigang Yan[1], Zhiyu Wu[1], Zihui Gu[1], Zijia Zhu[1],Zijun Liu[1,6], Zilin Li[1], Ziwei Xie[1], Ziyang Song[1,7], Zizheng Pan[1], Zhen Huang[1], Zhipeng Xu[1],Zhongyu Zhang[1] & Zhen Zhang[1]

[1]DeepSeek-AI团队，中国杭州。[2]现地址：独立研究员，中国北京。[3]现地址：建平中学，中国上海。[4]现地址：中国科学技术大学，中国合肥。[5]现地址：北京大学，中国北京。[6]现地址：清华大学，中国北京。[7]现地址：Citadel Securities，中国香港特别行政区。✉电子邮箱：wenfeng.liang@deepseek.com

方法

GRPO

GRPO[9]是我们用于训练DeepSeek-R1-Zero和DeepSeek-R1的强化学习算法。它最初被提出是为了简化训练过程并减少近端策略优化（PPO）的资源消耗[31]，，PPO广泛用于大语言模型的强化学习阶段[32]。GRPO的流程如扩展数据图2所示。

对于每个问题 q，GRPO 从旧策略中采样一组输出 $\{o_1, o_2, \ldots, o_G\}$，然后通过最大化以下目标来优化策略模型 π_θ：

$$\mathcal{J}_{\mathrm{GRPO}}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^{G} \sim \pi_{\theta_{\mathrm{old}}}(O|q)]$$
$$\frac{1}{G}\sum_{i=1}^{G}\left(\min\left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\mathrm{old}}}(o_i|q)}A_i,\ \mathrm{clip}\left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\mathrm{old}}}(o_i|q)}, 1-\epsilon, 1+\epsilon\right)A_i\right) - \beta\mathbb{D}_{KL}(\pi_\theta||\pi_{\mathrm{ref}})\right), \quad (1)$$

$$\mathbb{D}_{\mathrm{KL}}(\pi_\theta||\pi_{\mathrm{ref}}) = \frac{\pi_{\mathrm{ref}}(o_i|q)}{\pi_\theta(o_i|q)} - \log\frac{\pi_{\mathrm{ref}}(o_i|q)}{\pi_\theta(o_i|q)} - 1, \quad (2)$$

其中 π_{ref} 是参考策略，ϵ 和 β 是超参数，A_i是优势，使用一组奖励 $\{r_1, r_2, \ldots, r_G\}$ 计算得出，这些奖励对应于每组中的输出：

$$A_i = \frac{r_i - \mathrm{mean}(\{r_1, r_2, \cdots, r_G\})}{\mathrm{std}(\{r_1, r_2, \cdots, r_G\})}. \quad (3)$$

我们在补充信息第 1.3 节中给出了 GRPO 和 PPO 的比较。

奖励设计

奖励是训练信号的来源，它决定了RL优化的方向。对于DeepSeek-R1-Zero，我们使用基于规则的奖励，为数学、编码和逻辑推理领域的数据提供精确的反馈。对于DeepSeek-R1，我们扩展了这种方法，通过结合用于推理导向数据的基于规则的奖励和用于通用数据的基于模型的奖励，从而增强了学习过程在不同领域中的适应性。

基于规则的奖励。 我们的基于规则的奖励系统主要由两种类型的奖励组成：准确性奖励和格式奖励。

准确性奖励评估响应是否正确。例如，在具有确定性结果的数学问题中，模型需要以指定格式（例如，在框中）提供最终答案，从而能够对正确性进行可靠的基于规则的验证。同样，对于代码竞赛提示，可以使用编译器根据一组预定义的测试用例来评估模型的响应，从而生成关于正确性的客观反馈。

格式奖励通过强制特定的格式要求来补充准确性奖励模型。特别是，模型被激励将其推理过程封装在指定的标签内，具体为 <think> and </think>. 这确保了模型的思维过程被明确 delineated，增强了可解释性并促进了后续分析。

$$\mathrm{Reward}_{\mathrm{rule}} = \mathrm{Reward}_{\mathrm{acc}} + \mathrm{Reward}_{\mathrm{format}} \quad (4)$$

准确率、奖励和格式奖励以相同权重进行组合。值得注意的是，我们避免对推理任务应用神经奖励模型——无论是基于结果的还是基于过程的。这一决策基于我们的观察：神经奖励模型在大规模强化学习过程中容易受到奖励攻击。此外，重新训练此类模型需要大量计算资源，并给训练流程引入更多复杂性，从而使整体优化过程更加复杂。

基于模型的奖励。对于通用数据，我们借助奖励模型来捕捉复杂且细微场景中的人类偏好。我们基于DeepSeek-V3的流程构建，并使用类似分布的偏好对和训练提示。在有用性方面，我们仅关注最终摘要，确保评估侧重于响应对用户的使用价值和相关性，同时尽量减少对底层推理过程的干扰。在无害性方面，我们评估模型的完整响应，包括推理过程和摘要，以识别并缓解生成过程中可能出现的任何潜在风险、偏见或有害内容。

有用性奖励模型。对于有用性奖励模型的训练，我们首先使用Arena-Hard提示格式（列于补充信息第2.2节）提示DeepSeek-V3来生成偏好对，其中每一对包含一个用户查询和两个候选响应。对于每个偏好对，我们查询DeepSeek-V3四次，将响应随机分配为响应A或响应B以减轻位置偏差。最终偏好分数由四次独立判断的平均值确定，仅保留分数差（Δ）超过1的配对，以确保有意义的区分。此外，为了最小化长度相关偏差，我们确保整个数据集中被选中和被拒绝的响应长度相当。我们总共整理了66,000个数据对用于训练奖励模型。该数据集中使用的提示均为非推理问题，来源为公开可用的开源数据集或明确同意共享数据以用于模型改进的用户。我们的奖励模型架构与DeepSeek-R1一致，并增加了一个奖励头，用于预测标量偏好分数。

$$\mathrm{Reward}_{\mathrm{helpful}} = \mathrm{RM}_{\mathrm{helpful}}(\mathrm{Response}_A, \mathrm{Response}_B) \quad (5)$$

有用性奖励模型以256的批量大小、6×10^{-6} 的学习率，在训练数据集上训练了一个epoch。训练期间的最大序列长度设置为8,192个token，而奖励模型推理期间没有施加显式限制。

安全奖励模型。 为了评估和改进模型安全性，我们整理了一个包含106,000个提示的数据集，其中模型生成的回复根据预定义的安全准则被标注为“安全”或“不安全”。与有用性奖励模型中使用的成对损失不同，安全奖励模型使用逐点方法进行训练，以区分安全和unsafe 回复。训练超参数与有用性奖励模型相同。

$$\mathrm{Reward}_{\mathrm{safety}} = \mathrm{RM}_{\mathrm{safety}}(\mathrm{Response}) \quad (6)$$

对于一般查询，每个实例被归类为属于安全数据集或有用性数据集。分配给每个查询的一般奖励 $\mathrm{Reward}^{\mathrm{general}}$ 对应于相关数据集中定义的相应奖励。

训练细节

DeepSeek-R1-Zero 的训练细节。 为了训练 DeepSeek-R1-Zero，我们将学习率设为 3×10^{-6}，Kullback–Leibler（KL）系数设为 0.001，采样温度设为 1 用于 rollout。对于每个问题，我们在 8.2k 步之前采样 16 个输出，最大长度为 32,768 个 token，之后为 65,536 个 token。因此，DeepSeek-R1-Zero 的性能和响应长度在 8.2k 步时都出现了显著跃升，训练总共持续 10,400 步，对应 1.6 个训练 epoch。每个训练步包含 32 个不同问题，从而导致每步的训练批次大小为 512。每 400 步，我们将参考模型替换为

最新的策略模型。为了加速训练，每次 rollout 生成 8,192 个输出，这些输出被随机分成 16 个 minibatch，并且仅训练一个内部 epoch。

首个RL阶段的训练细节。在RL的第一阶段，我们将学习率设为3×10^{-6}，KL系数设为0.001，GRPO裁剪ratioϵto设为10，并将rollout的采样温度设为1。对于每个问题，我们采样16个输出，最大长度为32,768。每个训练步包含32个不同的问题，因此每步的训练批量大小为512。每400步，我们将参考模型替换为最新的策略模型。为加速训练，每次rollout生成8,192个输出，这些输出被随机分为16个小批量，并且仅训练一个内部epoch。然而，为缓解语言混合问题，我们在RL训练期间引入了语言一致性奖励，该奖励计算为CoT中目标语言词汇的比例。

$$\text{Reward}_{\text{language}} = \frac{\text{Num}(\text{Words}_{\text{target}})}{\text{Num}(\text{Words})} \tag{7}$$

尽管补充信息第2.6节中的消融实验表明，这种对齐会导致模型性能略有下降，但该奖励与人类偏好一致，使其更具可读性。我们通过直接将语言一致性奖励添加到最终奖励中，将其应用于推理和非推理数据。

注意，裁剪比例在训练中起着至关重要的作用。较低的值可能导致大量token的梯度被截断，从而降低模型的性能，而较高的值则可能导致训练过程中的不稳定性。此阶段所用强化学习数据的详细信息见补充信息第2.3节。

第二个强化学习阶段的训练细节。具体而言，我们使用奖励信号和多样化提示分布的组 合来训练模型。对于推理数据，我们遵循DeepSeek-R1-Zero中概述的方法，该方法使用基于规则的奖励来指导数学、编码和逻辑推理领域的学习。在训练过程中，我们观察到CoT经常表现出语言混合，尤其是当强化学习提示涉及多种语言时。对于通用数据，我们使用奖励模型来指导训练。最终，奖励信号与多样化数据分布的整合使我们能够开发出一个不仅在推理方面表现出色，而且优先考虑有用性和无害性的模型。给定一批数据，奖励可以表述为

$$\text{Reward} = \text{Reward}_{\text{reasoning}} + \text{Reward}_{\text{general}} + \text{Reward}_{\text{language}} \tag{8}$$

其中

$$\text{Reward}_{\text{reasoning}} = \text{Reward}_{\text{rule}} \tag{9}$$

$$\text{Reward}_{\text{general}} = \text{Reward}_{\text{reward_model}} + \text{Reward}_{\text{format}} \tag{10}$$

强化学习的第二阶段保留了第一阶段的大部分参数，关键区别在于温度降低至0.7，因为我们发现在此阶段使用更高的温度会导致生成不连贯。该阶段总共包含1,700个训练步骤，其中通用指令数据和基于偏好的奖励仅在最后400个步骤中引入。我们发现，更多使用基于模型的偏好奖励信号进行训练步骤可能导致奖励黑客行为，这在补充信息第2.5节中有记录。

数据可用性

我们在以下地址提供了用于拒绝采样和强化学习提示的数据样本：**https://github.com/deepseek-ai/DeepSeek-R1**（**https://doi.org/10.5281/zenodo.15753193**）[33]。完整的统计数据以及我们完整数据生成方法的详细信息见补充信息第2.3节。

代码可用性

DeepSeek-R1-Zero和DeepSeek-R1的训练权重以MIT许可协议提供，地址为**https://github.com/deepseek-ai/DeepSeek-R1**（**https://doi.org/10.5281/zenodo.15753193**）[33]。推理脚本发布于**https://github.com/deepseek-ai/DeepSeek-V3**（**https://doi.org/10.5281/zenodo.15753347**）[34]。神经网络使用PyTorch开发[35]，分布式框架基于我们的内部框架HAI-LLM（**https://www.high-flyer.cn/en/blog/hai-llm**）。推理框架基于vLLM[36]。数据分析使用了Python v.3.8（**https://www.python.org/**）、NumPy v.1.23.1（**https://github.com/numpy/numpy**）、Matplotlib v.3.5.2（**https://github.com/matplotlib/matplotlib**）和TensorBoard v.2.9.1（**https://github.com/tensorflow/tensorboard**）。

31. Schulman, J., Wolski, F., Dhariwal, P., Radford, A. & Klimov, O. 近端策略优化算法。预印本见 https://doi.org/10.48550/arXiv.1707.06347 (2017)。32. Ouyang, L. 等。通过人类反馈训练语言模型遵循指令。载于《神经信息处理系统进展》第*35*卷 (Koyejo, S. 等编) 27730–27744 (ACM, 2022)。33. Nano 等。deepseek-ai/DeepSeek-R1: v1.0.0。*Zenodo* https://doi.org/10.5281/zenodo.15753192 (2025)。34. Yu, X. 等。deepseek-ai/DeepSeek-V3: v1.0.0。*Zenodo* https://doi.org/10.5281/zenodo.15753346 (2025)。35. Paszke, A. 等。PyTorch：一种命令式风格的高性能深度学习库。载于《神经信息处理系统进展》第*32*卷 (Wallach, H. M. 等编) 8026–8037 (ACM, 2019)。36. Kwon, W. 等。使用PagedAttention实现大语言模型服务的高效内存管理。载于*ACM SIGOPS*第*29*届操作系统原理研讨会论文集611–626 (ACM, 2023)。

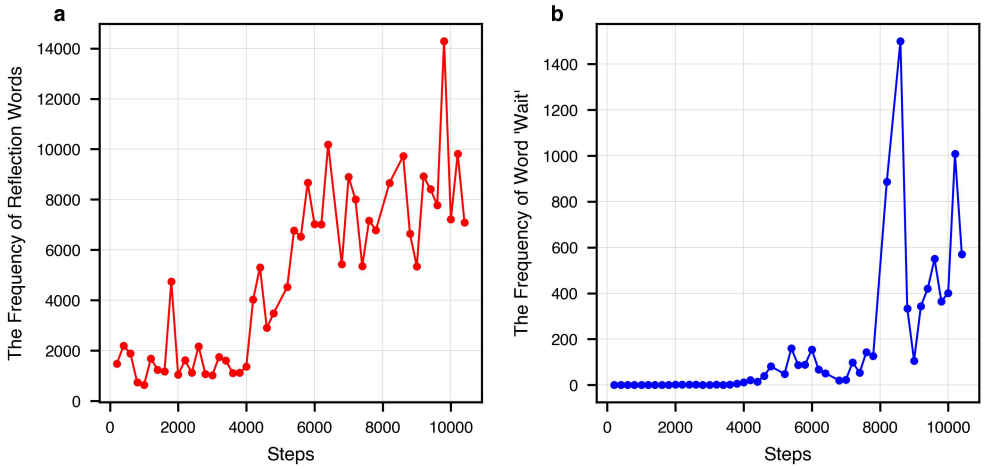
致谢本研究由DeepSeek-AI支持。

作者贡献所有作者均对本出版物有所贡献，分别参与了数据收集与整理、实验设计及大语言模型训练框架的构建。作者们还参与了实验装置的实现与测试、强化学习过程的优化以及结果分析。科学发现经全体贡献者讨论并认可。本文由合作团队指定的作者小组撰写，并经过了内部集体评审流程。所有作者均审阅并批准了稿件的最终版本。核心贡献者：D.G.、D.Y.、H.Z.、J.S.、R.Z.、R.X.、Q.Z.、S.M.、P.W.、X.B.、X.Z.、X.Y.、Y.W.、Z.F.W.、Z.G.、Z.S.、Z.L.、Z.G.。这些被指定为核心贡献者的作者对本工作贡献均等，按姓氏字母顺序排列。其余作者亦对本研究作出了重要贡献，其姓名同样按字母顺序排列。

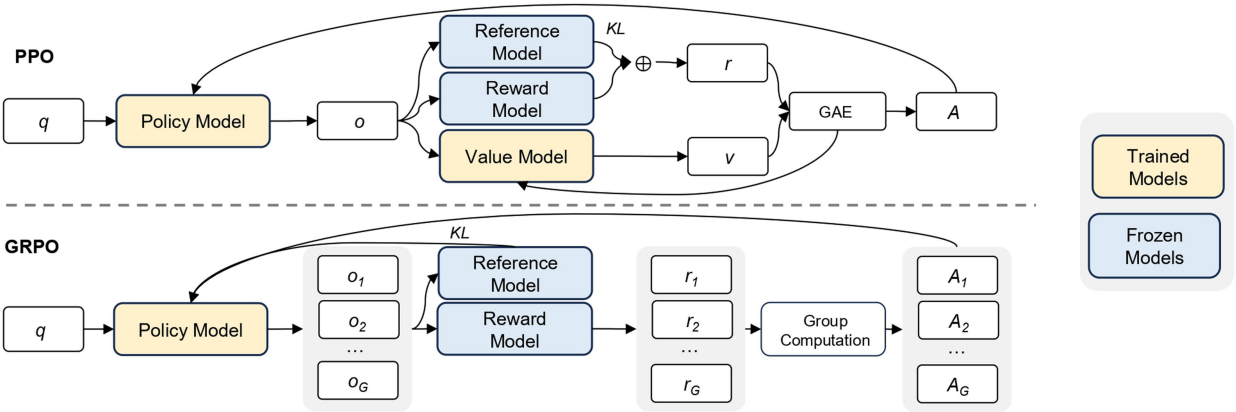
利益冲突声明作者声明无利益冲突，且不会就本手稿内容申请专利。

附加信息
补充信息在线版本包含补充材料，可访问https://doi.org/10.1038/s41586-025-09422-z。

通讯与材料索取请联系Wenfeng Liang。**同行评审信息** *Nature*感谢Edward Beeching、Yarin Gal、José Hernández-Orallo、Daphne Ippolito、Subbarao Kambhampati、Lewis Tunstall、Yiming Zhang和Lexin Zhou对本工作同行评审的贡献。同行评审报告可获取。**转载与许可信息**可访问http://www.nature.com/reprints。



扩展数据图 1 | 模型输出中与推理相关的语言特征在训练步骤中的演变。 **a**，模型生成输出中代表性反思性词汇在整个训练过程中的出现频率。反思性词汇——包括“wait”、“mistake”、“however”、“but”、“retry”、“error”、“verify”、“wrong”、“evaluate”和“check”——由三名人类专家组成的小组进行识别和整理。每位专家独立提出一组指示反思性推理的词汇，随后这些词汇通过共识整合为最终词汇列表。 **b**，模型输出中“wait”一词在训练过程中的出现频率。该词在初始训练阶段几乎不存在，在第4,000步至7,000步之间零星出现，并在第8,000步之后出现频率显著增加。这些趋势表明，随着训练的推进，时间推理或自我监控行为逐渐涌现。



扩展数据图 2| 所提出的用于基于强化学习的GRPO的图示

训练。在所提出的框架中，LLM被用作策略模型，以在给定查询q的条件下生成响应$\{o_1, o_2, \ldots, o_G\}$。组内的每个响应由奖励模型——无论是学习得到的（基于模型）还是手动指定的（基于规则）——进行评估，以分配标量奖励信号。随后，GRPO根据分配的奖励计算每个组成员的相对优势。与PPO中依赖显式价值函数不同，GRPO直接从组内奖励分布估计优势。然后更新策略参数，以最大化期望奖励，同时最小化与参考策略的散度，通常通过KL散度来量化。通过消除对单独价值网络的需求，GRPO为传统演员-评论家方法（如PPO）提供了一种简化而有效的替代方案。

扩展数据表 1 | 来自AIME数据集的一个示例

PROMPT

Let $b \geq 2$ be an integer. Call a positive integer n b-*eautiful* if it has exactly two digits when expressed in base b, and these two digits sum to $\sqrt{n}$. For example, 81 is 13-eautiful because $81 = \underline{6}\ \underline{3}_{13}$ and $6 + 3 = \sqrt{81}$. Find the least integer $b \geq 2$ for which there are more than ten b-eautiful integers.

Please reason step by step, and put your final answer within \boxed{}.

Evaluation

Parse the final answer within \boxed{} and use a rule-based grader to determine if it equals the ground truth. Round numerical values as needed, and use 'SymPy' to parse expressions.

所呈现的问题源自2024年AIME。模型的任务是解决该问题并按照要求的格式（例如，ANSWER）格式化其答案。在评估时，使用基于规则的评分系统来确定正确性。当且仅当模型的输出与真实解决方案完全匹配时，该输出才被视为正确。