文章

使用深度强化学习的冠军级无人机竞速

https://doi.org/10.1038/s41586-023-06419-4

收稿日期：2023年1月5日

接受日期：2023年7月10日

在线发布日期：2023年8月30日

开放获取

检查更新

Elia Kaufmann[1]✉、Leonard Bauersfeld[1]、Antonio Loquercio[1]、Matthias Müller[2]、Vladlen Koltun[3]与Davide Scaramuzza[1]

第一人称视角（FPV）无人机竞速是一项电视转播的体育运动，职业选手操控高速飞行器穿越三维赛道。每位飞行员通过机载摄像头传输的视频流，从自己无人机的视角观察环境。要让自主无人机达到职业飞行员的水平极具挑战性，因为机器人需要在物理极限下飞行，同时仅依靠机载传感器估计自身在赛道中的速度和位置[1]。在此，我们介绍Swift，一种能够以人类世界冠军水平驾驭实体飞行器竞速的自主系统。该系统将仿真中的深度强化学习（RL）与在物理世界中采集的数据相结合。Swift在真实世界的正面对决比赛中与三位人类冠军同场竞技，其中包括两个国际联赛的世界冠军。Swift在与每位人类冠军的多次比赛中均赢得数场，并展现出有记录以来的最快比赛时间。这项工作代表了移动机器人与机器智能的一个里程碑[2]，，或将启发基于混合学习的解决方案在其他物理系统中的部署。

深度强化学习[3]已经推动了人工智能领域的一些最新进展。通过深度强化学习训练的策略在复杂的竞争性游戏中已经超越了人类，包括Atari[4–6]、围棋[5,7–9]、国际象棋[5,9]、星际争霸[10]、Dota 2（参考文献11）和Gran Turismo[12,13]。这些对机器智能能力的令人印象深刻的展示主要局限于仿真和棋盘游戏环境，这些环境支持在与测试条件完全相同的副本中进行策略搜索。克服这一局限性并在物理竞赛中展示冠军级性能，是自主移动机器人和人工智能领域一个长期存在的问题[14–16]。

FPV无人机竞速是一项电视转播的体育运动，训练有素的人类飞行员在高速敏捷机动中将飞行器推向物理极限（图1a）。FPV竞速中使用的飞行器是四旋翼飞行器，它们是有史以来建造的最敏捷的机器之一（图1b）。在比赛期间，这些飞行器施加的力超过其自身重量的五倍或更多，速度超过100 km h^{-1}，加速度达到重力的数倍，即使在受限空间中也是如此。每架飞行器由一名人类飞行员远程控制，该飞行员佩戴显示来自机载摄像头视频流的头戴式设备，从而营造出身临其境的“第一人称视角”体验（图1c）。

创建达到人类飞行员性能的自主系统的尝试可以追溯到2016年首届自主无人机竞速比赛（参考文献17）。随后出现了一系列创新，包括使用深度网络来识别下一个门的位置[18–20]、将竞速策略从仿真迁移到现实[21,22]以及考虑感知中的不确定性[23,24]。2019年AlphaPilot自主无人机竞速比赛展示了该领域一些最优秀的研究[25]。然而，前两支队伍完成赛道所需的时间仍几乎是专业人类飞行员的两倍[26,27]。最近，自主系统已开始达到专家级人类性能[28–30]。然而，这些工作依赖于近乎完美的状态估计，该估计由外部动作捕捉系统提供。这使得与人类飞行员的比较不公平，因为人类只能获取无人机上的机载观测。

在本文中，我们介绍了Swift，这是一个自主系统，仅使用机载传感器和计算即可让四旋翼以人类世界冠军的水平进行竞速。Swift由两个关键模块组成：(1)一个感知系统，将高维视觉和惯性信息转换为低维表示；(2)一个控制策略，接收感知系统产生的低维表示并生成控制指令。

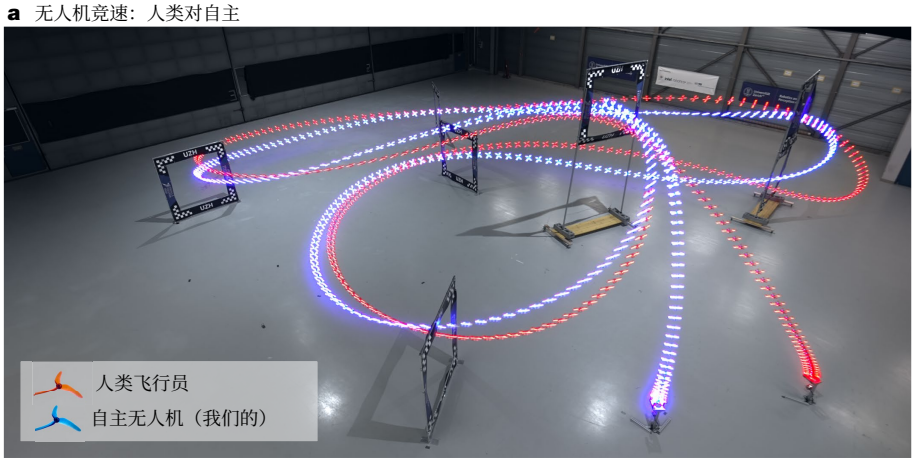
该控制策略由前馈神经网络表示，并在仿真中使用无模型同策略深度强化学习进行训练[31]。为了弥合仿真与物理世界之间在感知和动力学方面的差异，我们利用了从物理系统上采集的数据估计得到的非参数经验噪声模型。这些经验噪声模型已被证明对于将控制策略从仿真成功迁移到现实至关重要。

我们在一条由专业无人机竞速飞行员设计的实体赛道上评估了Swift（图1a）。该赛道包含七扇方形门，分布在30 × 30 × 8 m的体积内，构成一圈长度为75 m的赛道。Swift在这条赛道上与三位人类冠军进行了竞速：Alex Vanover，2019年无人机竞速联盟世界冠军；Thomas Bitmatta，两届MultiGP国际公开世界杯冠军；以及Marvin Schaepper，三届瑞士全国冠军。Swift和人类飞行员使用的四旋翼具有相同的重量、形状和推进系统。它们类似于国际比赛中使用的无人机。

人类飞行员在赛道上进行了一周的练习。经过这一周的练习，每位飞行员都与Swift进行了数场正面对决比赛（图1a,b）。在每场正面对决比赛中，两架无人机

[1]苏黎世大学机器人与感知组，瑞士苏黎世。[2]英特尔实验室，德国慕尼黑。[3]英特尔实验室，Jackson，怀俄明州，美国。✉电子邮箱：ekaufmann@ifi.uzh.ch

a 无人机竞速：人类对自主



b 正面交锋



c 人类冠军



图1|无人机竞速。 **a**，Swift（蓝色）与Alex Vanover，2019年无人机竞速联盟世界冠军（红色），进行正面交锋。赛道包含七个方形门，每圈必须按顺序通过。要赢得比赛，竞争者必须比对手先完成连续三圈。**b**，Swift的近距离视图，用蓝色LED灯照亮，以及一架人类驾驶无人机，用红色LED灯照亮。本工作中使用的自主无人机依赖仅依赖机载传感器测量，无需外部基础设施（如动作捕捉系统）的支持。**c**，从左到右：Thomas Bitmatta、Marvin Schaepper 和 Alex Vanover 驾驶无人机穿越赛道。每位飞手佩戴头戴式设备，该设备实时显示从其飞行器上摄像头传输的视频流。头戴式设备提供沉浸式“第一人称视角”体验。**c**，摄影：Regina Sablotny。

（一架由人类飞行员控制，一架由Swift控制）从起飞台出发。比赛由声音信号启动。第一辆完成赛道三整圈、每圈按正确顺序通过所有门的飞行器赢得比赛。

Swift在与每位人类飞行员的多次比赛中均获胜，并创造了赛事期间记录的最快比赛时间。据我们所知，我们的工作首次实现了自主移动机器人在真实世界竞技体育中达到世界冠军级表现。

Swift系统

Swift结合了基于学习的方法和传统算法，将机载传感读数映射为控制指令。这一映射包含两部分：(1) 观测策略，将高维视觉与惯性信息提炼为任务特定的低维编码；(2) 控制策略，将编码转换为无人机的控制指令。系统的示意图概览如图**2**所示。

观测策略包含一个视觉惯性估计器[32,33]，它与门检测器协同运行[26]，，门检测器是一个卷积神经网络，用于在机载图像中检测竞速门。检测到的竞速门随后用于估计无人机沿赛道的全局位置和朝向。这是通过相机重定位算法[34]结合赛道地图来完成的。然后，通过卡尔曼滤波器将门检测器获得的全局位姿估计与视觉惯性估计器的估计相结合，从而得到更精确的表示机器人状态。控制策略由两层感知机表示，将卡尔曼滤波器的输出映射为飞行器的控制指令。该策略在仿真中使用同策略无模型深度强化学习进行训练[31]。训练期间，策略最大化一个奖励，该奖励结合了向下一个竞速门前进的进度[35]与一个感知目标，后者奖励将下一个门保持在摄像头视场中。看到下一个门之所以受到奖励，是因为这提高了位姿估计的准确性。

若未缓解仿真与现实之间的差异，纯粹在仿真中优化策略会导致在物理硬件上的性能不佳。这些差异主要由两个因素造成：(1) 仿真动力学与真实动力学之间的差异；(2) 观测策略在获得真实传感数据时对机器人状态的有噪估计。我们通过在真实世界中收集少量数据，并利用这些数据提高仿真器的逼真度，从而缓解这些差异。

具体而言，当无人机在赛道上竞速时，我们记录机器人的机载感官观测，以及来自动作捕捉系统的高精度位姿估计。在此数据采集阶段，机器人由在仿真中训练的、基于动作捕捉系统提供的位姿估计运行的策略控制。所记录的数据能够识别出赛道上观测到的感知与动力学的特征性失效模式。这些感知失效和未建模动力学的复杂性取决于环境、平台、赛道和传感器。感知残差和动力学残差分别使用高斯过程[36]和k近邻回归进行建模。这一选择的动机在于我们根据经验

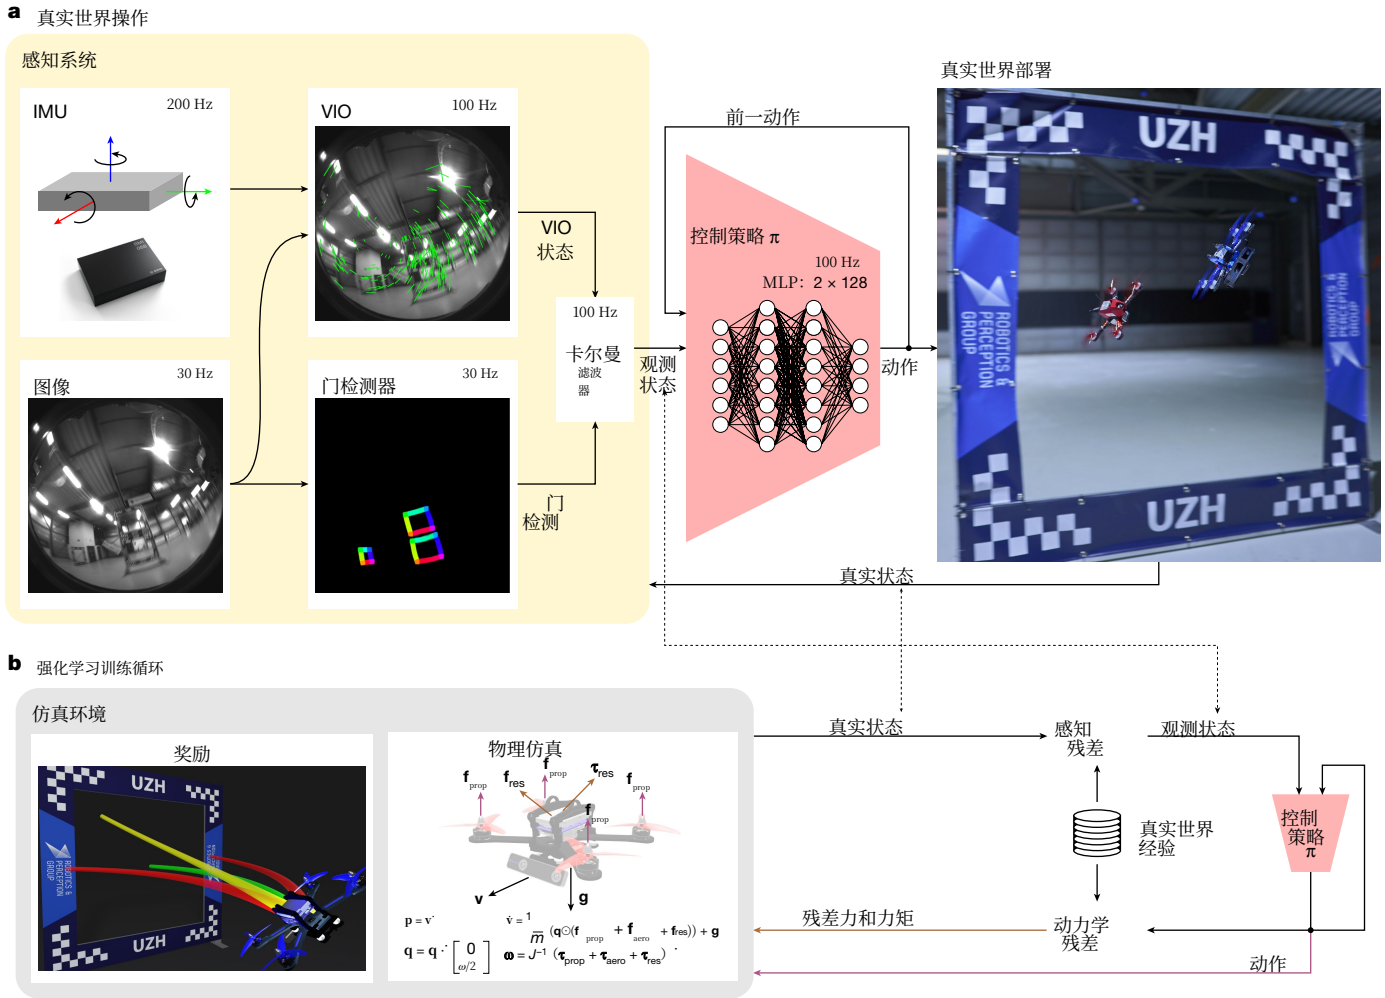


图 2 | Swift系统。 Swift由两个关键模块组成：一个感知系统，将视觉与惯性信息转换为低维状态观测；以及一个控制策略，将该状态观测映射为控制指令。控制指令指定期望的集体推力和机体角速率，与人类飞行员使用的控制模态相同。**a**，感知系统由一个VIO模块组成，该模块根据相机图像和惯性测量单元（IMU）获得的高频测量值计算无人机状态的度量估计。VIO估计与一个神经网络相结合，该神经网络在图像中检测竞速门的角点流。角点检测被映射为三维位姿，并使用卡尔曼滤波器与VIO估计融合。**b**，我们使用无模型同策略深度强化学习在仿真中训练控制策略。训练期间，策略最大化一个奖励，该奖励将朝向下一个赛道门中心的进展与保持下一个门位于摄像头视场内的感知目标相结合。为了将竞速策略从仿真迁移到物理世界，我们用车辆感知和动力学的数据驱动残差模型增强仿真。这些残差模型是从赛道上收集的真实世界经验中辨识得到的。MLP，多层感知机。

发现感知残差具有随机性，而动力学残差在很大程度上是确定性的（扩展数据图1）。这些残差模型被集成到仿真中，竞速策略在此增强仿真中进行微调。该方法与参考文献37中用于仿真到现实迁移的经验执行器模型相关，但进一步纳入了感知系统的经验建模，并且还考虑了平台状态估计中的随机性。

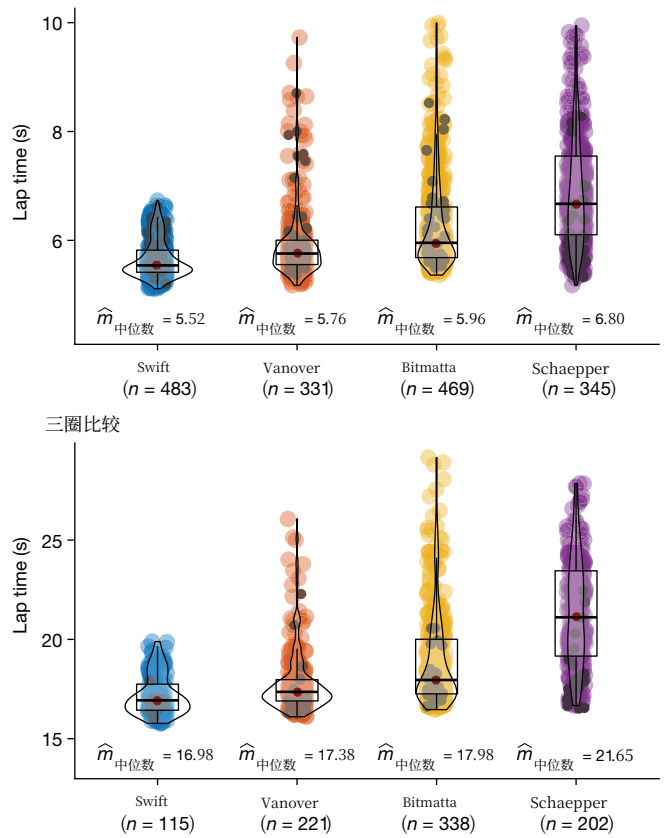
我们在扩展数据中报告的受控实验中对Swift的每个组件进行了消融。此外，我们与最近采用传统方法解决自主无人机竞速任务的工作进行了比较，包括轨迹规划和模型预测控制（MPC）。尽管此类方法在理想条件下（如简化动力学和完美已知机器人状态）能达到与我们的方法相当甚至更优的性能，但当其假设被违反时，性能便会崩溃。我们发现依赖预计算路径的方法[28,29]对噪声感知和动力学特别敏感。没有任何传统方法即使提供了来自动作捕捉系统的高精度状态估计，也未能达到与Swift或人类世界冠军相当的竞技圈速。详细分析见扩展数据。

结果

无人机竞速在由外部世界级FPV飞手设计的赛道上进行。赛道具有典型且富有挑战性的机动动作，例如Split-S（图1a（右上角）和图4d）。即使发生坠毁，只要飞行器仍能飞行，飞行员就可继续比赛。如果两架无人机均坠毁且无法完成赛道，则沿赛道行进更远的那架无人机获胜。

如图3b所示，Swift在对阵A. Vanover的9场比赛中赢得5场，在对阵T. Bitmatta的7场比赛中赢得4场，在对阵M. Schaepper的9场比赛中赢得6场。在Swift记录的10场负场中，40%是由于与对手碰撞，40%是由于与门碰撞，20%是由于无人机慢于人类飞行员。总体而言，Swift

a



b 正面对决竞速结果

	数量 比赛次数	最佳 完赛时间	胜场	负场	Win 比率
A. Vanover 对阵 Swift	9	17.956 s	4	5	0.44
T. Bitmatta 对阵 Swift	7	18.746 s	3	4	0.43
M. Schaepper 对阵 Swift	9	21.160 s	3	6	0.33
Swift 对比人类飞行员	25	17.465 s	15	10	0.60

图3|结果。 **a**，单圈时间结果。我们将Swift与人类飞行员在计时赛中进行比较。单圈时间表示在连续三圈的轮次中取得的最佳单圈最佳时间和最佳平均时间。所报告的统计数据是在赛道上为期一周记录的数据集上计算得出的，对应Swift的483（115）个数据点，A. Vanover的331（221）个，T. Bitmatta的469（338）个，以及M. Schaepper的345（202）个。第一个数字是单圈数，第二个是连续三圈数。每个分布中的深色点对应于在比赛条件下飞行的圈。**b**，正面对决结果。我们报告每位飞行员飞行的正面对决比赛数量、胜场数和负场数，以及胜率。

在对阵每位人类飞行员的比赛中赢得最多比赛。Swift还实现了记录的最快比赛时间，比人类飞行员（A. Vanover）创造的最佳时间领先半秒。

图4和扩展数据表1d分析了Swift和每位人类飞行员飞出的最快圈速。尽管Swift在全局上快于所有人类飞行员，但在赛道的各个单独赛段上并非都更快（扩展数据表1）。Swift在起步阶段以及诸如半滚倒转等急转弯中始终更快。起步时，Swift的反应时间更短，从出发台上起飞平均比人类飞行员早120 ms。此外，它加速更快，并在进入第一个门时达到更高的速度（扩展数据表1d，赛段1）。在急转弯中，如图4c,d所示，Swift找到了更紧凑的机动动作。一种假设是，Swift在比人类飞行员更长的时间尺度上优化轨迹。已知无模型强化学习可以通过价值函数优化长期奖励[38]。相反，人类飞行员在更短的时间尺度上规划其运动，最多提前一个门[39]。这一点很明显，例如在半滚倒转中（图4b,d），人类飞行员在机动动作开始时和结束时更快，但总体更慢（扩展数据表1d，赛段3）。此外，人类飞行员比Swift更早调整飞行器朝向以面向下一个门（图4c,d）。我们提出，人类飞行员习惯于将即将到来的门保持在视野中，而Swift已学会在依赖其他线索执行某些机动动作，例如惯性数据以及针对周围环境特征的视觉里程计。总体而言，在整个赛道上取平均，自主无人机实现了最高的平均速度，找到了最短的赛车线，并在整个比赛过程中设法将飞行器保持在更接近其驱动极限的状态，如平均推力和功率消耗所示（扩展数据表1d）。

我们还比较了 Swift 与人类冠军在计时赛中的表现（图 3a）。在计时赛中，由一名飞行员单独跑赛道，剩余圈数由飞行员自行决定。我们汇总了练习周和比赛期间的计时赛数据，包括训练飞行（图 3a，彩色）以及比赛条件下飞行的圈（图 3a，黑色）。对于每位参赛者，我们使用超过 300 圈来计算统计数据。自主无人机更一致地追求快速圈速，表现出更低的均值和方差。相反，人类飞行员则逐圈决定是否加速，因此在训练和比赛中圈速都具有更高的均值和方差。调整飞行策略的能力使人类飞行员在判断自己已明显领先时能够保持较慢节奏，以降低坠毁风险。自主无人机不知道对手的情况，无论何时都追求最快预期完成时间，这可能在其领先时冒太大风险，而在落后时又冒太小风险。[40]。

讨论

FPV无人机竞速要求基于来自物理环境的噪声和不完整的感官输入进行实时决策。我们提出了一种自主物理系统，在该运动中达到了冠军级表现，达到——有时甚至超过——人类世界冠军的表现。我们的系统相较于人类飞行员具有某些结构性优势。首先，它利用了来自机载惯性测量单元的惯性数据[32]。这类似于人类前庭系统[41]，，而人类飞行员并不使用该系统，因为他们并非实际位于飞行器内，无法感受到作用于其上的加速度。其次，我们的系统受益于更低的感觉运动延迟（Swift为40 ms，而专家级人类飞行员平均为220 ms[39]）。另一方面，Swift所用摄像头的有限刷新率（30 Hz）可被视为人类飞行员的结构性优势，其摄像头的刷新率快四倍（120 Hz），从而改善了他们的反应时间[42]。

人类飞行员具有令人印象深刻的鲁棒性：他们能够以全速坠毁，并且——如果硬件仍然正常工作——继续飞行并完成赛道。Swift并未接受过坠毁后恢复的训练。人类飞行员对环境条件的变化（例如光照）也具有鲁棒性，而光照会显著改变赛道的外观。相比之下，Swift的感知系统假设环境的外观与训练期间观测到的一致。如果这一假设不成立，系统可能会失效。通过对门检测器和残差观测模型在多样化条件下进行训练，可以提供对外观变化的鲁棒性。解决这些局限性将使得所提出的方法能够应用于自主无人机竞速比赛中，而在这些比赛中，对环境和无人机的访问是受限的[25]。

尽管仍存在局限性和有待完成的工作，但自主移动机器人在一项流行的物理运动中达到世界冠军级表现，是机器人学的一个里程碑

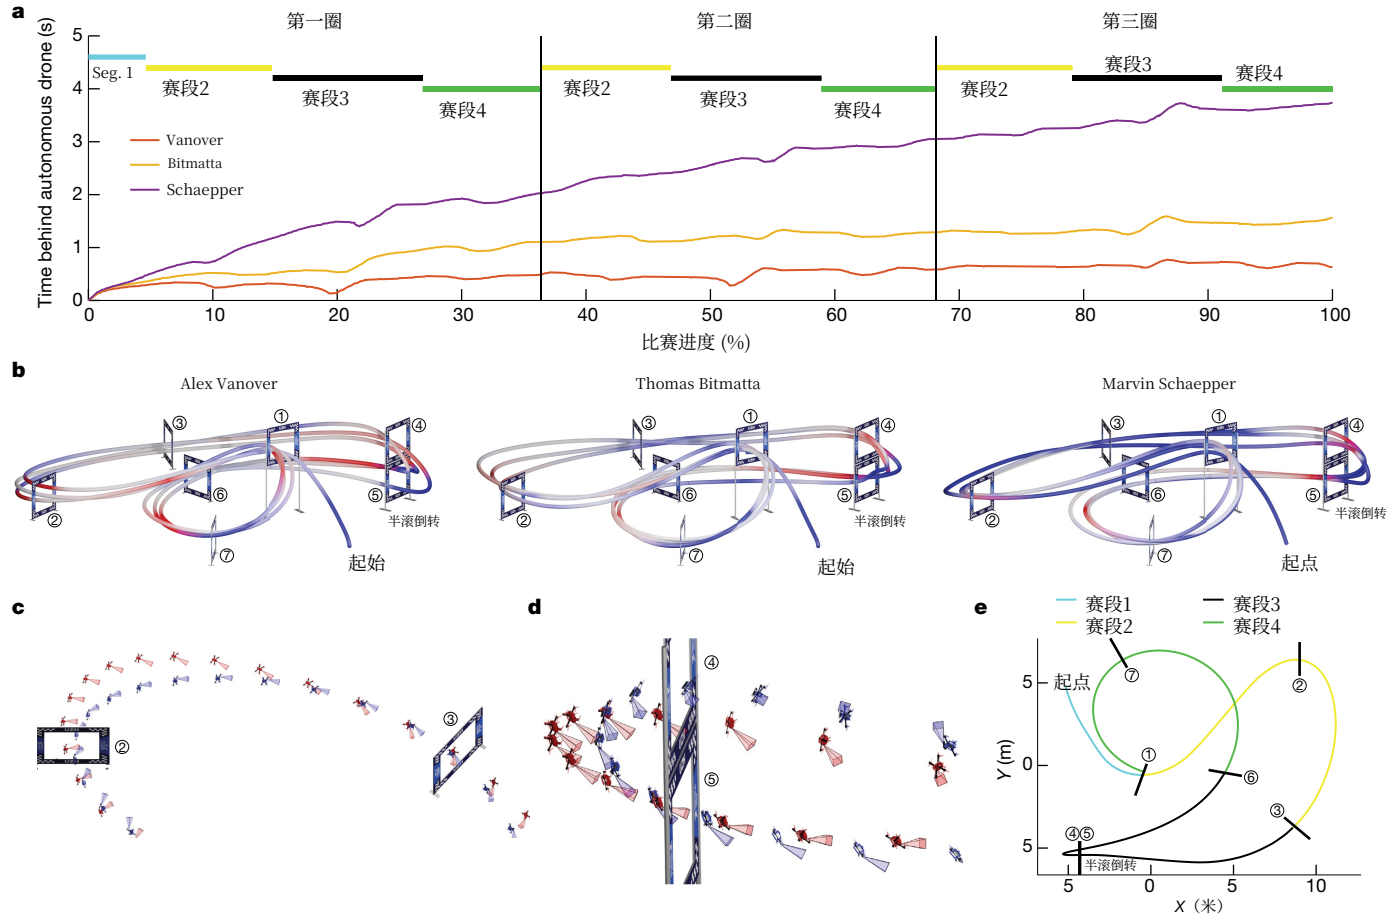


图 4 | 分析。a，各飞行员最快比赛对比，以落后 Swift 的时间表示。与自主无人机的时间差按其通过赛道上同一位置后的时间计算。尽管 Swift 全局上快于所有人类飞行员，但在赛道的各个单独赛段上未必都更快。**b**，与自主无人机相比，人类飞行员更快（红色）和更慢（蓝色）位置的可视化。Swift 在起步和急转弯（如半滚倒转）处始终更快。**c**，门2之后机动动作的分析。Swift 为蓝色，Vanover 为红色。Swift 在该赛段中通过执行更紧的转弯同时对人类飞行员取得时间优势，同时保持相当的速度。**d**，半滚倒转机动动作的分析。Swift 为蓝色，Vanover 为红色。半滚倒转是赛道中最具挑战性的赛段，需要精心协调的滚转和俯仰运动，从而通过两个门形成下降半滚。Swift 在该赛段中通过以更小的过冲执行更紧的转弯，对人类飞行员取得时间优势。**e**，用于分析的赛道赛段示意图。赛段1在起步时通过一次，而赛段2–4在每一圈中通过（比赛过程中共三次）。

与机器智能。这项工作可能会启发在其他物理系统中部署基于混合学习的解决方案，例如自动驾驶地面车辆、飞行器和个人机器人，应用于广泛领域。

在线内容

所有方法、附加参考文献、Nature Portfolio 报告摘要、源数据、扩展数据、补充信息、致谢、同行评审信息；作者贡献和利益冲突详情；以及数据和代码可用性声明均可在 https://doi.org/10.1038/s41586-023-06419-4 获取。

1. De Wagter, C., Paredes-Vallés, F., Sheth, N. & de Croon, G. 在自主无人机竞速中快速学习。*Nat. Mach. Intell.* **3**，923 (2021)。 2. Hanover, D. 等。 自主无人机竞速：综述。 预印本见 https://arxiv.org/abs/2301.01755 (2023)。 3. Sutton, R. S. & Barto, A. G. 强化学习：导论 (MIT Press, 2018)。 4. Mnih, V. 等。 通过深度强化学习实现人类水平的控制。*Nature* **518**，529–533 (2015)。 5. Schrittwieser, J. 等。 通过使用学习模型进行规划来掌握 Atari 、围棋、国际象棋和将棋。*Nature* **588**，604–609 (2020)。 6. Ecoffet, A., Huizinga, J., Lehman, J., Stanley, K. O. & Clune, J. 先返回，再探索。*Nature* **590**，580–586 (2021)。

7. Silver, D. 等。利用深度神经网络和树搜索掌握围棋游戏。Nature 529, 484–489 (2016). 8. Silver, D. 等。无需人类知识掌握围棋游戏。Nature 550, 354–359 (2017). 9. Silver, D. 等。一种通过自我对弈掌握国际象棋、将棋和围棋的通用强化学习算法。Science 362, 1140–1144 (2018). 10. Vinyals, O. 等。使用多智能体强化学习在 StarCraft II 中达到大师级水平。Nature 575, 350–354 (2019). 11. Berner, C. 等。大规模深度强化学习下的 Dota 2。预印本见 https://arxiv.org/abs/1912.06680 (2019). 12. Fuchs, F., Song, Y., Kaufmann, E., Scaramuzza, D. & Dürr, P. 使用深度强化学习在 Gran Turismo Sport 中实现超人表现。IEEE Robot. Autom. Lett. 6, 4257–4264 (2021). 13. Wurman, P. R. 等。使用深度强化学习超越冠军 Gran Turismo 车手。Nature 602, 223–228 (2022). 14. Funke, J. 等。载于 Proc. 2012 IEEE Intelligent Vehicles Symposium 541–547 (IEEE, 2012). 15. Spielberg, N. A., Brown, M., Kapania, N. R., Kegelman, J. C. & Gerdes, J. C. 用于高性能自动驾驶的神经网络车辆模型。Sci. Robot. 4, eaaw1975 (2019). 16. Won, D.-O., Müller, K.-R. & Lee, S.-W. 一种自适应深度强化学习框架使冰壶机器人在真实世界条件下具备类人表现。Sci. Robot. 5, eabb9764 (2020). 17. Moon, H., Sun, Y., Baltes, J. & Kim, S. J. IROS 2016 竞赛。IEEE Robot. Autom. Mag. 24, 20–29 (2017). 18. Jung, S., Hwang, S., Shin, H. & Shim, D. H. 使用深度学习进行室内自主无人机竞速的感知、制导和导航。IEEE Robot. Autom. Lett. 3, 2539–2544 (2018). 19. Kaufmann, E. 等。载于 Proc. 2nd Conference on Robot Learning (CoRL) 133–145 (PMLR, 2018). 20. Zhang, D. & Doyle, D. D. 载于 Proc. 2020 IEEE Aerospace Conference, 1–11 (IEEE, 2020).

21. Loquercio, A. 等。深度无人机竞速：通过域随机化从仿真到现实。IEEE Trans. Robot. 36, 1–14 (2019)。 22. Loquercio, A. 等。在野外环境中学习高速飞行。Sci. Robot. 6, eabg5810 (2021)。 23. Kaufmann, E. 等。载于 Proc. 2019 International Conference on Robotics and Automation (ICRA) 690–696 (IEEE, 2019)。 24. Li, S., van der Horst, E., Duernay, P., De Wagter, C. & de Croon, G. C. 面向计算高效自主竞速的 72 克无人机视觉模型预测定位。J. Field Robot. 37, 667–692 (2020)。 25. A.I. 正在驾驶无人机（非常、非常缓慢地）。https://www.nytimes.com/2019/03/26/technology/ alphapilot-ai-drone-racing.html (2019)。 26. Foehn, P. 等。AlphaPilot：自主无人机竞速。Auton. Robots 46, 307–320 (2021)。 27. Wagter, C. D., Paredes-Vallé, F., Sheth, N. & de Croon, G. 2019 Artificial Intelligence Robotic Racing Competition 获胜方案背后的感知、状态估计与控制。Field Robot. 2, 1263–1290 (2022)。 28. Foehn, P., Romero, A. & Scaramuzza, D. 四旋翼航点飞行的时间最优规划。Sci. Robot. 6, eabh1221 (2021)。 29. Romero, A., Sun, S., Foehn, P. & Scaramuzza, D. 面向时间最优四旋翼飞行的模型预测轮廓控制。IEEE Trans. Robot. 38, 3340–3356 (2022)。 30. Sun, S., Romero, A., Foehn, P., Kaufmann, E. & Scaramuzza, D. 非线性 MPC 与基于微分平坦的控制在四旋翼敏捷飞行中的比较研究。IEEE Trans. Robot. 38, 3357–3373 (2021)。 31. Schulman, J., Wolski, F., Dhariwal, P., Radford, A. & Klimov, O. 近端策略优化算法。预印本见 https://arxiv.org/abs/1707.06347 (2017)。 32. Scaramuzza, D. & Zhang, Z. Encyclopedia of Robotics（编：Ang, M., Khatib, O. & Siciliano, B.）1–9 (Springer, 2019)。 33. Huang, G. 载于 Proc. 2019 International Conference on Robotics and Automation (ICRA) 9572–9582 (IEEE, 2019)。 34. Collins, T. & Bartoli, A. 基于无穷小平面的位姿估计。Int. J. Comput. Vis. 109, 252–286 (2014)。 35. Song, Y., Steinweg, M., Kaufmann, E. & Scaramuzza, D. 载于 Proc. 2021 IEEE/RSJ International Conference o n Intelligent Robots and Systems (IROS) 1205–1212 (IEEE, 2021)。

36. Williams, C. K. & Rasmussen, C. E. 《机器学习中的高斯过程》(MIT Press, 2006)。 37. Hwangbo, J. 等。为腿式机器人学习敏捷且动态的运动技能。《Sci. Robot.》**4**，eaau5872 (2019)。 38. Hung, C.-C. 等。通过传递价值在长时间尺度上优化智能体行为。《Nat. Commun.》**10**，5223 (2019)。 39. Pfeiffer, C. & Scaramuzza, D. 人类驾驶无人机竞速：视觉处理与控制。《IEEE Robot. Autom. Lett.》**6**，3467–3474 (2021)。 40. Spica, R., Cristofalo, E., Wang, Z., Montijano, E. & Schwager, M. 面向自主双人无人机竞速的实时博弈论规划器。《IEEE Trans. Robot.》**36**，1389–1403 (2020)。 41. Day, B. L. & Fitzpatrick, R. C. 前庭系统。《Curr. Biol.》**15**，R583–R586 (2005)。 42. Kim, J. 等。电子竞技军备竞赛：竞技游戏任务中的延迟与刷新率。《J. Vis.》**19**，218c (2019)。

出版者注 施普林格·自然对已出版地图中的管辖权主张和机构隶属关系保持中立。

开放获取 本文根据知识共享署名4.0国际许可协议授权，允许以任何媒介或格式使用、共享、改编、分发和复制，只要您给予适当

注明原始作者和来源，提供知识共享许可协议的链接，并说明是否进行了修改。本文中的图像或其他第三方材料均包含在文章的知识共享许可协议中，除非在材料的署名行中另有说明。如果材料未包含在文章的知识共享许可协议中，且您的预期使用未获法定许可或超出许可范围，您需要直接向版权持有人获得许可。要查看此许可协议的副本，请访问 http://creativecommons.org/licenses/by/4.0/。

© 作者 2023

方法

四旋翼仿真

四旋翼动力学。为实现大规模训练，我们使用了四旋翼动力学的高保真仿真。本节简要说明该仿真。飞行器的动力学可以写为

$$\dot{\mathbf{x}} = \begin{bmatrix} \dot{\mathbf{p}}_{\mathcal{WB}} \\ \dot{\mathbf{q}}_{\mathcal{WB}} \\ \dot{\mathbf{v}}_{\mathcal{W}} \\ \dot{\boldsymbol{\omega}}_{\mathcal{B}} \\ \dot{\Omega} \end{bmatrix} = \begin{bmatrix} \mathbf{v}_{\mathcal{W}} \\ \mathbf{q}_{\mathcal{WB}} \cdot \begin{bmatrix} 0 \\ \boldsymbol{\omega}_{\mathcal{B}}/2 \end{bmatrix} \\ \frac{1}{m}(\mathbf{q}_{\mathcal{WB}} \odot (\mathbf{f}_{\text{prop}} + \mathbf{f}_{\text{aero}})) + \mathbf{g}_{\mathcal{W}} \\ J^{-1}(\boldsymbol{\tau}_{\text{prop}} + \boldsymbol{\tau}_{\text{mot}} + \boldsymbol{\tau}_{\text{aero}} + \boldsymbol{\tau}_{\text{iner}}) \\ \frac{1}{k_{\text{mot}}}(\Omega_{\text{ss}} - \Omega) \end{bmatrix}, \tag{1}$$

其中$\odot$表示四元数旋转，$\mathbf{p}$ $\mathbf{q}$ $\mathbf{v}_{\mathcal{WB}}$ $\boldsymbol{\omega}_{\mathcal{WB}}$ $\mathcal{W}$、$\mathcal{B}$ 和 $\boldsymbol{\omega}_{\mathcal{B}}$ 分别表示四旋翼的位置、姿态四元数、惯性速度和机体角速率。电机时间常数为 k_{mot}，电机转速 $\boldsymbol{\Omega}$ 和 $\boldsymbol{\Omega}_{\text{ss}}$ 分别为实际电机转速和稳态电机转速。矩阵 J 为四旋翼的惯性，$\mathcal{W}\mathbf{g}$表示重力向量。有两个力作用于四旋翼：由螺旋桨产生的升力 $\mathbf{f}_{\text{prop}}$，以及一个气动力 $\mathbf{f}_{\text{aero}}$，该力汇总了所有其他力，如气动阻力、动态升力和诱导阻力。力矩被建模为四个分量之和：由各个螺旋桨推力产生的力矩 $\boldsymbol{\tau}_{\text{prop}}$、由电机转速变化产生的偏航力矩 $\boldsymbol{\tau}_{\text{mot}}$、考虑桨叶挥舞等各种气动效应的气动力矩 $\boldsymbol{\tau}_{\text{aero}}$，以及惯性项 $\boldsymbol{\tau}_{\text{iner}}$。各分量如下所示

$$\mathbf{f}_{\text{prop}} = \sum_i \mathbf{f}_i, \ \boldsymbol{\tau}_{\text{prop}} = \sum_i \boldsymbol{\tau}_i + \mathbf{r}_{\text{P},i} \times \mathbf{f}_i, \tag{2}$$

$$\boldsymbol{\tau}_{\text{mot}} = J_{\text{m+p}} \sum_i \zeta_i \dot{\Omega}_i, \ \boldsymbol{\tau}_{\text{iner}} = -\boldsymbol{\omega}_{\mathcal{B}} \times \mathbf{J}\boldsymbol{\omega}_{\mathcal{B}} \tag{3}$$

其中 $\mathbf{r}_{\text{P},i}$ 是螺旋桨 i 在机体坐标系中的位置，$\mathbf{f}_i$ 和 $\boldsymbol{\tau}_i$ 分别是第 i 个螺旋桨产生的力和力矩。第 i 个电机的旋转轴记为 $\boldsymbol{\zeta}_i$，电机和螺旋桨的合惯性为 $J_{\text{m+p}}$，第 i 个电机转速的导数为 $\dot{\Omega}_i$。各个螺旋桨采用常用的二次模型进行建模，该模型假设升力和阻力力矩与螺旋桨转速的平方成正比 Ω_i:

$$\mathbf{f}_i(\Omega_i) = \begin{bmatrix} 0 & 0 & c_{\text{l}} \cdot \Omega_i^2 \end{bmatrix}^\top, \quad \boldsymbol{\tau}_i(\Omega_i) = \begin{bmatrix} 0 & 0 & c_{\text{d}} \cdot \Omega_i^2 \end{bmatrix}^\top \tag{4}$$

其中 c_{l} 和 c_{d} 分别表示螺旋桨升力系数和阻力系数。

气动力和力矩。气动力和力矩难以用第一性原理方法建模。因此我们使用数据驱动模型[43]。为保持大规模强化学习训练所需的低计算复杂度，采用灰盒多项式模型而非神经网络。假设气动效应主要取决于速度 $\mathbf{v}_{\mathcal{B}}$（在机体坐标系中）以及平均电机转速平方 Ω^2。气动力 f_x、f_y 和 f_z 以及力矩 τ_x、τ_y 和 τ_z 均在机体坐标系中估计。量 v_x、v_y 和 v_z 表示三个轴向速度分量（在机体坐标系中），而 $\overline{v_{xy}}$ 表示四旋翼在 (x、y) 平面内的速度。基于对底层物理过程的洞察，选择各项的线性与二次组合。为便于阅读，乘以每个求和项的系数已被省略:

$$\begin{aligned}
f_x &\sim v_x + v_x|v_x| + \overline{\Omega^2} + v_x\,\overline{\Omega^2} \\
f_y &\sim v_y + v_y|v_y| + \overline{\Omega^2} + v_y\,\overline{\Omega^2} \\
f_z &\sim v_z + v_z|v_z| + v_{xy} + v_{xy}^2 + v_{xy}\,\overline{\Omega^2} + v_z\,\overline{\Omega^2} + v_{xy}\,v_z\,\overline{\Omega^2} \\
\tau_x &\sim v_y + v_y|v_y| + \overline{\Omega^2} + v_y\,\overline{\Omega^2} + v_y|v_y|\,\overline{\Omega^2} \\
\tau_y &\sim v_x + v_x|v_x| + \overline{\Omega^2} + v_x\,\overline{\Omega^2} + v_x|v_x|\,\overline{\Omega^2} \\
\tau_z &\sim v_x + v_y
\end{aligned}$$

随后从真实世界飞行数据中辨识各自的系数，其中使用动作捕捉来提供真值力和力矩测量。我们使用来自赛道的数据，使动力学模型能够拟合该赛道。这类似于人类飞行员在比赛前数天或数周在将要比赛的特定赛道上进行训练。在我们的案例中，人类飞行员在比赛前获得了一周在同一赛道上的练习。

Betaflight 低级控制器。为控制四旋翼，神经网络输出集体推力和机体角速率。已知这种控制信号兼具高敏捷性和对仿真到现实迁移的良好鲁棒性[44]。随后，预测的集体推力和机体角速率由机载低级控制器处理，该控制器计算出各个电机指令，这些指令随后通过控制电机的电子调速器（ESC）转换为模拟电压信号。在物理飞行器上，该低级比例-积分-微分（PID）控制器和 ESC 使用开源的 Betaflight 和 BLHeli32 固件实现[45]。在仿真中，我们使用低级控制器和电机转速控制器的精确模型。

由于Betaflight PID控制器针对人工驾驶飞行进行了优化，它表现出一些特殊性，仿真正确地捕捉到了这些特性：D项的参考值始终为零（纯阻尼），油门切断时I项会被重置，并且在电机推力饱和时，机体角速率控制被赋予优先级（对所有电机信号进行比例降幅以避免饱和）。用于仿真的控制器增益已从Betaflight控制器内部状态的详细日志中辨识得到。仿真能够以低于1%的误差预测各个电机指令。

电池模型与电子调速器。低级控制器将各个电机指令转换为脉宽调制（PWM）信号并发送至电子调速器，由电子调速器控制电机。由于电子调速器不对电机转速执行闭环控制，稳态电机转速 $\Omega_{i,\text{ ss}}$ 对于给定的PWM电机指令 cmd_i 是电池电压的函数。因此，我们的仿真使用灰箱电池模型对电池电压进行建模[46]，该模型基于瞬时功耗 P_{mot} 来模拟电压:

$$P_{\text{mot}} = \frac{c_{\text{d}}\Omega^3}{\eta} \tag{5}$$

电池模型[46] 然后根据该功率需求模拟电池电压。给定电池电压 U_{bat} 和各电机指令 $u_{\text{cmd},\ i}$，我们使用该映射（再次省略了与各求和项相乘的系数）

$$\Omega_{i,\text{ss}} \sim 1 + U_{\text{bat}} + \sqrt{u_{\text{cmd},i}} + u_{\text{cmd},i} + U_{\text{bat}}\sqrt{u_{\text{cmd},i}} \tag{6}$$

以计算相应的稳态电机转速 $\Omega_{i,\text{ ss}}$ 这是方程（1）中动力学仿真所需的。这些系数已

从包含所有相关量测量的Betaflight日志中辨识得到。结合低级控制器模型，这使模拟器能够正确地将以集体推力和机体角速率形式表示的动作转换为期望电机转速Ω_{ss}，见方程（1）。

策略训练

我们训练深度神经控制策略，其直接将观测$\mathbf{o}_t$以平台状态和下一门观测的形式映射到控制动作$\mathbf{u}_t$，动作以质量归一化集体推力和机体角速率的形式表示[44]。控制策略在仿真中使用无模型强化学习进行训练。

训练算法。训练使用近端策略优化[31]进行。这种演员-评论家方法需要在训练期间联合优化两个神经网络：策略网络，将观测映射到动作；以及价值网络，充当“评论家”并评估策略所采取的动作。训练后，仅策略网络部署在机器人上。

观测、动作和奖励。在时间t从环境中获得的观测$\mathbf{o}_t \in \mathbb{R}^{31}$包括：(1) 当前机器人状态的估计；(2) 赛道上需要通过的下一个门的相对位姿；以及 (3) 上一步施加的动作。具体地，机器人状态的估计包含平台的位置、其速度以及用旋转矩阵表示的态度，从而得到$\mathbb{R}^{15}$中的一个向量。尽管仿真内部使用四元数，我们使用旋转矩阵来表示态度以避免歧义[47]。下一个门的相对位姿通过提供四个门角相对于飞行器的相对位置来编码，从而得到$\mathbb{R}^{12}$中的一个向量。所有观测在传递给网络之前都被归一化。由于价值网络仅在训练时使用，它可以访问策略无法访问的环境特权信息[48]。此特权信息与策略网络的其他输入拼接，并包含机器人的精确位置、朝向和速度。

对于每个观测 $\mathbf{o}_t$，策略网络产生一个 $\text{action}_t \in \mathbb{R}^4$ $\mathbf{a}$，其形式为期望的质量归一化集体推力和机体角速率。

我们使用密集塑形奖励公式来学习感知感知自主无人机竞速任务。奖励 r_t 在时间步 t 由下式给出

$$r_t = r_t^{\text{prog}} + r_t^{\text{perc}} + r_t^{\text{cmd}} - r_t^{\text{crash}} \tag{7}$$

其中 r^{prog} 奖励朝向下一门的进度[35], r^{perc} 通过调整飞行器的姿态，使摄像头的光轴指向下一门中心，从而编码感知意识，r^{cmd} 奖励平滑动作，并且 r^{crash} 是一个二元惩罚，仅在与门碰撞或平台离开预定义边界框时激活。如果 r^{crash} 被触发，训练回合结束。

具体而言，奖励项为

$$\begin{aligned} r_t^{\text{prog}} &= \lambda_1 [d_{t-1}^{\text{Gate}} - d_t^{\text{Gate}}] \\ r_t^{\text{perc}} &= \lambda_2 \exp[\lambda_3 \cdot \delta_{\text{cam}}^4] \end{aligned} \tag{8}$$

$$r_t^{\text{cmd}} = \lambda_4 \mathbf{a}_t^{\omega} + \lambda_5 \|\mathbf{a}_t - \mathbf{a}_{t-1}\|^2 \tag{9}$$

$$r_t^{\text{crash}} = \begin{cases} 5.0, \text{ if } p_z < 0 \text{ or in collision with gate} \\ 0, \quad \text{otherwise} \end{cases}$$

其中 d_t^{Gate} 表示在时间步 t 时，从飞行器质心到下一门中心的距离，δ_{cam} 表示摄像头光轴与下一门中心之间的角度

而 ${}^{t}\boldsymbol{\omega}\mathbf{a}$ 是指令机体角速率。超参数 $\lambda_1, \ldots, \lambda_5$用于平衡不同的项（扩展数据表1a）。

训练细节。 数据收集通过并行模拟100个智能体完成，这些智能体以1,500步的回合与环境交互。每次环境重置时，每个智能体在赛道上的随机门处初始化，并在先前通过该门时观测到的状态附近有界扰动。与先前工作相比[44,49,50],我们在训练时不执行平台动力学的随机化。相反，我们基于真实世界数据进行微调。训练环境使用TensorFlow Agents实现[51]。策略网络和价值网络均由两层感知机表示，每层128个节点，并使用负斜率为0.2的LeakyReLU激活函数。网络参数使用Adam优化器优化，学习率为 3×10^{-4}，用于策略网络和价值网络。

策略被训练总共进行 1×10^8 次环境交互，这在工作站（i9 12900K、RTX 3090、32 GB RAM DDR5）上需要 50 分钟。微调则进行 2×10^7 次环境交互。

残差模型辨识

我们基于在真实世界中收集的少量数据，对原始策略进行微调。具体而言，我们在真实世界中采集三次完整 rollout，对应约 50 秒飞行时间。我们通过辨识残差观测和残差动力学来微调策略，随后将其用于仿真训练。在此微调阶段，仅更新控制策略的权重，而门检测网络的权重保持不变。

残差观测模型。高速飞行会导致显著的运动模糊，这可能导致跟踪到的视觉特征丢失以及线性里程计估计的严重漂移。我们使用仅从真实世界中记录的少量试验中辨识出的里程计模型来微调策略。为了对里程计漂移建模，我们使用高斯过程[36],，因为它们允许拟合里程计扰动的后验分布，从中我们可以采样时间上一致的实现。

具体而言，高斯过程模型将残差位置、速度和姿态拟合为真值机器人状态的函数。通过将真实世界滚动中观测到的视觉惯性里程计（VIO）估计值与从外部运动跟踪系统获得的真值平台状态进行比较，来识别观测残差。

我们分别处理观测的每个维度，从而有效地将一组九个一维高斯过程拟合到观测残差。我们使用径向基函数核的混合

$$\kappa(\mathbf{z}_i, \mathbf{z}_j) = \sigma_{\text{f}}^2 \exp\left(-\frac{1}{2}(\mathbf{z}_i - \mathbf{z}_j)^{\top} L^{-2} (\mathbf{z}_i - \mathbf{z}_j)\right) + \sigma_{\text{n}}^2 \tag{10}$$

其中L是对角长度尺度矩阵，σ_{f}和σ_{n}分别表示数据和先验噪声方差，$\mathbf{z}_i$和$\mathbf{z}_j$表示数据特征。核超参数通过最大化对数边际似然来优化。在核超参数优化之后，我们从后验分布中采样新的实现，这些实现随后用于策略的微调。扩展数据图1展示了真实世界滚动中位置、速度和姿态的残差观测，以及从高斯过程模型中采样的100个实现。

残差动力学模型。我们使用残差模型来补充仿真机器人动力学[52]。具体而言，我们将残差加速度辨识为平台状态$\mathbf{s}$和指令质量归一化集体推力c的函数：

$$\mathbf{a}_{\text{res}} = \text{KNN}(\mathbf{s}, c) \tag{11}$$

我们使用 k-最近邻回归，其中 $k = 5$。用于残差动力学模型辨识的数据集大小取决于赛道布局，对于本工作中使用的赛道布局，其范围在800到1,000个样本之间。

门检测

为校正VIO管线累积的漂移，门被用作相对定位的独特地标。具体而言，通过分割门角在机载摄像头视图中检测门[26]。Intel RealSense追踪相机T265提供的灰度图像用作门检测器的输入图像。分割网络的架构是六级U-Net[53]，每级具有(8, 16, 16, 16, 16, 16)个大小为(3, 3, 3, 5, 7, 7)的卷积滤波器，以及一个对U-Net输出进行操作的最终额外层，包含12个滤波器。激活函数使用LeakyReLU，$\alpha = 0.01$。为部署在NVIDIA Jetson TX2上，网络被移植到TensorRT。为优化内存占用和计算时间，推理在半精度模式(FP16)下进行，图像在输入网络前被下采样至384×384大小。在NVIDIA Jetson TX2上，一次前向传播需要40 ms。

VIO漂移估计

来自VIO管线的里程计估计[54]在高速飞行期间表现出显著的漂移。我们使用门检测来稳定VIO产生的位姿估计。门检测器输出所有可见门的角点坐标。首先使用基于无穷小平面的位姿估计（IPPE）对所有预测的门估计相对位姿[34]。给定该相对位姿估计，每个门观测被分配给已知赛道布局中最近的门，从而得到无人机的位姿估计。

由于门检测频率较低且VIO方向估计质量较高，我们仅对VIO测量的平移分量进行修正。我们使用卡尔曼滤波器估计并校正VIO管线的漂移，该滤波器估计平移漂移$\mathbf{p}_{\text{d}}$（位置偏移）及其导数，即漂移速度$\mathbf{v}_{\text{d}}$。漂移校正通过从相应的VIO估计中减去估计的漂移状态$\mathbf{p}_{\text{d}}$和$\mathbf{v}_{\text{d}}$来执行。卡尔曼滤波器状态$\mathbf{x}$由下式给出$\mathbb{R}\mathbf{x}\ \mathbf{p}\ \mathbf{v} = [\ ^{\top}_{\text{d}},\ ^{\top}]^{\top} \in_{\text{d}}{}^{6}$。

状态 $\mathbf{x}$ 和协方差 P 的更新由下式给出：

$$\mathbf{x}_{k+1} = F\mathbf{x}_k, \quad P_{k+1} = FP_kF^{\top} + Q, \tag{12}$$

$$F = \begin{bmatrix} \mathbb{I}^{3\times3} & \mathrm{d}t\,\mathbb{I}^{3\times3} \\ \mathbf{0}^{3\times3} & \mathbb{I}^{3\times3} \end{bmatrix}, \quad Q = \begin{bmatrix} \sigma_{\text{pos}}\mathbb{I}^{3\times3} & \mathbf{0}^{3\times3} \\ \mathbf{0}^{3\times3} & \sigma_{\text{vel}}\mathbb{I}^{3\times3} \end{bmatrix}. \tag{13}$$

根据测量结果，过程噪声设置为 $\sigma_{\text{pos}} = 0.05$ 和 $\sigma_{\text{vel}} = 0.1$。滤波器状态和协方差初始化为零。对于每次测量 $\mathbf{z}_k$（来自门检测的位姿估计），预测的 VIO 漂移 $\mathbf{x}_k^-$ 根据卡尔曼滤波器方程被校正为估计值 $\mathbf{x}_k^+$：

$$\begin{aligned} K_k &= P_k^- H_k^{\top}(H_k P_k^- H_k^{\top} + R)^{-1}, \\ \mathbf{x}_k^+ &= \mathbf{x}_k^- + K_k(\mathbf{z}_k - H(\mathbf{x}_k^-)), \\ P_k^+ &= (I - K_k H_k)P_k^-, \end{aligned} \tag{14}$$

其中 K_k 是卡尔曼增益，R 是测量协方差，H_k 是测量矩阵。如果在单个相机帧中检测到多个门，则将所有相对位姿估计堆叠起来，并在同一个卡尔曼滤波器更新步骤中处理。测量误差的主要来源是网络门角点检测中的不确定性。图像平面中的这一误差在应用 IPPE 时会导致位姿误差。我们选择了一种基于采样的方法，根据已知的平均门角点检测不确定性来估计位姿误差。对于每个门，IPPE 算法既应用于标称门观测，也应用于 20 个扰动后的门角点估计。然后使用所得的位姿估计分布来近似门观测的测量协方差 R。

仿真结果

在自主无人机竞速中达到冠军级表现需要克服两个挑战：不完美感知和系统动力学的不完整模型。在仿真中的受控实验里，我们评估我们的方法对这两个挑战的鲁棒性。为此，我们评估在四种不同设置下部署时竞速任务中的性能。在设置（1）中，我们仿真一个简化四旋翼模型，并访问真值状态观测。在设置（2）中，我们用从真实世界飞行中识别出的噪声观测替换真值状态观测。这些噪声观测通过从残差观测模型中采样一个实现来生成，并且与所部署控制器的感知意识无关。设置（3）和（4）分别与前两个设置共享观测模型，但将简化动力学模型替换为更准确的空气动力学仿真[43]。这四种设置允许对方法对动力学变化和观测保真度变化的敏感性进行受控评估。

在所有四种设置中，我们将我们的方法与以下基线进行基准比较：零样本、域随机化和时间最优。零样本基线代表一个基于学习的竞速策略[35]，该策略使用无模型强化学习训练，并从训练域零样本部署到测试域。该策略的训练域等于实验设置（1），即理想化动力学和真值观测。域随机化通过随机化观测和动力学属性来扩展零样本基线的学习策略，以提高鲁棒性。时间最优基线使用预计算的时间最优轨迹[28]，并通过MPC控制器进行跟踪。与其他基于模型的时间最优飞行方法相比，该方法已展现出最佳性能[55,56]。轨迹生成和MPC控制器所使用的动力学模型与实验设置（1）中的模拟动力学相匹配。

性能评估基于最快圈速、成功通过门的平均和最小观测门裕度，以及成功完成的赛道百分比。门裕度度量的是无人机穿越门平面时与门上最近点之间的距离。较高的门裕度表明四旋翼飞行器靠近门的中心通过。保留较小的门裕度可以提高速度，但也会增加碰撞或错过门的风险。任何导致坠毁的圈均视为无效。

结果总结于扩展数据表1c。当部署于理想化动力学和真值观测时，所有方法均能成功完成任务，其中时间最优基线取得了最低圈速。当部署于存在域偏移的设置中时，无论是动力学还是观测中的域偏移，所有基线的性能均崩溃，三个基线均无法完成哪怕一圈。这种性能下降在学习型方法和传统方法中均有体现。相比之下，我们的方法以动力学的经验模型和观测噪声为特征，在所有部署设置中均取得成功，圈速仅有小幅增加。

使我们的方法能够在各种部署条件下成功的关键特征是使用从真实世界数据估计得到的动力学与观测噪声的经验模型。能够访问此类数据的方法与无法访问此类数据的方法之间的比较并不完全公平。因此，我们还在所有基线方法能够访问与我们方法所用相同的真实世界数据时，对其性能进行基准测试。具体而言，我们

比较实验设置(2)中的性能，该设置具有理想化动力学模型但感知存在噪声。所有基线方法都被提供了与我们用于表征观测噪声的同一高斯过程模型的预测。结果总结在扩展数据表1b中。所有基线方法都受益于更真实的观测，从而获得更高的完成率。然而，我们的方法是唯一能够可靠完成整个赛道的方法。除了观测噪声模型的预测外，我们的方法还考虑了模型的不确定性。关于在受控实验中强化学习与最优控制性能的深入比较，我们建议读者参考文献57。

进行多次迭代的微调

我们研究了不同迭代之间行为变化的程度。我们的分析结果表明，后续的微调操作对性能提升和行为改变的影响可以忽略不计（扩展数据图2）。

在下文中，我们提供了关于此调查的更多细节。我们首先列举微调步骤以提供必要的符号表示：

1. 在仿真中训练策略-0。2. 在真实世界中部署策略-0。该策略基于来自动作捕捉系统的真值数据运行。3. 识别策略-0在真实世界中观察到的残差。4. 基于识别出的残差，对策略-0进行微调以训练策略-1。5. 在真实世界中部署策略-1。该策略仅基于机载传感器测量运行。6. 识别策略-1在真实世界中观察到的残差。7. 基于识别出的残差，对策略-1进行微调以训练策略-2。

我们在各自残差上进行微调后，比较了策略-1和策略-2在仿真中的性能。结果如扩展数据图2所示。我们观察到，与门中心的距离差异（这是衡量策略安全性的一个指标）为0.09 ± 0.08 m。此外，完成单圈所需时间的差异为0.02 ± 0.02 s。请注意，这一单圈时间差异远小于Swift与人类飞行员单圈完成时间之间的差异（0.16 s）。

无人机硬件配置

人类飞行员和Swift所使用的四旋翼飞行器具有相同的重量、形状和推进系统。该平台设计基于Agilicious框架[58]。每个飞行器的重量为870 g，可产生约35 N的最大静态推力，从而得到4.1的静态推重比。每个平台的底座由一个Armattan Chameleon 6英寸主机架构成，该主机架配备T-Motor Velox 2306电机和5英寸三叶螺旋桨。自主无人机的主要计算资源由NVIDIA Jetson TX2及Connect Tech Quasar载板提供，其具有一个运行频率为2 GHz的六核CPU和一个运行频率为1.3 GHz、拥有256个CUDA核心的专用GPU。尽管门检测网络的前向传播在GPU上执行，竞速策略在CPU上评估，一次推理过程耗时8 ms。自主无人机搭载一个Intel RealSense追踪相机T265，其以100 Hz提供VIO估计[59]，并通过USB馈送至NVIDIA Jetson TX2。人类驾驶的无人机既不搭载Jetson计算机也不搭载RealSense相机，而是配备相应的配重。由人类飞行员或Swift生成的形式为集体推力和机体角速率的控制指令被发送至商用飞行控制器，该控制器运行在216 MHz的STM32处理器上。飞行控制器运行Betaflight，这是一款开源飞行控制软件[45]。

人类飞行员的印象

以下引言传达了三位与Swift竞速的人类冠军的印象。

Alex Vanover:

• 这些比赛将在半滚倒转处决出胜负，这是赛道中最具挑战性的部分。

• 这是最棒的一场比赛！我离自主无人机非常近，在试图跟上它时，我真的能感受到湍流。

Thomas Bitmatta:

• 可能性是无限的，这是可能改变整个世界的开端。另一方面，我是一名竞速选手，我不希望有任何东西比我更快。

• 当你飞得越快，你就得用精确度来换取速度。• 看到无人机真正具备的潜力令人鼓舞。很快，AI无人机甚至可以用作训练工具，来理解哪些事情将成为可能。

Marvin Schaepper:

• 与机器竞速的感觉不同，因为你知道机器不会疲倦。

研究伦理

本研究按照《赫尔辛基宣言》开展。根据苏黎世大学的规章制度，本研究方案免于伦理委员会审查，因为未收集任何健康相关数据。参与者在参与研究前均给出了书面知情同意。

数据可用性

评估论文结论所需的所有（其他）数据均包含在论文或扩展数据中。比赛事件的运动捕捉记录及配套分析代码可在 Zenodo 上的文件‘racing_data.zip’中找到，网址为 https://doi.org/10.5281/zenodo.7955278。

代码可用性

Swift 的伪代码，详细说明了训练过程和算法，可在 Zenodo 上的文件‘pseudocode.zip’中找到，网址为 https://doi.org/10.5281/zenodo.7955278。为防止潜在滥用，本研究相关的完整源代码将不会公开提供。

43. Bauersfeld, L., Kaufmann, E., Foehn, P., Sun, S. & Scaramuzza, D. in *Proc. Robotics:Science and Systems XVII* 42 (Robotics: Science and Systems Foundation, 2021).44. Kaufmann, E., Bauersfeld, L. & Scaramuzza, D. in *Proc. 2022 International Conference onRobotics and Automation (ICRA)* 10504–10510 (IEEE, 2022).45. The Betaflight Open Source Flight Controller Firmware Project. Betaflight. https://github.com/betaflight/betaflight (2022).46. Bauersfeld, L. & Scaramuzza, D. Range, endurance, and optimal speed estimates formulticopters. *IEEE Robot. Autom. Lett.* **7**, 2953–2960 (2022).47. Zhou, Y., Barnes, C., Lu, J., Yang, J. & Li, H. in *Proc. IEEE/CVF* 计算机视觉与模式识别会议（*CVPR*） 5745–5753 (IEEE, 2019).48. Pinto, L., Andrychowicz, M., Welinder, P., Zaremba, W. & Abbeel, P. in *Proc. Robotics:Science and Systems XIV* (MIT Press Journals, 2018).49. Molchanov, A. et al. in *Proc. 2019 IEEE/RSJ International Conference on Intelligent Robotsand Systems (IROS)* 59–66 (IEEE, 2019).50. Andrychowicz, O. M. et al. Learning dexterous in-hand manipulation. *Int. J. Robot. Res.***39**, 3–20 (2020).51. Guadarrama, S. et al. TF-Agents: a library for reinforcement learning in TensorFlow.https://github.com/tensorflow/agents (2018).52. Torrente, G., Kaufmann, E., Foehn, P. & Scaramuzza, D. Data-driven MPC for quadrotors.*IEEE Robot. Autom. Lett.* **6**, 3769–3776 (2021).53. Ronneberger, O., Fischer, P. & Brox, T. in *Proc.* 国际医学图像计算与计算机辅助介入会议 234–241 (Springer, 2015) .54. Intel RealSense T265 series product family. https://www.intelrealsense.com/wp-content/uploads/2019/09/Intel_RealSense_Tracking_Camera_Datasheet_Rev004_release.pdf (2019).55. Ryou, G., Tal, E. & Karaman, S. Multi-fidelity black-box optimization for time-optimalquadrotor maneuvers. *Int. J. Robot. Res.* **40**, 1352–1369 (2021).56. Pham, H. & Pham, Q.-C. A new approach to time-optimal path parameterization based onreachability analysis. *IEEE Trans. Robot.* **34**, 645–659 (2018).57. Song, Y., Romero, A., Müller, M., Koltun, V. & Scaramuzza, D. Reaching the limit inautonomous racing: optimal control versus reinforcement learning. *Sci. Robot.* (in thepress).

58. Foehn, P. et al. Agilicious：开源开放硬件敏捷四旋翼用于基于视觉的飞行。 *Sci. Robot.* **7**, eabl6259 (2022)。 59. Jones, E. S. & Soatto, S. 视觉惯性导航、建图与定位：一种可扩展的实时因果方法。 *International Journal of Robotics Research* **30**, 407–430 (2011)。

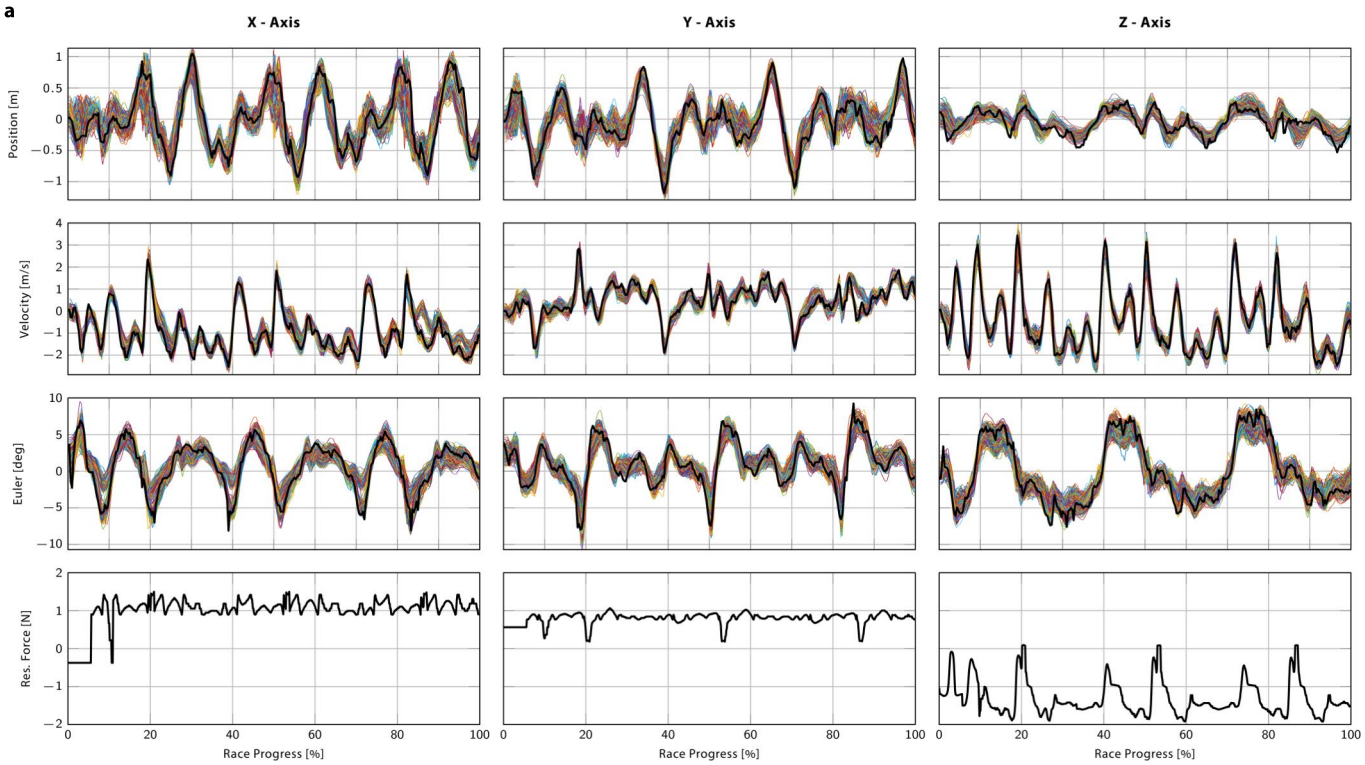
致谢 作者感谢 A. Vanover、T. Bitmatta 和 M. Schaepper 接受与 Swift 竞速。作者还感谢 C. Pfeiffer、T. Längle 和 A. Barden 对赛事组织及无人机硬件设计的贡献。本工作得到英特尔具身智能实验室、瑞士国家科学基金会（SNSF）通过国家研究能力中心（NCCR）机器人学以及欧洲研究委员会（ERC）在资助协议 864042 (AGILEFLIGHT) 下的支持。

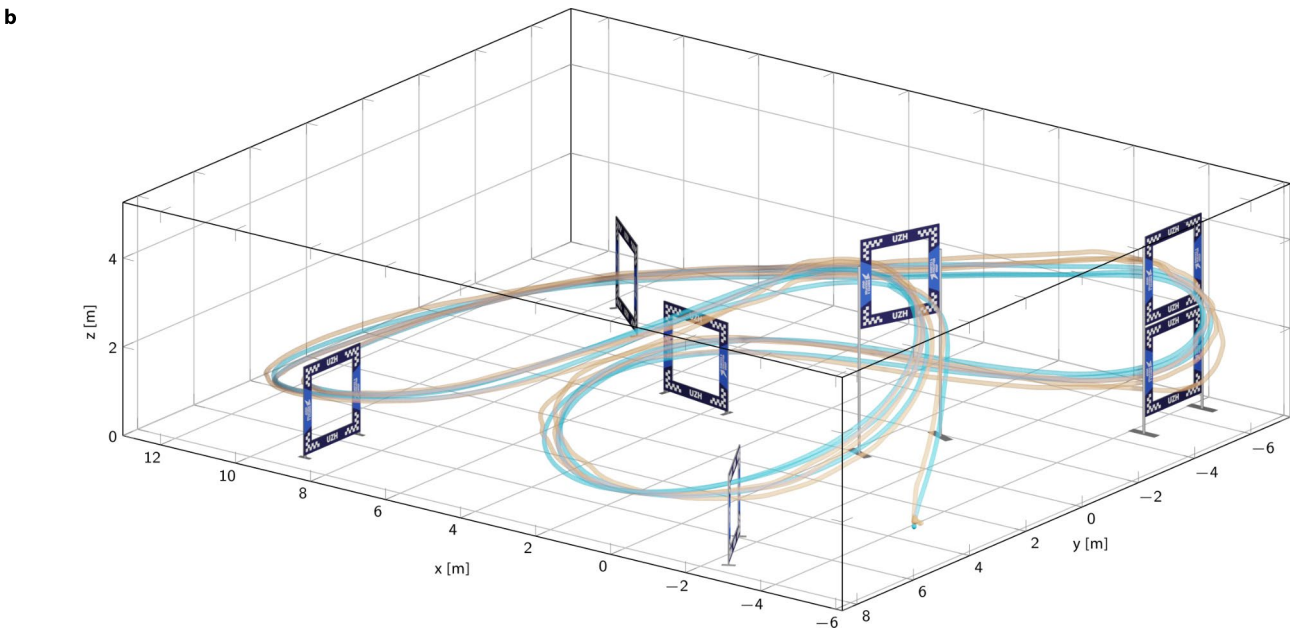
作者贡献 E.K.提出了核心思想，实现了系统，完成了实验和数据分析，并撰写了论文。L.B.对核心思想、实验、数据分析、论文写作做出了贡献，并设计了图形插图。A.L. 提出了核心思想，并对实验设计、数据分析和论文写作做出了贡献。M.M.对实验设计、数据分析和论文写作做出了贡献。V.K.对核心思想、实验设计、实验分析和论文写作做出了贡献。D.S.对核心思想、实验设计、实验分析和论文写作做出了贡献，并提供了资助。

利益冲突 作者声明无利益冲突。

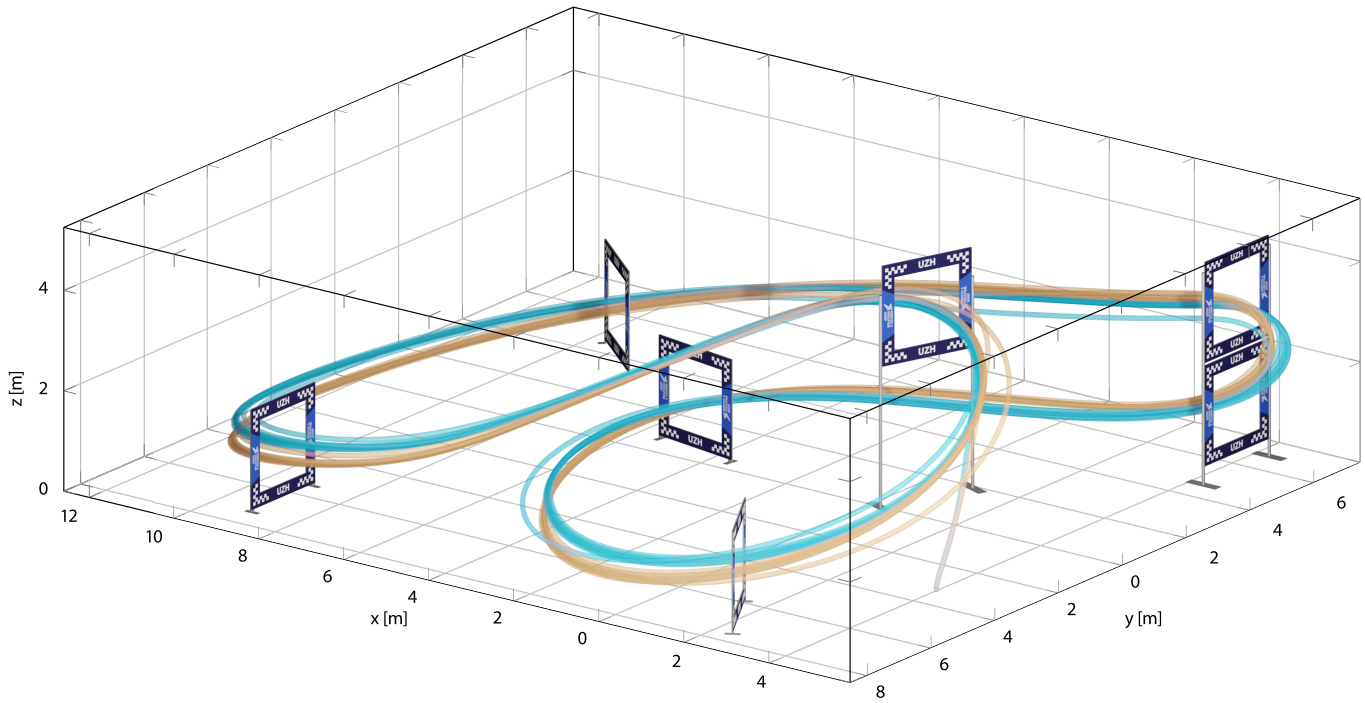
附加信息

补充信息 在线版本包含补充材料，可访问 https://doi.org/10.1038/s41586-023-06419-4。**通讯作者及材料索取**请联系 Elia Kaufmann。**同行评审信息** *Nature* 感谢 Sunggoo Jung、Karime Pereida 以及其他匿名审稿人对本工作同行评审的贡献。同行评审报告可获取。**转载与许可信息** 可访问 http://www.nature.com/reprints。





扩展数据图1|残差模型。 **a**，从真实世界数据中辨识出的残差观测模型和残差动力学模型的可视化。黑色曲线描绘了真实世界中观测到的残差，彩色线条展示了残差观测模型的100个采样实现。每个子图描绘了整场比赛，即三圈。**b**，模拟展开的预测残差观测。蓝色，模拟器提供的真实位置；橙色，高斯过程残差生成的扰动位置。



扩展数据图 2| 多迭代微调。将策略微调一个迭代（蓝色）和两个迭代（橙色）后的展开比较 e).

扩展数据表 1 | 网络参数和详细指标展示了我们的Swift系统与其他方法的比较

a

Hyperparameter	Value
γ (discount factor)	0.99
ε (importance ratio clipping)	0.2
λ_1	1.0
λ_2	0.02
λ_3	-10.0
λ_4	-2e-4
λ_5	-1e-4

b

Approach	Lap time in seconds	Gate margin in meters	Completion in %
Zero-Shot Transfer [33]	4.92	0.57 — 0.41	42
Domain Randomization	1	0.34 — 0.23	19
Time-Opt. Traj. + MPC [26]	1	0.51 — 0.41	19
Ours	5.26	0.56 — 0.44	100

c

		Ground-truth observations			Noisy observations		
	Approach	Lap time in seconds	Gate margin in meters	Completion in %	Lap time in seconds	Gate margin in meters	Completion in %
Idealized dyn.	Zero-Shot Transfer [33]	4.88	0.63 — 0.46	100	1	n/a — n/a	0
	Domain Randomization	5.06	0.60 — 0.47	100	1	0.43 — 0.30	9
	Time-Opt. Traj. + MPC [26]	4.60	0.50 — 0.25	100	1	0.48 — 0.29	9
	Ours	4.88	0.63 — 0.46	100	5.26	0.56 — 0.44	100
Realistic dyn.	Zero-Shot Transfer [33]	1	0.62 — 0.62	4	1	0.41 — 0.21	9
	Domain Randomization	1	0.28 — 0.28	4	1	0.47 — 0.45	9
	Time-Opt. Traj. + MPC [26]	1	n/a — n/a	0	1	0.23 — 0.23	4
	Ours	5.20	0.51 — 0.30	100	5.42	0.48 — 0.23	100

d

	Autonomous Drone					**Vanover**					**Bitmatta**					**Schaepper**				
	Speed in m/s	Power in W	Thrust in N	Time in s	Length in m	Speed in m/s	Power in W	Thrust in N	Time in s	Length in m	Speed in m/s	Power in W	Thrust in N	Time in s	Length in m	Speed in m/s	Power in W	Thrust in N	Time in s	Length in m
Segment 1	**6.52**	**548.14**	**19.80**	**1.27**	8.27	5.62	348.91	14.96	1.42	7.98	5.93	365.78	15.87	1.36	8.07	4.92	201.06	10.47	1.59	**7.82**
Segment 2	13.72	852.20	29.01	**1.82**	**25.01**	**13.83**	**863.85**	**29.22**	1.83	25.31	13.72	854.36	28.95	1.89	25.94	10.76	508.29	19.97	2.36	25.35
Segment 3	13.70	798.69	27.60	**1.96**	**26.89**	**13.86**	**853.69**	**28.98**	2.09	28.91	13.16	727.36	25.50	2.23	29.35	12.66	636.78	23.47	2.40	30.34
Segment 4	13.43	**1047.05**	**33.69**	1.61	21.62	12.97	953.47	31.62	**1.60**	**20.72**	**13.47**	1035.91	33.39	1.67	22.53	13.11	885.53	29.95	1.77	23.20
Full Race	**13.11**	**866.48**	**29.16**	**17.46**	**228.85**	12.96	843.50	28.65	17.96	232.79	12.89	822.50	27.96	18.74	241.52	11.55	623.53	22.95	21.16	244.49

a，训练超参数。**b**，与基线的比较，这些基线使用与我们方法相同的观测噪声模型。**c**，仿真评估，理想化动力学（上）与真实动力学（下）以及真值观测（左）与噪声观测（右）的对比。我们报告最快实现的无碰撞单圈时间（秒）、成功通过门的平均和最小门裕度以及赛道完成度百分比。我们将我们的方法与一种执行零样本迁移的基于学习的方法进行比较，该迁移在训练期间有和没有域随机化，以及一种传统的规划与控制方法[28]。**d**，在最快飞行比赛中每位飞行员的平均速度、功率、推力、时间和飞行距离的比较。最佳数值以粗体表示。