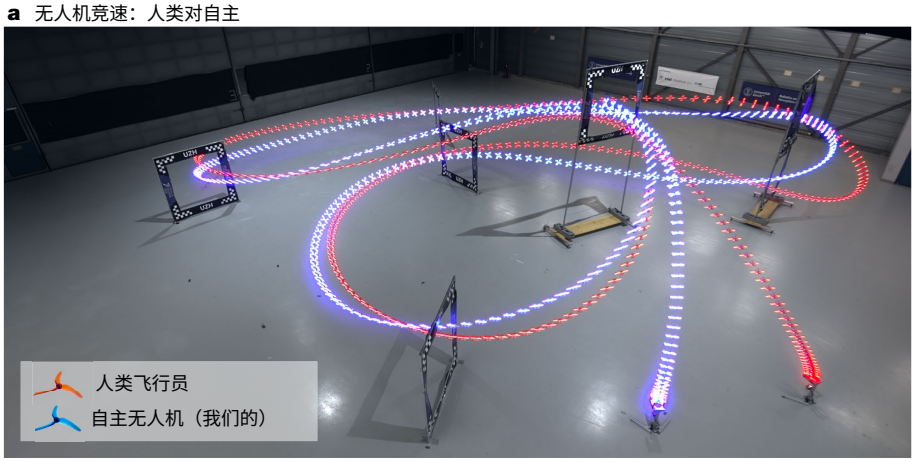
a 无人机竞速：人类对自主



b 正面交锋



c 人类冠军



图1|无人机竞速。 **a**，Swift（蓝色）与2019年无人机竞速联赛世界冠军Alex Vanover（红色）进行头对头竞速。赛道包含七个方形门，每圈必须按顺序通过。要赢得比赛，参赛者必须在对手之前完成连续三圈。**b**，Swift的近距离视图，以蓝色LED灯照明，以及人类驾驶无人机，以红色LED灯照明。本工作中使用的自主无人机仅依赖机载传感器测量，无外部基础设施（如动作捕捉系统）的支持。**c**，从左至右：Thomas Bitmatta、Marvin Schaepper和Alex Vanover驾驶他们的无人机穿过赛道。每位飞行员佩戴一个头戴式设备，显示从其飞行器上的摄像头实时传输的视频流。头戴式设备提供沉浸式的“第一人称视角”体验。**c**，摄影：Regina Sablotny。

（一架由人类飞行员控制，一架由Swift控制）从起飞台出发。比赛由声学信号启动。第一辆完成赛道上完整三圈、且每圈均按正确顺序通过所有门的车辆赢得比赛。

Swift在与每位人类飞行员的多次比赛中均获胜，并取得了赛事期间记录的最快比赛时间。据我们所知，我们的工作首次实现了自主移动机器人在真实世界竞技体育中达到世界冠军级表现。

Swift系统

Swift结合了基于学习的方法和传统算法，将机载传感读数映射为控制指令。这一映射包括两部分：（1）观测策略，将高维视觉和惯性信息提炼为任务特定的低维编码；（2）控制策略，将编码转换为无人机的指令。系统的概览示意图见图2。

观测策略由一个视觉惯性估计器组成[32,33]，它与门检测器协同运行[26],，门检测器是一个卷积神经网络，用于检测机载图像中的赛道门。检测到的赛道门随后被用于估计无人机沿赛道的全局位置和姿态。这是通过相机重定位算法[34]结合赛道地图完成的。然后，通过卡尔曼滤波器将由门检测器获得的全局位姿估计与视觉惯性估计器的估计进行融合，从而获得更精确的表示

表示机器人状态。控制策略由两层感知机表示，将卡尔曼滤波器的输出映射为飞行器的控制指令。该策略在仿真中使用同策略无模型深度强化学习[31]进行训练。在训练期间，策略最大化一个奖励，该奖励将朝向下一赛道门的进展[35]与一个感知目标结合起来，后者奖励将下一赛道门保持在摄像头视野内。看到下一赛道门会获得奖励，因为这会提高位姿估计的准确性。

如果在仿真中纯粹优化策略，当仿真与现实之间的差异未被缓解时，在物理硬件上会产生较差的性能。这些差异主要由两个因素引起：(1) 仿真动力学与真实动力学之间的差异，以及(2) 当观测策略面对真实传感数据时，对机器人状态的噪声估计。我们通过在现实世界中收集少量数据，并使用这些数据来提高仿真器的真实感，从而缓解这些差异。

具体而言，我们记录了机器人的机载传感器观测数据，以及无人机在赛道上竞速时由动作捕捉系统提供的高精度位姿估计。在此数据收集阶段，机器人由在仿真中训练的策略控制，该策略基于动作捕捉系统提供的位姿估计进行操作。所记录的数据能够识别出在赛道上观察到的感知和动力学的典型失效模式。感知失效和未建模动力学的这些复杂特性取决于环境、平台、赛道和传感器。感知和动力学残差分别使用高斯过程[36]和k近邻回归进行建模。这一选择的动机是我们根据经验

方法

四旋翼仿真

四旋翼动力学。为了实现大规模训练，我们使用了四旋翼动力学的高保真仿真。本节简要说明该仿真。飞行器的动力学可以写为

$$\dot{\mathbf{x}}=\begin{bmatrix}\dot{\mathbf{p}}_{\mathcal{WB}}\\ \dot{\mathbf{q}}_{\mathcal{WB}}\\ \dot{\mathbf{v}}_{\mathcal{W}}\\ \dot{\boldsymbol{\omega}}_{\mathcal{B}}\\ \dot{\Omega}\end{bmatrix}=\begin{bmatrix}\mathbf{v}_{\mathcal{W}}\\ \mathbf{q}_{\mathcal{WB}}\cdot\begin{bmatrix}0\\ \boldsymbol{\omega}_{\mathcal{B}}/2\end{bmatrix}\\ \frac{1}{m}(\mathbf{q}_{\mathcal{WB}}\odot(\mathbf{f}_{\text{prop}}+\mathbf{f}_{\text{aero}}))+\mathbf{g}_{\mathcal{W}}\\ J^{-1}(\boldsymbol{\tau}_{\text{prop}}+\boldsymbol{\tau}_{\text{mot}}+\boldsymbol{\tau}_{\text{aero}}+\boldsymbol{\tau}_{\text{iner}})\\ \frac{1}{k_{\text{mot}}}(\Omega_{\text{ss}}-\Omega)\end{bmatrix}, \tag{1}$$

其中$\odot$表示四元数旋转，$\mathbf{p}$ $\mathbf{q}$ $\mathbf{v}_{\mathcal{WB}}$ $_{\mathcal{WB}}$ $_{\mathcal{W}}$，，和$\boldsymbol{\omega}_{\mathcal{B}}$分别表示四旋翼的位置、姿态四元数、惯性速度和机体角速度。电机时间常数为k_{mot}，电机转速$\boldsymbol{\Omega}$和$\boldsymbol{\Omega}_{\text{ss}}$分别为实际电机转速和稳态电机转速。矩阵$J$为四旋翼的惯性，$_{\mathcal{W}}\mathbf{g}$ 表示重力向量。两个力作用于四旋翼：由螺旋桨产生的升力$\mathbf{f}_{\text{prop}}$以及气动力$\mathbf{f}_{\text{aero}}$，后者综合了所有其他力，例如气动阻力、动态升力和诱导阻力。力矩被建模为四个分量之和：各个螺旋桨推力产生的力矩$\boldsymbol{\tau}_{\text{prop}}$、电机转速变化产生的偏航力矩$\boldsymbol{\tau}_{\text{mot}}$、考虑桨叶挥舞等各种气动效应的气动力矩$\boldsymbol{\tau}_{\text{aero}}$以及惯性项$\boldsymbol{\tau}_{\text{iner}}$。各分量分别为

$$\mathbf{f}_{\text{prop}}=\sum_i\mathbf{f}_i,\ \boldsymbol{\tau}_{\text{prop}}=\sum_i\boldsymbol{\tau}_i+\mathbf{r}_{\text{P},i}\times\mathbf{f}_i, \tag{2}$$

$$\boldsymbol{\tau}_{\text{mot}}=J_{\text{m+p}}\sum_i\zeta_i\dot{\Omega}_i,\ \boldsymbol{\tau}_{\text{iner}}=-\boldsymbol{\omega}_{\mathcal{B}}\times\mathbf{J}\boldsymbol{\omega}_{\mathcal{B}} \tag{3}$$

其中$\mathbf{r}_{\text{P},i}$是螺旋桨i在机体坐标系中的位置，$\mathbf{f}_i$和$\boldsymbol{\tau}_i$分别是第i个螺旋桨产生的力和力矩。第i个电机的旋转轴记为$\boldsymbol{\zeta}_i$，电机和螺旋桨的合成惯性为$J_{\text{m+p}}$，第i个电机转速的导数为$\dot{\Omega}_i$。各螺旋桨采用常用的二次模型进行建模，该模型假设升力和阻力力矩与螺旋桨转速Ω_i的平方成正比：

$$\mathbf{f}_i(\Omega_i)=\begin{bmatrix}0 & 0 & c_{\text{l}}\cdot\Omega_i^2\end{bmatrix}^{\top},\quad\boldsymbol{\tau}_i(\Omega_i)=\begin{bmatrix}0 & 0 & c_{\text{d}}\cdot\Omega_i^2\end{bmatrix}^{\top} \tag{4}$$

其中c_{l}和c_{d}分别表示螺旋桨升力系数和阻力系数。

气动力与力矩。气动力与力矩难以用第一性原理方法建模。因此，我们使用数据驱动模型[43]。为保持大规模强化学习训练所需的低计算复杂度，我们采用灰盒多项式模型，而非神经网络。假设气动效应主要取决于速度$\mathbf{v}_{\mathcal{B}}$（在机体坐标系中）以及平均电机转速平方Ω^2。气动力f_x、f_y和f_z以及力矩τ_x、τ_y和τ_z均在机体坐标系中估计。量v_x、v_y和v_z表示三个轴向速度分量（在机体坐标系中），而v_{xy}表示四旋翼在(x,y)平面内的速度。基于对底层物理过程的洞察，选取各项的线性与二次组合。为便于阅读，乘以各求和项的系数已省略：

$$\begin{aligned}
f_x &\sim v_x+v_x|v_x|+\overline{\Omega^2}+v_x\,\overline{\Omega^2}\\
f_y &\sim v_y+v_y|v_y|+\overline{\Omega^2}+v_y\,\overline{\Omega^2}\\
f_z &\sim v_z+v_z|v_z|+v_{xy}+v_{xy}^2+v_{xy}\,\overline{\Omega^2}+v_z\,\overline{\Omega^2}+v_{xy}\,v_z\,\overline{\Omega^2}\\
\tau_x &\sim v_y+v_y|v_y|+\overline{\Omega^2}+v_y\,\overline{\Omega^2}+v_y|v_y|\,\overline{\Omega^2}\\
\tau_y &\sim v_x+v_x|v_x|+\overline{\Omega^2}+v_x\,\overline{\Omega^2}+v_x|v_x|\,\overline{\Omega^2}\\
\tau_z &\sim v_x+v_y
\end{aligned}$$

随后，从真实飞行数据中辨识各自的系数，其中利用动作捕捉提供真值力与力矩测量。我们使用赛道数据，使动力学模型能够拟合该赛道。这类似于人类飞行员在比赛前于其将要参赛的特定赛道上进行数天或数周的训练。在我们的情况中，人类飞行员在比赛前于同一赛道上获得了一周的练习时间。

Betaflight 底层控制器。为控制四旋翼，神经网络输出总推力和机体角速度。已知该控制信号兼具高敏捷性与良好的仿真到现实迁移鲁棒性[44]。预测的总推力和机体角速度随后由机载底层控制器处理，计算出各电机指令，再通过控制电机的电子调速器(ESC)转换为模拟电压信号。在实体飞行器上，该底层比例-积分-微分(PID)控制器和电子调速器使用开源 Betaflight 和 BLHeli32 固件实现[45]。在仿真中，我们使用底层控制器和电机转速控制器的精确模型。

由于Betaflight PID控制器针对人工驾驶飞行进行了优化，它表现出一些特殊性，仿真正确地捕捉到了这些特性：D项的参考值恒为零（纯阻尼），油门切断时I项会被重置，并且在电机推力饱和情况下，机体角速率控制被赋予优先级（对所有电机信号进行比例降幅以避免饱和）。用于仿真的控制器增益已从Betaflight控制器内部状态的详细日志中辨识得到。该仿真能够以低于1%的误差预测各个电机指令。

电池模型与电子调速器。底层控制器将各个电机指令转换为脉宽调制（PWM）信号，并将其发送给电子调速器，由电子调速器控制电机。由于电子调速器不对电机转速执行闭环控制，因此对于给定的PWM电机指令cmd_i，稳态电机转速$\Omega_{i,\ \text{ss}}$是电池电压的函数。因此，我们的仿真使用灰箱电池模型对电池电压进行建模[46]，该模型基于瞬时功耗P_{mot}来模拟电压：

$$P_{\text{mot}}=\frac{c_{\text{d}}\Omega^3}{\eta} \tag{5}$$

电池模型[46]然后根据该功率需求模拟电池电压。给定电池电压U_{bat}和各个电机指令$u_{\text{cmd},i}$，我们使用映射（再次省略乘以每个加数的系数）

$$\Omega_{i,\text{ss}}\sim 1+U_{\text{bat}}+\sqrt{u_{\text{cmd},i}}+u_{\text{cmd},i}+U_{\text{bat}}\sqrt{u_{\text{cmd},i}} \tag{6}$$

以计算对应稳态电机转速$\Omega_{i,\ \text{ss}}$该转速为方程（1）中动力学仿真所需。系数已

扩展数据表 1 | 网络参数和详细指标展示了我们的Swift系统与其他方法的比较

a

Hyperparameter	Value
γ (discount factor)	0.99
ε (importance ratio clipping)	0.2
λ_1	1.0
λ_2	0.02
λ_3	-10.0
λ_4	-2e-4
λ_5	-1e-4

b

Approach	Lap time in seconds	Gate margin in meters	Completion in %
Zero-Shot Transfer [33]	4.92	0.57 — 0.41	42
Domain Randomization	1	0.34 — 0.23	19
Time-Opt. Traj. + MPC [26]	1	0.51 — 0.41	19
Ours	5.26	0.56 — 0.44	100

c

		Ground-truth observations			Noisy observations		
	Approach	Lap time in seconds	Gate margin in meters	Completion in %	Lap time in seconds	Gate margin in meters	Completion in %
Idealized dyn.	Zero-Shot Transfer [33]	4.88	0.63 — 0.46	100	1	n/a — n/a	0
	Domain Randomization	5.06	0.60 — 0.47	100	1	0.43 — 0.30	9
	Time-Opt. Traj. + MPC [26]	4.60	0.50 — 0.25	100	1	0.48 — 0.29	9
	Ours	4.88	0.63 — 0.46	100	5.26	0.56 — 0.44	100
Realistic dyn.	Zero-Shot Transfer [33]	1	0.62 — 0.62	4	1	0.41 — 0.21	9
	Domain Randomization	1	0.28 — 0.28	4	1	0.47 — 0.45	9
	Time-Opt. Traj. + MPC [26]	1	n/a — n/a	0	1	0.23 — 0.23	4
	Ours	5.20	0.51 — 0.30	100	5.42	0.48 — 0.23	100

d

	Autonomous Drone					**Vanover**					**Bitmatta**					**Schaepper**				
	Speed in m/s	Power in W	Thrust in N	Time in s	Length in m	Speed in m/s	Power in W	Thrust in N	Time in s	Length in m	Speed in m/s	Power in W	Thrust in N	Time in s	Length in m	Speed in m/s	Power in W	Thrust in N	Time in s	Length in m
Segment 1	**6.52**	**548.14**	**19.80**	**1.27**	8.27	5.62	348.91	14.96	1.42	7.98	5.93	365.78	15.87	1.36	8.07	4.92	201.06	10.47	1.59	**7.82**
Segment 2	13.72	852.20	29.01	**1.82**	**25.01**	**13.83**	**863.85**	**29.22**	1.83	25.31	13.72	854.36	28.95	1.89	25.94	10.76	508.29	19.97	2.36	25.35
Segment 3	13.70	798.69	27.60	**1.96**	**26.89**	**13.86**	**853.69**	**28.98**	2.09	28.91	13.16	727.36	25.50	2.23	29.35	12.66	636.78	23.47	2.40	30.34
Segment 4	13.43	**1047.05**	**33.69**	1.61	21.62	12.97	953.47	31.62	**1.60**	**20.72**	**13.47**	1035.91	33.39	1.67	22.53	13.11	885.53	29.95	1.77	23.20
Full Race	**13.11**	**866.48**	**29.16**	**17.46**	**228.85**	12.96	843.50	28.65	17.96	232.79	12.89	822.50	27.96	18.74	241.52	11.55	623.53	22.95	21.16	244.49

a，训练超参数。**b**，与基线的比较，基线使用与我们方法相同的观测噪声模型。**c**，仿真评估，使用理想动力学（上）与真实动力学（下），以及真值观测（左）与噪声观测（右）。我们报告最快实现的无碰撞单圈时间（秒）、成功通过门的平均门裕度和最小门裕度，以及赛道完成度百分比。我们将我们的方法与进行零样本迁移的基于学习的方法（训练期间有和没有域随机化）以及传统的规划与控制方法进行比较[28]。**d**，比较每位飞行员在最快飞行比赛中的平均速度、功率、推力、时间和飞行距离。最佳数值以粗体表示。