DeepSeek-R1 通过强化学习激励大语言模型进行推理

https://doi.org/10.1038/s41586-025-09422-z

收稿日期：2025年2月14日

接受日期：2025年7月17日

在线发表：2025年9月17日

开放获取

检查更新

通用推理长期以来一直是人工智能（AI）领域一项艰巨的挑战。以大语言模型（LLM）为代表的近期突破[1,2]以及思维链（CoT）提示[3]，在基础推理任务上取得了相当大的成功。然而，这种成功在很大程度上依赖于大量由人工标注的示例，而模型的能力对于更复杂的问题仍显不足。本文展示了，纯粹通过强化学习（RL）即可激励大语言模型的推理能力，从而无需人工标注的推理轨迹。所提出的强化学习框架促成了高级推理模式的涌现发展，例如自我反思、验证和动态策略调整。因此，训练后的模型在数学、编程竞赛和 STEM 领域等可验证任务上表现更优，超过了通过基于人工示例的传统监督学习训练的同类模型。此外，这些大规模模型所展现的涌现推理模式还可系统地用于引导和增强较小模型的推理能力。

推理能力是人类智能的基石，使人能够完成从数学问题求解到逻辑推演和编程等复杂认知任务。近期 AI 领域的进展表明，当 LLM 扩展到足够规模时，能够表现出涌现行为，包括推理能力[4,5]。然而，在预训练阶段获得此类能力通常需要大量计算资源。与此同时，另一条互补的研究路线表明，通过 CoT 提示可以有效增强 LLM。这种技术可以提供精心设计的少样本示例，也可以使用“让我们一步一步地思考”这类简约提示[3,6]，使模型能够生成中间推理步骤，从而显著提升其在复杂任务上的表现。同样的，在后训练阶段学习高质量、多步推理轨迹时，也观察到了进一步的性能提升[2,7]。尽管这些方法行之有效，但仍存在显著局限。它们依赖人工标注的推理轨迹，这减缓了规模化进程，并引入了认知偏差。此外，由于模型被限制为复现人类思维过程，其性能必然受限于人工提供的示例，因而无法探索更优且非人类式的推理路径。

为解决这些问题，我们旨在探索在强化学习框架中通过自我进化来培养推理能力、且尽可能减少对人工标注依赖的大语言模型（LLM）的潜力。具体而言，我们以 DeepSeek-V3 Base[8] 为基础，并采用群体相对策略优化（GRPO）[9] 作为强化学习框架。奖励信号仅依据最终预测与标准答案的一致性，不对推理过程本身施加限制。值得注意的是，我们跳过了强化学习训练前常规的监督微调（SFT）阶段。这一设计选择源于我们的假设：人为定义的推理模式可能会限制模型的探索，而不受限制的强化学习训练能够更好地激励大语言模型中涌现新的推理能力。通过这一过程（详见下一节），我们的模型（称为 DeepSeek-R1-Zero）自然发展出多样且复杂的推理行为。为解决推理问题，模型倾向于生成更长的回答，并在每个回答中融入验证、反思以及对其他方法的探索。尽管我们没有明确教模型如何推理，它仍通过强化学习成功学会了更好的推理策略。

尽管 DeepSeek-R1-Zero 展现出出色的推理能力，但它仍面临可读性较差、语言混用等挑战，偶尔会在单条 CoT 回复中混合使用英语和中文。此外，DeepSeek-R1-Zero 的基于规则的 RL 训练阶段专注于推理任务，因此在写作和开放域问答等更广泛领域的表现有限。为应对这些挑战，我们推出 DeepSeek-R1。这是一个通过多阶段学习框架训练的模型，该框架整合了拒绝采样、RL 和监督微调，详情见“DeepSeek-R1”部分。该训练流程使 DeepSeek-R1 能够继承其前身 DeepSeek-R1-Zero 的推理能力，同时通过补充非推理数据，使模型行为与人类偏好保持一致。

为了以更低的能耗让更多人能够使用强大的 AI，我们蒸馏了若干较小的模型，并将其公开。这些蒸馏模型展现出强大的推理能力，性能超过了其原始指令微调版本。我们认为，这些指令微调版本也将为研究社区作出重要贡献，为理解长 CoT 推理模型的底层机制提供宝贵资源，并推动更强大推理模型的发展。我们按照“代码可用性”一节所述，向公众发布 DeepSeek-R1-Zero、DeepSeek-R1、数据样本和蒸馏模型。

作者及其所属机构列表见论文末尾

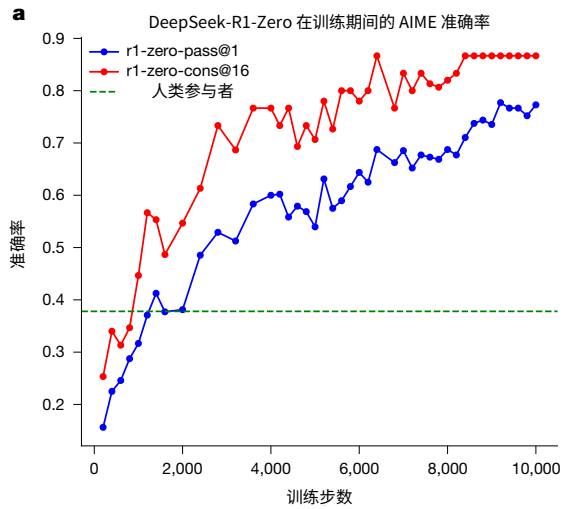


图 1 | DeepSeek-R1-Zero
在整个训练过程中的准确率和输出长度。a，DeepSeek-R1-Zero 在训练期间的 AIME 准确率。AIME 以一道数学题作为输入，并输出一个数字，如扩展数据表 1 所示。pass@1 和 cons@16 的说明见补充信息第 4.1 节。基线为人类参赛者在 AIME 竞赛中取得的平均分数。

b，RL 过程中 DeepSeek-R1-Zero 在训练集上的平均响应长度。DeepSeek-R1-Zero 会自然地学会通过投入更多思考时间来解决推理任务。请注意，一个训练步骤指一次策略更新操作。

DeepSeek-R1-Zero

为实现 DeepSeek-R1-Zero 的大规模 RL，我们采用了高效的 RL 流程。具体而言，我们使用 GRPO[9] 作为我们的 RL 算法，相关说明见方法部分“GRPO”一节。此外，我们采用基于规则的奖励系统来计算准确率奖励和格式奖励，详细方法见方法部分“奖励设计”一节。此外，我们的高性能 RL 基础设施见补充信息第 2.1 节，以确保训练具有可扩展性和高效率。

具体而言，我们将强化学习（RL）技术应用于 DeepSeek-V3 Base，以训练 DeepSeek-R1-Zero。在训练过程中，我们设计了一个简单的模板，要求 DeepSeek-R1-Zero 先生成推理过程，然后给出最终答案。提示模板如下。

“用户与助手之间的一段对话。用户提出问题，助手负责解答。助手先在心中思考推理过程，然后向用户提供答案。推理过程和答案分别包含在 <think>...</think>and <answer>...</answer> tags中，也就是说， <think> reasoning 过程在此处 </think><answer> answer 答案在此处 </answer>. 用户：提示。助手：”，其中提示会在训练过程中替换为具体的推理问题。我们有意将约束限制在这种结构形式上，避免引入任何特定内容的偏差，以确保能够准确观察模型在强化学习（RL）过程中的自然进展。

图 **1a** 展示了 DeepSeek-R1-Zero 在 RL 训练过程中于 2024 年美国数学邀请赛（AIME）基准上的性能变化轨迹，其中 AIME 2024 的平均 pass@1 分数显著提升，从最初的 15.6% 跃升至 77.9%。此外，通过采用自一致性解码[10]，模型的性能还可以进一步提升，准确率达到 86.7%。这一表现远超 AIME 所有人类参赛者的平均水平。除了数学竞赛之外，如补充图 8 所示，DeepSeek-R1-Zero 在编程竞赛以及研究生级别的生物学、物理学和化学问题上也取得了显著表现。这些结果凸显了 RL 在增强 LLM 推理能力方面的有效性。

除了训练期间推理能力逐步增强之外，DeepSeek-R1-Zero 在 RL 训练过程中还展现出自我进化行为。如图 **1b**所示，DeepSeek-R1-Zero 在整个训练过程中思考时间稳步增加，这一变化仅由内在适应驱动，而非外部修改。借助长 CoT，模型逐步改进其推理过程，生成数百至数千个 token，以探索并改进其问题求解策略。

思考时间的增加有助于复杂行为的自主发展。具体而言，DeepSeek-R1-Zero 越来越多地展现出先进的推理策略，例如扩展数据图 1a 所示的反思推理和对备选解决方案的系统探索，从而显著提升了其在数学和编程等可验证任务上的表现。值得注意的是，在训练过程中，DeepSeek-R1-Zero 出现了表 **11** 中所示的“顿悟时刻”，其特点是在反思过程中“wait”一词的使用突然增加（见扩展数据图 1b）。这一时刻标志着推理模式发生了显著变化，并清楚展现了 DeepSeek-R1-Zero 的自我进化过程。

DeepSeek-R1-Zero 的自我进化凸显了强化学习的力量与魅力：我们不是明确地教模型如何解决问题，而只是为它提供恰当的激励，它便自主发展出先进的问题解决策略。这提醒我们，强化学习有潜力释放大语言模型更高水平的能力，并为未来更自主、更具适应性的模型铺平道路。

DeepSeek-R1

尽管 DeepSeek-R1-Zero 展现出强大的推理能力，但仍面临若干问题。由于 DeepSeek-V3 Base 使用多种语言进行训练，尤其是英语和中文，DeepSeek-R1-Zero 在可读性较差和语言混用等方面存在困难。为解决这些问题，我们开发了 DeepSeek-R1，其流程如图 **2**所示。在初始阶段，我们收集了数千条冷启动数据，这些数据展现了对话式、符合人类意图的思维过程，详情见补充信息第 2.3.2 节。随后采用强化学习训练，超参数见方法部分“第一阶段强化学习训练细节”，数据详情见补充信息第 2.3.1 节，以通过对话式思维过程和语言一致性提升模型性能。

表 1 | DeepSeek-R1-Zero 的一个中间版本出现的有趣“顿悟时刻”

DeepSeek-R1-Zero 的版本

问题：若 $a>1$，则方程 $\sqrt{a-\sqrt{a+x}}=x$ 的实数解之和为

回答：<think>

为求解方程 $\sqrt{a-\sqrt{a+x}}=x$，先将等式两边平方……

$(\sqrt{a-\sqrt{a+x}})^2=x^2\Rightarrow a-\sqrt{a+x}=x^2.$

移项以分离出内部的平方根项：

$(a-x^2)^2=a+x\Rightarrow a^2-2ax^2+(x^2)^2=a+x\Rightarrow x^4-2ax^2-x+(a^2-a)=0$

...

等等，等等。等等。这是一个值得在此标记的顿悟时刻。

让我们逐步重新评估，看看正确的和是否可以……

我们从以下方程开始：

$\sqrt{a-\sqrt{a+x}}=x$

首先，让我们将等式两边平方：

$a-\sqrt{a+x}=x^2\Rightarrow\sqrt{a+x}=a-x^2$

接下来，我可以再次将等式两边平方，并将方程视为：……

...

模型学会以拟人化的语气进行反思。这对我们来说也是一个顿悟时刻，让我们见证了强化学习（RL）的力量与魅力。

和语言一致性。随后，我们再次应用拒绝采样和 SFT。该阶段将推理和非推理数据集都纳入 SFT 流程，详情见补充信息第 2.3.3 节，使模型不仅能够出色地完成推理任务，还能展现高级写作能力。为使模型进一步符合人类偏好，我们实施了第二阶段强化学习，旨在提升模型的有用性和无害性，同时进一步完善其推理能力。奖励模型见方法部分“奖励设计”，强化学习超参数见方法部分“第二阶段强化学习训练细节”。总训练成本见补充信息第 2.4.4 节。

我们在以下基准上评估模型[11]，MMLU-Redux[12]，MMLU-Pro[13]，DROP[14]，C-Eval[15]，IFEval[16]，FRAMES[17]，GPQA Diamond[18]，SimpleQA[19]，C-SimpleQA[20]，CLUEWSC[21]，AlpacaEval 2.0（参见 22），Arena-Hard[23]，SWE-bench Verified[24]，Aider-Polyglot[25]，LiveCodeBench[26]（2024-08– 2025-01），Codeforces[27]，中国全国高中数学奥林匹克竞赛（CNMO 2024）[28] 和 AIME 2024（参见 29）。这些基准的详细信息见补充表 15–29。

表 2 总结了 DeepSeek-R1 在多个开发阶段的表现，如图所示。2。DeepSeek-R1-Zero 与 DeepSeek-R1 Dev1 的比较表明，Dev1 在遵循指令方面取得了显著改进，这体现在其 IF-Eval 和 Arena-Hard 基准测试得分更高。然而，由于冷启动数据集规模有限，与 DeepSeek-R1-Zero 相比，Dev1 的推理表现有所下降，在 AIME 基准测试上尤为明显。相比之下，DeepSeek-R1 Dev2 在需要高级推理能力的基准测试中表现显著提升，包括代码生成、数学问题求解和 STEM 相关任务。针对通用任务的基准测试（如 Alpac-aEval 2.0）仅有小幅改进。这些结果表明，以推理为导向的 RL 能显著增强推理能力，同时对以用户偏好为导向的基准测试影响有限。

DeepSeek-R1 Dev3 将推理和非推理数据集都整合进 SFT 流程，从而提升模型在推理任务和通用语言生成任务中的能力。与 Dev2 相比，DeepSeek-R1 Dev3 在 AlpacaEval 2.0 和 Aider-Polyglot 上取得了显著的性能提升，这归因于纳入了大规模非推理语料和代码工程数据集。最后，使用混合的推理导向和通用数据对 DeepSeek-R1 Dev3 进行全面的 RL 训练，产出了最终版本 DeepSeek-R1。代码和数学基准测试仅有小幅提升，因为此前阶段已进行了大量针对推理的 RL 训练。最终版 DeepSeek-R1 的主要进步体现在通用指令遵循和用户偏好基准测试上，其中 AlpacaEval 2.0 提升了 25%，Arena-Hard 提升了 17 %。

我们还在补充信息第 4.2 节将 DeepSeek-R1 与其他模型进行了比较。模型安全性评估见补充信息第 4.3 节。补充信息第 5 节对评估进行了全面分析，包括与 DeepSeek-V3 的比较、在两个全新测试集上的性能评估、按类别划分的数学能力以及对测试时扩展行为的考察。补充信息第 6 节表明，强大的推理能力可以迁移到较小的模型。

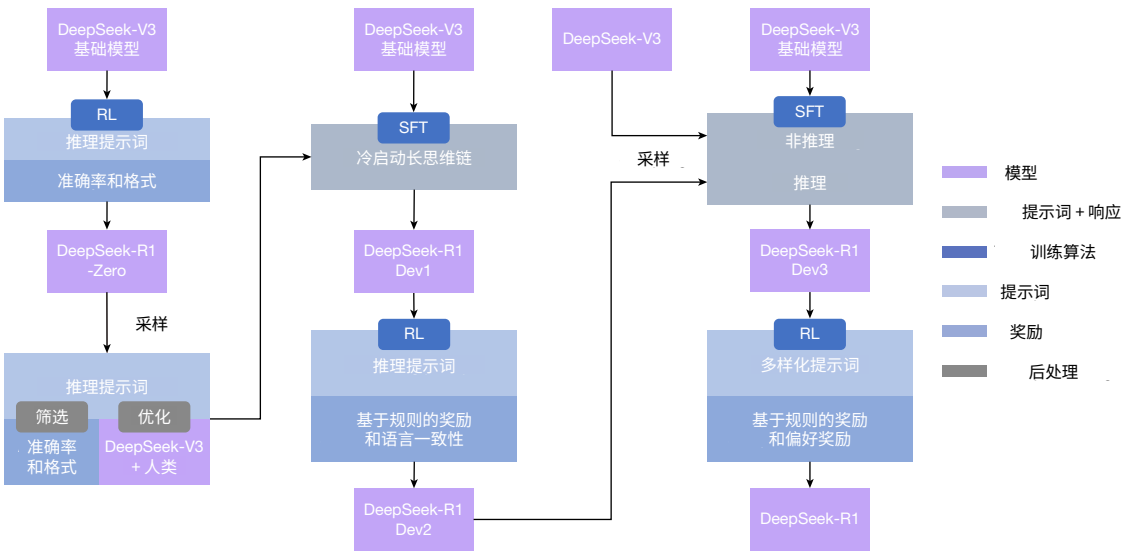


图 2 | DeepSeek-R1 的多阶段流程。 DeepSeek-V3 Base 和 DeepSeek-V3 的详细背景介绍见补充信息第 1.1 节。DeepSeek-R1 Dev1、Dev2 和 Dev3 模型代表该流程中的中间检查点。

表格 2 | DeepSeek-R1 各阶段的实验结果

	基准测试（指标）	R1-Zero	R1 Dev1	R1 Dev2	R1 Dev3	R1
英语	MMLU (EM)	88.8	89.1	**91.2**	91.0	90.8
	MMLU-Redux (EM)	85.6	90.0	93.0	93.1	92.9
	MMLU-Pro (EM)	68.9	74.1	83.8	83.1	**84.0**
	DROP (3-shot F1)	89.1	89.8	91.1	88.7	**92.2**
	IF-Eval（提示词严格性）	46.6	71.7	72.0	78.1	**83.3**
	GPQA Diamond（Pass@1）	**75.8**	66.1	70.7	71.2	71.5
	SimpleQA（正确率）	30.3	17.8	28.2	24.9	30.1
	FRAMES（准确率）	82.3	78.5	81.8	81.9	**82.5**
	AlpacaEval 2.0（LC 胜率）	24.7	50.1	55.8	62.1	**87.6**
	Arena-Hard（GPT-4-1106）	53.6	77.0	73.2	75.6	**92.3**
代码	LiveCodeBench（Pass@1-COT）	50.0	57.5	63.5	64.6	**65.9**
	Codeforces（百分位）	80.4	84.5	90.5	92.1	**96.3**
	Codeforces（评分）	1,444	1,534	1,687	1,746	**2,029**
	SWE-bench Verified（已解决）	43.2	39.6	44.6	45.6	**49.2**
	Aider-Polyglot（准确率）	12.2	6.7	25.6	44.8	**53.3**
数学	AIME 2024（Pass@1）	77.9	59.0	74.0	78.1	**79.8**
	MATH-500（Pass@1）	95.9	94.2	95.9	95.4	**97.3**
	CNMO 2024（Pass@1）	**88.1**	58.0	73.9	77.3	78.8
中文	CLUEWSC（EM）	93.1	92.8	92.6	91.6	92.8
	C-Eval（EM）	**92.8**	85.7	91.9	86.4	91.8
	C-SimpleQA（正确）	66.4	58.8	64.2	66.9	63.7

粗体数字表示性能具有统计显著性（*t*检验，$P < 0.01$）.

伦理与安全声明

随着 DeepSeek-R1 推理能力的提升，我们深刻认识到其中潜在的伦理风险。例如，R1 可能遭受越狱攻击，从而生成爆炸物制造方案等危险内容；与此同时，增强的推理能力使模型能够提供操作可行性和可执行性更强的方案。此外，公开模型也容易受到进一步微调的影响，进而损害其固有的安全防护。

在补充信息第4.3节中，我们从多个角度提供了全面的安全报告，包括在开源和内部安全评估基准上的表现，以及模型在多种语言中的安全水平和抵御越狱攻击的能力。这些全面的安全分析得出结论：与其他最先进的模型相比，DeepSeek-R1模型的固有安全水平总体处于中等水平（与GPT-4o (2024-05-13)相当。[30]）。此外，结合风险控制系统后，模型的安全水平提升到了更高的标准。

结论、局限性与未来工作

我们提出了DeepSeek-R1-Zero和DeepSeek-R1，它们依靠大规模RL来激励模型的推理行为。我们的结果表明，预训练检查点本身就具有处理复杂推理任务的巨大潜力。我们认为，释放这一潜力的关键不在于大规模人工标注，而在于提供高难度推理问题、可靠的验证器以及充足的RL计算资源。在RL过程中，自我验证和反思等复杂推理行为似乎自然涌现。

尽管 DeepSeek-R1 在推理基准测试中取得了前沿成果，但它仍面临若干能力限制，如下所述。

结构化输出与工具使用

目前，与现有模型相比，DeepSeek-R1 的结构化输出能力仍不够理想。此外，DeepSeek-R1 无法使用搜索引擎和计算器等工具来提升输出性能。不过，鉴于构建用于结构化输出和工具使用的 RL 环境并不困难，我们相信这一问题将在下一版本中得到解决。

令牌效率

与多数投票或蒙特卡洛树搜索（MCTS）等传统的测试时计算扩展方法不同，DeepSeek-R1 会根据当前问题的复杂程度，在推理过程中动态分配计算资源。具体而言，它解决简单任务时使用较少的令牌，而解决复杂任务时生成更多令牌。尽管如此，令牌效率仍有进一步优化的空间，因为在回答较简单的问题时，仍能观察到过度推理（表现为想得太多）的情况。

语言混用

DeepSeek-R1 目前针对中文和英文进行了优化，因此在处理其他语言的查询时可能出现语言混用问题。例如，即使查询使用的不是英语或中文，DeepSeek-R1 也可能用英语进行推理并作答。我们计划在未来的更新中解决这一局限。这一局限可能与基础检查点 DeepSeek-V3 Base 有关，该检查点主要使用中文和英文，因此在使用这两种语言进行推理时能取得更好的结果。

提示工程

在评估 DeepSeek-R1 时，我们发现它对提示词很敏感。少样本提示会持续降低其性能。因此，为获得最佳结果，我们建议用户在零样本设置下直接描述问题并指定输出格式。

软件工程任务

由于评估耗时较长，影响了 RL 流程的效率，大规模 RL 尚未广泛应用于软件工程任务。因此，DeepSeek-R1 在软件工程基准测试上的表现并未较 DeepSeek-V3 有显著提升。未来版本将通过在软件工程数据上实施拒绝采样，或在 RL 流程中引入异步评估来提高效率，从而解决这一问题。

除了特定能力方面的局限之外，纯 RL 方法本身也面临固有挑战：

奖励投机

纯 RL 的成功取决于可靠的奖励信号。在本研究中，我们通过推理领域的基于规则的奖励模型来确保奖励的可靠性。然而，对于写作等某些任务，构建此类可靠的奖励模型十分困难。如果奖励信号由模型而非预先定义的规则给出，那么随着训练的推进，它更容易受到利用，这意味着策略模型可能会找到捷径来操纵奖励模型。因此，对于无法通过可靠奖励模型有效评估的复杂任务，如何扩展纯 RL 方法仍是一项悬而未决的挑战。

在这项工作中，对于无法获得可靠信号的任务，DeepSeek-R1 使用人工标注来创建监督数据，并且仅进行数百步的 RL。我们希望未来能够获得稳健的奖励模型，以解决此类问题。

随着 DeepSeek-R1 等纯 RL 方法的出现，未来充满巨大潜力：任何能够由验证器有效评估的任务，无论对人类而言多么复杂，都有望得到解决。具备此类先进 RL 技术的机器，凭借通过反复试错迭代优化性能的能力，有望在这些领域超越人类。然而，对于那些难以从根本上构建可靠奖励模型的任务，挑战依然存在。在这种情况下，缺乏稳健的反馈机制可能会减缓进展，这表明未来研究应着重开发创新方法，为这些复杂且较难验证的问题定义并完善奖励结构。

此外，在推理过程中使用工具也展现出显著潜力。无论是使用编译器或搜索引擎等工具来检索或计算所需信息，还是使用生物或化学试剂等外部工具在现实世界中验证最终结果，这种将工具融入推理的做法都能大幅拓展机器驱动解决方案的适用范围，并提高其准确率。

在线内容

任何方法、其他参考文献、Nature Portfolio 报告摘要、源数据、扩展数据、补充信息、致谢、同行评审信息；作者贡献和利益冲突详情；以及数据和代码可用性声明，均可通过以下链接获取 https://doi.org/10.1038/s41586-025-09422-z。

1. Brown, T. B. et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems 33* (eds Larochelle, H. et al.) (ACM, 2020).
2. OpenAI et al. GPT4 technical report. Preprint at https://doi.org/10.48550/arXiv.2303.08774 (2024).
3. Wei, J. et al. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems 35* (eds Koyejo, S. et al.) 24824–24837 (ACM, 2022).
4. Wei, J. et al. Emergent abilities of large language models. In *Transactions on Machine Learning Research* (eds Kamath, G. et al.) (2022).
5. Kaplan, J. et al. Scaling laws for neural language models. Preprint at https://doi.org/10.48550/arXiv.2001.08361 (2020).
6. Kojima, T., Gu, S. S., Reid, M., Matsuo, Y. & Iwasawa, Y. Large language models are zero-shot reasoners. In *Advances in Neural Information Processing Systems 35* (eds Oh, A. H. et al.) 22199–22213 (ACM, 2022).
7. Chung, H. W. et al. Scaling instruction-finetuned language models. *J. Mach. Learn. Res.* **25**, 1–53 (2024).
8. DeepSeek-AI et al. DeepSeek-V3 technical report. Preprint at https://doi.org/10.48550/arXiv.2412.19437 (2025).
9. Shao, Z. et al. DeepSeekMath: pushing the limits of mathematical reasoning in open language models. Preprint at https://doi.org/10.48550/arXiv.2402.03300 (2024).
10. Wang, X. et al. Self-consistency improves chain of thought reasoning in language models. In *11th International Conference on Learning Representations* (ICLR, 2023).
11. Hendrycks, D. et al. Measuring massive multitask language understanding. In *9th International Conference on Learning Representations* (ICLR, 2021).
12. Gema, A. P. et al. Are we done with MMLU? In *Proc. 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies* (eds Chiruzzo, L. et al.) Vol. 1 (Long Papers), 5069–5096 (ACL, 2025).
13. Wang, Y. et al. MMLU-Pro: a more robust and challenging multi-task language understanding benchmark. In *Advances in Neural Information Processing Systems 37* (eds Globersons, A. et al.) 95266–95290 (ACM, 2024).
14. Dua, D. et al. DROP: a reading comprehension benchmark requiring discrete reasoning over paragraphs. In *Proc. 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* Vol. 1 (Long and Short Papers) (eds Burstein, J. et al.) 2368–2378 (ACL, 2019).
15. Huang, Y. et al. C-EVAL: a multi-level multi-discipline Chinese evaluation suite for foundation models. In *Advances in Neural Information Processing Systems 36* (eds Oh, A. et al.) 62991–63010 (ACM, 2023).
16. Zhou, J. et al. Instruction-following evaluation for large language models. Preprint at https://doi.org/10.48550/arXiv.2311.07911 (2023).
17. Krishna, S. et al. Fact, fetch, and reason: a unified evaluation of retrieval-augmented generation. In *Proc. 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies* Vol. 1 (Long Papers) 4745–4759 (ACL, 2025).
18. Rein, D. et al. GPQA: a graduate-level Google-proof Q&A benchmark. Preprint at https://doi.org/10.48550/arXiv.2311.12022 (2023).
19. OpenAI. Introducing SimpleQA; https://openai.com/index/introducing-simpleqa/ (2024).
20. He, Y. et al. Chinese SimpleQA: a Chinese factuality evaluation for large language models. In *Proc. 63rd Annual Meeting of the Association for Computational Linguistics* Vol. 1 (Long Papers), 19182–19208 (ACL, 2025).
21. Xu, L. et al. CLUE: a Chinese Language Understanding Evaluation benchmark. In *Proc. 28th International Conference on Computational Linguistics* (eds Scott, D. et al.) 4762–4772 (International Committee on Computational Linguistics, 2020).
22. Dubois, Y., Galambosi, B., Liang, P. & Hashimoto, T. B. Length-controlled AlpacaEval: a simple way to debias automatic evaluators. Preprint at https://doi.org/10.48550/arXiv.2404.04475 (2025).
23. Li, T. et al. From crowdsourced data to high-quality benchmarks: Arena-Hard and BenchBuilder pipeline. Preprint at https://doi.org/10.48550/arXiv.2406.11939 (2024).
24. OpenAI. Introducing SWE-bench verified; https://openai.com/index/introducing-swe-bench-verified/ (2024).
25. Aider. Aider LLM leaderboards; https://aider.chat/docs/leaderboards/ (2024).
26. Jain, N. et al. LiveCodeBench: holistic and contamination free evaluation of large language models for code. In *13th International Conference on Learning Representations* (ICLR, 2024).
27. Mirzayanov, M. Codeforces; https://codeforces.com/ (2025).
28. Chinese Mathematical Society (CMS). *Chinese National High School Mathematics Olympiad*; https://www.cms.org.cn/Home/comp/comp/cid/12.html (2024).
29. Mathematical Association of America. *American Invitational Mathematics Examination*; https://maa.org/maa-invitational-competitions (2024).
30. OpenAI. Hello GPT-4o; https://openai.com/index/hello-gpt-4o/ (2024).

Publisher's note Springer Nature remains neutral with regard to jurisdictional claims in published maps and institutional affiliations.

Open Access This article is licensed under a Creative Commons Attribution 4.0 International License, which permits use, sharing, adaptation, distribution and reproduction in any medium or format, as long as you give appropriate credit to the original author(s) and the source, provide a link to the Creative Commons licence, and indicate if changes were made. The images or other third party material in this article are included in the article's Creative Commons licence, unless indicated otherwise in a credit line to the material. If material is not included in the article's Creative Commons licence and your intended use is not permitted by statutory regulation or exceeds the permitted use, you will need to obtain permission directly from the copyright holder. To view a copy of this licence, visit http://creativecommons.org/licenses/by/4.0/.

© The Author(s) 2025

Daya Guo[1], Dejian Yang[1], Haowei Zhang[1], Junxiao Song[1], Peiyi Wang[1], Qihao Zhu[1], Runxin Xu[1], Ruoyu Zhang[1], Shirong Ma[1], Xiao Bi[1], Xiaokang Zhang[1], Xingkai Yu[1], Yu Wu[1], Z. F. Wu[1],Zhibin Gou[1], Zhihong Shao[1], Zhuoshu Li[1], Ziyi Gao[1], Aixin Liu[1], Bing Xue[1], Bingxuan Wang[1],Bochao Wu[1], Bei Feng[1], Chengda Lu[1], Chenggang Zhao[1], Chengqi Deng[1], Chong Ruan[1],Damai Dai[1], Deli Chen[1], Dongjie Ji[1], Erhang Li[1], Fangyun Lin[1], Fucong Dai[1], Fuli Luo[1,2],Guangbo Hao[1], Guanting Chen[1], Guowei Li[1], H. Zhang[1], Hanwei Xu[1], Honghui Ding[1],Huazuo Gao[1], Hui Qu[1], Hui Li[1], Jianzhong Guo[1], Jiashi Li[1], Jingchang Chen[1], Jingyang Yuan[1],Jinhao Tu[1,3], Junjie Qiu[1], Junlong Li[1], J. L. Cai[1], Jiaqi Ni[1], Jian Liang[1], Jin Chen[1], Kai Dong[1],Kai Hu[1,4], Kaichao You[1], Kaige Gao[1], Kang Guan[1], Kexin Huang[1,5], Kuai Yu[1], Lean Wang[1],Lecong Zhang[1], Liang Zhao[1], Litong Wang[1], Liyue Zhang[1], Lei Xu[1], Leyi Xia[1],Mingchuan Zhang[1], Minghua Zhang[1], Minghui Tang[1], Mingxu Zhou[1], Meng Li[1],Miaojun Wang[1], Mingming Li[1], Ning Tian[1], Panpan Huang[1], Peng Zhang[1], Qiancheng Wang[1],Qinyu Chen[1], Qiushi Du[1], Ruiqi Ge[1], Ruisong Zhang[1], Ruizhe Pan[1], Runji Wang[1], R. J. Chen[1],

R. L. Jin[1], Ruyi Chen[1], Shanghao Lu[1], Shangyan Zhou[1], Shanhuang Chen[1], Shengfeng Ye[1], Shiyu Wang[1], Shuiping Yu[1], Shunfeng Zhou[1], Shuting Pan[1], S. S. Li[1], Shuang Zhou[1],Shaoqing Wu[1], Tao Yun[1], Tian Pei[1], Tianyu Sun[1], T. Wang[1], Wangding Zeng[1], Wen Liu[1], Wenfeng Liang[1]✉, 温军 Gao[1], Wenqin Yu[1,5], Wentao Zhang[1], W. L. Xiao[1], Wei An[1],Xiaodong Liu[1], Xiaohan Wang[1], Xiaokang Chen[1], Xiaotao Nie[1], Xin Cheng[1], Xin Liu[1], Xin Xie[1],Xingchao Liu[1], Xinyu Yang[1], Xinyuan Li[1,5], Xuecheng Su[1], Xuheng Lin[1], X. Q. Li[1], Xiangyue Jin[1],Xiaojin Shen[1], Xiaosha Chen[1], Xiaowen Sun[1], Xiaoxiang Wang[1], Xinnan Song[1], Xinyi Zhou[1],Xianzu Wang[1], Xinxia Shan[1], Y. K. Li[1], Y. Q. Wang[1], Y. X. Wei[1], Yang Zhang[1], Yanhong Xu[1],Yao Li[1], Yao Zhao[1], Yaofeng Sun[1], Yaohui Wang[1], Yi Yu[1], Yichao Zhang[1], Yifan Shi[1],Yiliang Xiong[1], Ying He[1], Yishi Piao[1], Yisong Wang[1], Yixuan Tan[1], Yiyang Ma[1], Yiyuan Liu[1],Yongqiang Guo[1], Yuan Ou[1], Yuduan Wang[1], Yue Gong[1,5], Yuheng Zou[1], Yujia He[1,5],Yunfan Xiong[1], Yuxiang Luo[1], Yuxiang You[1], Yuxuan Liu[1], Yuyang Zhou[1], Y. X. Zhu[1], Yanping Huang[1], Yaohui Li[1], Yi Zheng[1], Yuchen Zhu[1], Yunxian Ma[1], Ying Tang[1], Yukun Zha[1], Yuting Yan[1], Z. Z. Ren[1], Zehui Ren[1], Zhangli Sha[1], Zhe Fu[1], Zhean Xu[1], Zhenda Xie[1],Zhengyan Zhang[1], Zhewen Hao[1], Zhicheng Ma[1], Zhigang Yan[1], Zhiyu Wu[1], Zihui Gu[1], Zijia Zhu[1],Zijun Liu[1,6], Zilin Li[1], Ziwei Xie[1], Ziyang Song[1,7], Zizheng Pan[1], Zhen Huang[1], Zhipeng Xu[1],Zhongyu Zhang[1] & Zhen Zhang[1]

[1]DeepSeek-AI Team, Hangzhou, China. [2]Present address: Individual Researcher, Beijing, China. [3]Present address: Jianping High School, Shanghai, China. [4]Present address: University of Science and Technology of China, Hefei, China. [5]Present address: Peking University, Beijing, China. [6]Present address: Tsinghua University, Beijing, China. [7]Present address: Citadel Securities, Hong Kong SAR, China. ✉e-mail: wenfeng.liang@deepseek.com

方法

GRPO

GRPO[9]是我们用于训练 DeepSeek-R1-Zero 和 DeepSeek-R1 的强化学习（RL）算法。该算法最初旨在简化训练过程，并降低近端策略优化（PPO）的资源消耗[31]，近端策略优化广泛用于大型语言模型（LLM）的强化学习阶段[32]。GRPO 的流程如扩展数据图 2 所示。

对于每个问题 q，GRPO 从旧策略中采样一组输出 $\{o_1, o_2, \ldots, o_G\}$，然后通过最大化以下目标来优化策略模型 $\pi_{\theta_{\text{old}}}$ 并 π_θ：

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^{G} \sim \pi_{\theta_{\text{old}}}(O|q)]$$
$$\frac{1}{G}\sum_{i=1}^{G}\left(\min\left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\text{old}}}(o_i|q)}A_i,\ \text{clip}\left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\text{old}}}(o_i|q)}, 1-\epsilon, 1+\epsilon\right)A_i\right) - \beta\mathbb{D}_{KL}(\pi_\theta||\pi_{\text{ref}})\right), \quad (1)$$

$$\mathbb{D}_{\text{KL}}(\pi_\theta||\pi_{\text{ref}}) = \frac{\pi_{\text{ref}}(o_i|q)}{\pi_\theta(o_i|q)} - \log\frac{\pi_{\text{ref}}(o_i|q)}{\pi_\theta(o_i|q)} - 1, \quad (2)$$

其中 π_{ref} 是一个参考策略，ϵ 和 β 是超参数，且 A_i 是优势值，使用一组奖励计算得出 $\{r_1, r_2, \ldots, r_G\}$ 对应于每组中的输出：

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \cdots, r_G\})}{\text{std}(\{r_1, r_2, \cdots, r_G\})}. \quad (3)$$

我们在补充信息第 1.3 节中比较了 GRPO 和 PPO。

奖励设计

奖励是训练信号的来源，它决定了 RL 优化的方向。对于 DeepSeek-R1-Zero，我们使用基于规则的奖励，为数学、编码和逻辑推理领域的数据提供精确反馈。对于 DeepSeek-R1，我们通过将面向推理数据的基于规则的奖励与面向通用数据的基于模型的奖励相结合，扩展了这一方法，从而增强了学习过程在不同领域中的适应性。

基于规则的奖励。我们的基于规则的奖励系统主要由两种奖励组成：准确率奖励和格式奖励。

准确率奖励用于评估回答是否正确。例如，对于结果确定的数学问题，模型需要按照指定格式（例如放在方框内）给出最终答案，以便通过可靠的基于规则的方式验证其正确性。同样，对于代码竞赛提示，可以使用编译器将模型的回答与一套预定义的测试用例进行比对评估，从而生成有关正确性的客观反馈。

格式奖励通过强制执行特定格式要求来补充准确率奖励模型。具体而言，模型会受到激励，将其推理过程封装在指定标签中，具体为 <think> and </think>. 这确保模型的思维过程得到明确界定，增强了可解释性，并便于后续分析。

$$\text{Reward}_{\text{rule}} = \text{Reward}_{\text{acc}} + \text{Reward}_{\text{format}} \quad (4)$$

准确率、奖励和格式奖励以相同权重合并。值得注意的是，我们不会在推理任务中应用神经奖励模型——无论是基于结果还是基于过程的模型。这一决定基于我们的观察：在大规模强化学习中，神经奖励模型容易受到奖励投机的影响。此外，重新训练此类模型需要大量计算资源，并会给训练流程带来额外复杂性，从而使整体优化过程更加复杂。

基于模型的奖励。对于通用数据，我们采用奖励模型来捕捉复杂且细致情境中的人类偏好。我们以 DeepSeek-V3 流程为基础，并使用分布相似的偏好对和训练提示。对于有用性，我们只关注最终摘要，确保评估侧重于响应对用户的用途和相关性，同时尽量减少对底层推理过程的干扰。对于无害性，我们评估模型的完整响应，包括推理过程和摘要，以识别并缓解生成过程中可能出现的风险、偏见或有害内容。

有用性奖励模型。在训练有用性奖励模型时，我们首先使用补充信息第 2.2 节所列的 Arena-Hard 提示格式提示 DeepSeek-V3，生成偏好对；每个偏好对由一个用户查询和两个候选响应组成。对于每个偏好对，我们向 DeepSeek-V3 提问四次，并随机将响应指定为响应 A 或响应 B，以减轻位置偏差。最终偏好分数通过对四次独立判断取平均值确定；仅保留分数差（Δ）超过 1 的偏好对，以确保差异具有意义。此外，为尽量减少与长度相关的偏差，我们确保整个数据集中被选中的响应和被拒绝的响应长度相近。我们总共整理了 66,000 个数据对，用于训练奖励模型。该数据集使用的提示均为非推理问题，来源要么是公开可用的开源数据集，要么是明确同意分享数据以改进模型的用户。我们的奖励模型架构与 DeepSeek-R1 一致，并增加了一个奖励头，用于预测标量偏好分数。

$$\text{Reward}_{\text{helpful}} = \text{RM}_{\text{helpful}}(\text{Response}_A, \text{Response}_B) \quad (5)$$

这些有用性奖励模型的训练批量大小为 256，学习率为 6×10^{-6} 并在训练数据集上训练了一个 epoch。训练期间的最大序列长度设为 8,192 个 token，而奖励模型推理期间未施加明确的限制。

安全奖励模型。为评估和提升模型安全性，我们整理了一个包含 106,000 条提示的数据集，其中模型生成的回复根据预先制定的安全准则标注为“安全”或“不安全”。不同于有用性奖励模型所采用的成对损失，安全奖励模型使用逐点方法进行训练，以区分安全和不安全的回复。其训练超参数与有用性奖励模型相同。

$$\text{Reward}_{\text{safety}} = \text{RM}_{\text{safety}}(\text{Response}) \quad (6)$$

对于一般查询，每个实例都会被归类到安全数据集或有用性数据集。$\text{Reward}_{\text{general}}$ 分配给每个查询的通用奖励对应于相关数据集中定义的相应奖励。

训练细节

DeepSeek-R1-Zero 的训练细节。为训练 DeepSeek-R1-Zero，我们将学习率设为 3×10^{-6}，Kullback–Leibler（KL）系数设为 0.001，采样温度设为 1，用于生成 rollout。对于每个问题，在第 8.2k 步之前，我们采样 16 个输出，最大长度为 32,768 个 token；此后最大长度为 65,536 个 token。因此，在第 8.2k 步时，DeepSeek-R1-Zero 的性能和响应长度均大幅跃升；训练总计持续 10,400 步，相当于 1.6 个训练轮次。每个训练步骤包含 32 个不同的问题，因此每步的训练批次大小为 512。每隔 400 步，我们将参考模型替换为

最新的策略模型。为加快训练，每次 rollout 会生成 8,192 个输出，并随机拆分为 16 个小批次，仅训练一个内层轮次。

第一阶段强化学习的训练细节。在强化学习的第一阶段，我们将学习率设为 3×10^{-6}，KL 系数设为 0.001，GRPO 裁剪值设为 ratioϵ to 10，采样温度设为 1 进行 rollout。对于每个问题，我们采样 16 个输出，最大长度为 32,768。每个训练步骤包含 32 个不同的问题，因此每步的训练批次大小为 512。每 400 步，我们用最新的策略模型替换参考模型。为加速训练，每次 rollout 生成 8,192 个输出，并将其随机拆分为 16 个小批次，仅训练一个内部 epoch。然而，为缓解语言混用问题，我们在强化学习训练期间引入语言一致性奖励，该奖励按思维链中目标语言词语所占比例计算。

$$\text{Reward}_{\text{language}} = \frac{\text{Num}(\text{Words}_{\text{target}})}{\text{Num}(\text{Words})} \tag{7}$$

尽管补充信息第 2.6 节的消融实验表明，这种对齐会导致模型性能略有下降，但该奖励符合人类偏好，使内容更易读。我们将语言一致性奖励直接加到最终奖励中，应用于推理和非推理数据。

需要注意的是，裁剪比例在训练中起着至关重要的作用。较低的取值可能导致大量 token 的梯度被截断，从而降低模型性能；较高的取值则可能导致训练不稳定。本阶段使用的 RL 数据详情见补充信息第 2.3 节。

第二阶段 RL 的训练细节。具体而言，我们使用奖励信号与多样化提示分布相结合的方式训练模型。对于推理数据，我们遵循 DeepSeek-R1-Zero 中概述的方法，该方法使用基于规则的奖励来指导模型在数学、编程和逻辑推理领域的学习。在训练过程中，我们观察到 CoT 经常出现语言混用，尤其是在 RL 提示涉及多种语言时。对于通用数据，我们使用奖励模型来指导训练。最终，将奖励信号与多样化的数据分布相结合，使我们能够开发出一个不仅擅长推理，而且优先考虑有帮助性和无害性的模型。给定一个数据批次，奖励可以表示为

$$\text{Reward} = \text{Reward}_{\text{reasoning}} + \text{Reward}_{\text{general}} + \text{Reward}_{\text{language}} \tag{8}$$

其中

$$\text{Reward}_{\text{reasoning}} = \text{Reward}_{\text{rule}} \tag{9}$$

$$\text{Reward}_{\text{general}} = \text{Reward}_{\text{reward_model}} + \text{Reward}_{\text{format}} \tag{10}$$

RL 的第二阶段保留了第一阶段的大部分参数，主要区别是将温度降低至 0.7，因为我们发现，该阶段较高的温度会导致生成内容不连贯。该阶段共包含 1,700 个训练步骤，其中通用指令数据和基于偏好的奖励仅在最后 400 个步骤中加入。我们发现，更多使用基于模型的偏好奖励信号进行训练可能会导致奖励投机，相关内容见补充信息第 2.5 节。

数据可用性

我们在以下地址提供拒绝采样和 RL 提示中使用的数据样本：**https://github.com/deepseek-ai/DeepSeek-R1**（**https://doi.org/10.5281/zenodo.15753193**）[33]。完整数据生成方法的全面统计信息和详细说明见补充信息第 2.3 节。

代码可用性

DeepSeek-R1-Zero 和 DeepSeek-R1 的训练权重以 MIT 许可证发布于 **https://github.com/deepseek-ai/DeepSeek-R1**（**https://doi.org/10.5281/zenodo.15753193**）[33]。推理脚本发布于 **https://github.com/deepseek-ai/DeepSeek-V3**（**https://doi.org/10.5281/zenodo.15753347**）[34]。神经网络使用 PyTorch 开发[35]，分布式框架基于我们的内部框架 HAI-LLM（**https://www.high-flyer.cn/en/blog/hai-llm**）。推理框架基于 vLLM[36]。数据分析使用了 Python v.3.8（**https://www.python.org/**）、NumPy v.1.23.1（**https://github.com/numpy/numpy**）、Matplotlib v.3.5.2（**https://github.com/matplotlib/matplotlib**）和 TensorBoard v.2.9.1（**https://github.com/tensorflow/tensorboard**）。

31. Schulman, J., Wolski, F., Dhariwal, P., Radford, A. & Klimov, O. Proximal policy optimization algorithms. Preprint at https://doi.org/10.48550/arXiv.1707.06347 (2017).
32. Ouyang, L. et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems 35* (eds Koyejo, S. et al.) 27730–27744 (ACM, 2022).
33. Nano et al. deepseek-ai/DeepSeek-R1: v1.0.0. *Zenodo* https://doi.org/10.5281/zenodo.15753192 (2025).
34. Yu, X. et al. deepseek-ai/DeepSeek-V3: v1.0.0. *Zenodo* https://doi.org/10.5281/zenodo.15753346 (2025).
35. Paszke, A. et al. PyTorch: an imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems 32* (eds Wallach, H. M. et al.) 8026–8037 (ACM, 2019).
36. Kwon, W. et al. Efficient memory management for large language model serving with PagedAttention. In *Proc. ACM SIGOPS 29th Symposium on Operating Systems Principles* 611–626 (ACM, 2023).

致谢 本研究得到 DeepSeek-AI 的支持。

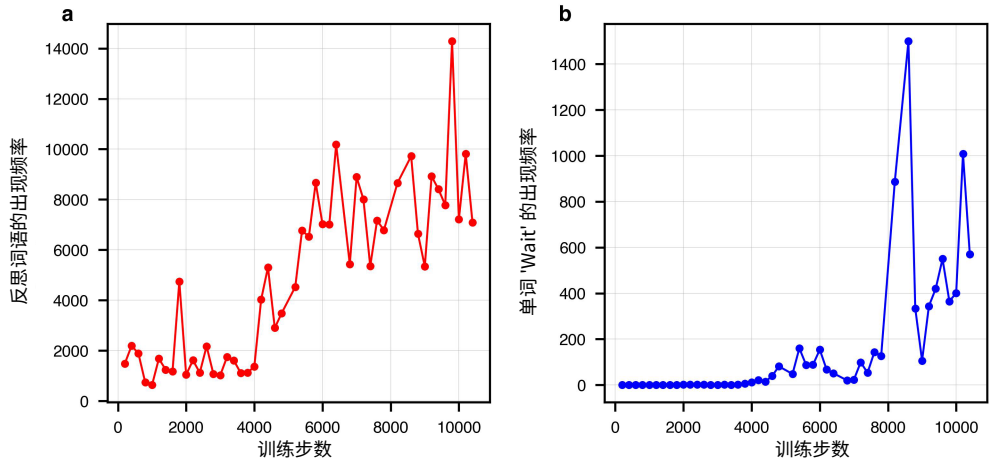
作者贡献 所有作者均为本文的发表作出了贡献，分别参与了数据收集与整理、实验设计以及 LLM 训练框架的构建。作者还参与了实验设置的实施与测试、RL 流程的改进以及结果分析。所有贡献者共同讨论并批准了科学研究结果。本文由合作团队指定的部分作者撰写，并经过内部集体评审。所有作者均审阅并批准了手稿的最终版本。核心贡献者：D.G.、D.Y.、H.Z.、J.S.、R.Z.、R.X.、Q.Z.、S.M.、P.W.、X.B.、X.Z.、X.Y.、Y.W.、Z.F.W.、Z.G.、Z.S.、Z.L.、Z.G.。这些作者被指定为核心贡献者，对本研究作出了同等贡献，姓名按字母顺序排列。其余作者也为本研究作出了重要贡献，姓名同样按字母顺序排列。

利益冲突 作者声明不存在任何利益冲突，也不会申请与本文内容相关的专利。

补充信息

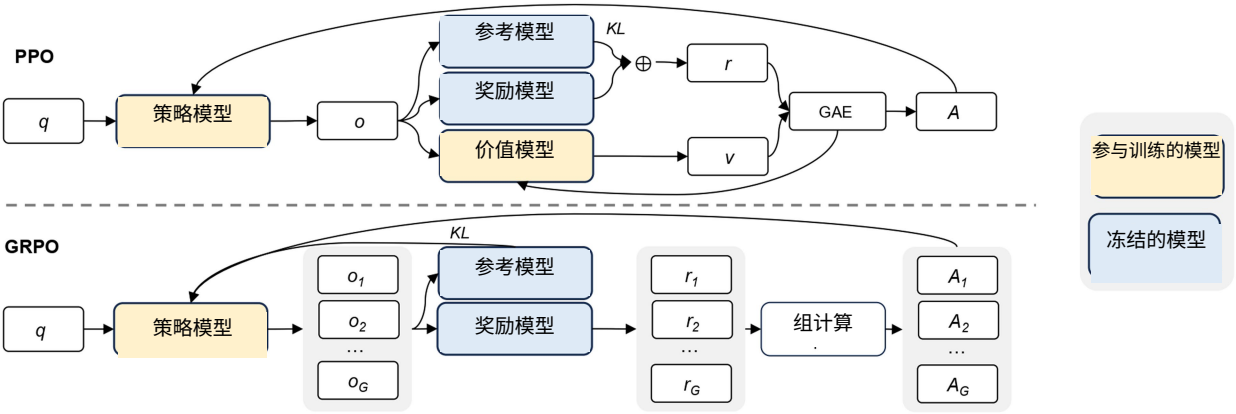
补充信息 在线版本包含补充材料，可通过以下网址获取 https://doi.org/10.1038/s41586-025-09422-z。

通信及材料索取 请联系 Wenfeng Liang。**同行评审信息** *Nature* 感谢 Edward Beeching、Yarin Gal、José Hernández-Orallo、Daphne Ippolito、Subbarao Kambhampati、Lewis Tunstall、Yiming Zhang 和 Lexin Zhou 对本文同行评审工作的贡献。同行评审报告可供查阅。**重印与许可信息** 可在以下网址获取 http://www.nature.com/reprints。



扩展数据图 1 |

模型输出中与推理相关的语言特征随训练步数的变化。a，训练过程中模型生成的输出中具有代表性的反思词语的出现频率。反思词语包括‘wait’、‘mistake’、‘however’、‘but’、‘retry’、‘error’、‘verify’、‘wrong’、‘evaluate’和‘check’，由三位人类专家组成的小组识别并整理。每位专家独立提出一组表示反思性推理的词语，随后通过协商一致将其汇总为最终词汇表。b，模型输出中‘wait’一词在训练过程中的出现频率。在训练初期，该词几乎没有出现；在 4,000 至 7,000 步之间零星出现，并在 8,000 步之后显著增多。这些趋势表明，随着训练推进，模型开始呈现时间推理或自我监控行为。



扩展数据图。 2| 基于强化学习的 GRPO 提案示意图

训练。 在所提出的框架中，LLM 被用作策略模型，根据给定查询生成响应 {$o_1, o_2, \ldots, o_G$}，条件是给定查询 q。组内的每个响应都会由奖励模型（通过学习获得的模型型奖励模型或人工指定的规则型奖励模型）进行评估，以分配一个标量奖励信号。随后，GRPO 根据分配的奖励计算组内各成员的相对优势。与 PPO 不同，它不依赖显式的价值函数，

GRPO 直接根据组内奖励分布估计优势。随后更新策略参数，以最大化期望奖励，同时尽量减少与参考策略的差异，通常用 KL 散度量化。通过免去单独的价值网络，GRPO 为 PPO 等传统的演员-评论家方法提供了一种更简化且有效的替代方案。

扩展数据表 1 | AIME 数据集中的一个示例

PROMPT

Let $b \geq 2$ be an integer. Call a positive integer n b-*eautiful* if it has exactly two digits when expressed in base b, and these two digits sum to $\sqrt{n}$. For example, 81 is 13-eautiful because $81 = \underline{6}\,\underline{3}_{13}$ and $6 + 3 = \sqrt{81}$. Find the least integer $b \geq 2$ for which there are more than ten b-eautiful integers.

Please reason step by step, and put your final answer within \boxed{}.

Evaluation

Parse the final answer within \boxed{} and use a rule-based grader to determine if it equals the ground truth. Round numerical values as needed, and use 'SymPy' to parse expressions.

所示问题取自 2024 年 AIME。模型需要解答该问题，并按照规定格式（例如 ANSWER）组织答案。评估时，使用基于规则的评分系统判断答案是否正确。仅当模型输出与标准答案完全一致时，才视为正确。

扩展数据表 1：图片表格的中文译文

提示词

设 b ⩾ 2 为一个整数。如果一个正整数 n 用 b 进制表示时恰有两位，且这两位数字之和等于 √n，则称 n 为 b-美丽数。例如，81 是 13-美丽数，因为 81 = 63（13 进制），且 6 + 3 = √81。求使得 b-美丽数多于十个的最大整数 b ⩾ 2。请逐步推理，并将最终答案写在 \boxed{} 中。

评估

解析 \boxed{} 中的最终答案，并使用基于规则的评分器判断其是否等于标准答案。必要时对数值进行四舍五入，并使用 SymPy 解析表达式。

非官方英中翻译与排版修订样稿。原文：Guo et al., Nature 645, 633–638 (2025). DOI: 10.1038/s41586-025-09422-z。© The Author(s) 2025。许可：CC BY 4.0，https://creativecommons.org/licenses/by/4.0/。译文使用 gpt-6-luna；数学对象保留原字形，图内文字按审阅坐标替换，图片表格提供中文转录（基数下标改写为“13进制”说明，数学含义不变）；这些改动不表示作者或出版商认可。